

大模型与多模态生成模型训练框架技术图谱

面向工程选型的训练框架报告，覆盖预训练、继续预训练、SFT、参数高效微调、偏好优化、RL 后训练、多模态训练，以及图像和视频生成模型训练栈。

Winston

资料口径截至 2026-05-04

Primary repositories · official documentation · technical papers

| 目录

01	执行摘要	训练框架不能用总榜理解
02	分类框架	按训练阶段和系统层级拆分
03	从零训练与分布式底座	Megatron、DeepSpeed、TorchTitan、NeMo
04	SFT、LoRA 与偏好优化	LlamaFactory、Axolotl、ms-swift、TRL
05	RL 后训练系统	verl、OpenRLHF、NeMo RL、AReAL、slime
06	多模态训练	VLM、MLLM、视觉预训练
07	图像与视频生成训练	Diffusers、Open-Sora、Wan、HunyuanVideo
08	选型方法与边界	场景入口、风险清单、资料口径

执行摘要

现阶段训练框架的关键分化，不在项目热度，而在训练目标、模型形态和系统边界。预训练底座、SFT 工作台、RL 后训练系统、VLM 配方库和视频生成模型项目承担的是不同职责，混合排序会掩盖真正的选型问题。

FINDING 01

训练阶段先于项目名

从零训练关注并行、显存、吞吐和恢复；业务微调关注数据、模板、adapter、导出和验证；在线 RL 关注 rollout、reward、环境和权重同步。

FINDING 02

后训练已进入系统工程

DPO 等离线偏好优化仍可作为普通训练任务处理，GRPO/PPO/Agentic RL 则需要训练引擎、推理引擎、奖励服务和环境接口协同。

FINDING 03

多模态没有统一入口

VLM 训练比文本 SFT 多出 processor、图像分辨率、多图样本、视觉 token、projector 和评测链路，模型族适配比算法名更重要。

FINDING 04

生成模型按模型族选栈

图像 LoRA、Flux/SDXL 微调、Wan/Hunyuan 视频 LoRA、Open-Sora 式研究训练依赖不同数据格式、VAE/DiT/text encoder 和显存预算。

本报告的结论范围

本文讨论的是训练框架与训练闭环，不展开推理服务框架。vLLM、SGLang、FlashAttention、xFormers、Liger Kernel、torchao 等项目仅在影响训练吞吐、RL rollout、量化训练或导出验证时出现；纯推理部署、服务编排和线上压测不作为本次主题。

选型主线

大规模预训练优先评估 Megatron Core/Megatron-LM、DeepSpeed、TorchTitan、NeMo、Megatron Bridge、VeOmni、Nanotron 等底座；常规业务微调优先评估 LlamaFactory、Axolotl、ms-swift、TRL/PEFT/Accelerate、Unsloth、torch tune、XTuner；在线 RL 优先评估 verl、OpenRLHF、NeMo RL、AReal、slime；图像和视频生成训练应按模型族进入 Diffusers、sd-scripts、SimpleTuner、ai-toolkit、OneTrainer、musubi-tuner、diffusion-pipe、Open-Sora、Wan、HunyuanVideo 等生态。

分类框架

训练框架应按“任务层、编排层、控制层、分布式层、模型与数据层、运行依赖层”理解。项目名相近并不代表职责相同，模型仓库、训练脚本、分布式底座、后训练系统和推理引擎需要分开判断。

任务层

定义训练目标和评测口径，决定后续工具链的边界。

预训练 继续预训练 SFT LoRA / QLoRA DPO / KTO / ORPO
GRPO / PPO VLM Diffusion Video

训练编排层

组织模型、数据、loss、评测、导出和日志，决定实验是否可复现。

LlamaFactory Axolotl ms-swift TRL torchtune XTuner
Diffusers

RL 控制层

协调 actor、critic、reference、rollout、reward、工具环境和异步采样。

verl OpenRLHF NeMo RL AReal slime open-instruct

分布式与内核层

处理显存、并行、通信、checkpoint 和吞吐，上层框架通常建立在这一层之上。

Megatron DeepSpeed TorchTitan NeMo ColossalAI FSDP
FlashAttention Liger Kernel

模型与数据层

模型定义、adapter、tokenizer、dataset、reward data 和多模态 processor 决定训练是否对齐。

Transformers PEFT Datasets torchao Open Thoughts
ModelScope

运行依赖层

在线 RL、评测和导出验证会反复调用推理引擎和任务环境，这一层影响训练成本但不是本报告主体。

vLLM SGLang Ray torchrun checkpoint store
W&B / TensorBoard

训练框架的五类角色

角色	代表项目	主要解决的问题	不应期待它解决的问题
分布式底座	Megatron、DeepSpeed、TorchTitan、NeMo、ColossalAI、VeOmni、Nanotron	多维并行、显存优化、吞吐、容错、checkpoint 和大规模训练配方。	业务数据清洗、模板适配、端到端产品化微调体验。
微调工作台	LlamaFactory、Axolotl、ms-swift、TRL、Unsloth、torch tune、XTuner	统一数据格式、chat template、LoRA/QLoRA、偏好优化、评测和导出。	超大规模预训练的系统上限，复杂在线 RL 控制面。
RL 后训练系统	verl、OpenRLHF、NeMo RL、AReaL、slime	rollout、reward、environment、actor/reference/critic、异步调度和权重同步。	替代数据策略、自动保证 reward 可信、覆盖所有推理部署场景。
模型配方项目	LLaVA、InternVL、VILA、Qwen-VL、Open-Sora、Wan、HunyuanVideo、CogVideo	给出模型结构、训练 recipe、数据处理和评测参考。	成为跨模型族的通用训练平台。
训练组件	Transformers、PEFT、Accelerate、Diffusers、FlashAttention、Liger Kernel、torchao	提供模型定义、adapter、分布式启动、生成模型 pipeline、内核或量化能力。	单独承担完整工程项目的流程治理。

从零训练与分布式底座

从零训练的优先级是系统上限：并行策略能否覆盖模型形态，通信和显存是否可控，checkpoint 是否能稳定恢复，训练产物能否和主流模型生态互转。入口易用性重要，但不是首要指标。

主力底座项目

项目	核心能力	适合场景	边界与风险
Megatron-LM / Megatron Core	TP、PP、DP、EP、CP 等多维并行，面向大规模 Transformer、MoE 和 VLM 训练。	需要在 NVIDIA GPU 集群上训练十亿到千亿级模型，并愿意投入分布式训练工程能力。	抽象层级低，排错成本高；团队需要理解并行拓扑、通信重叠和 checkpoint 结构。
DeepSpeed	ZeRO、offload、MoE、pipeline 并行和大模型训练优化，常被上层框架调用。	多节点训练、显存受限训练、已有 PyTorch/HF 训练代码需要接入优化能力。	配置复杂度高；不同 ZeRO stage、offload 和并行组合需要逐项压测。
TorchTitan	PyTorch native 的预训练平台，围绕 FSDP2、DTensor、torch.compile 等官方抽象组织。	希望贴近 PyTorch 官方分布式路线，减少框架黑盒，并建立可读的预训练基线。	项目仍处在快速演进阶段，生产稳定性应按具体 recipe 验证。
NeMo / Megatron Bridge	NVIDIA 生态的 LLM、VLM、语音训练框架；Megatron Bridge 提供 Hugging Face 与 Megatron checkpoint 双向转换。	企业训练栈、NVIDIA 容器和 Megatron 生态深度绑定场景，尤其重视模型格式互操作。	生态依赖较重；非 NVIDIA 设备或非 Megatron 路线需评估迁移成本。
VeOmni	ByteDance Seed 开源的多模态训练框架，强调 model-centric distributed recipe。	单模态到多模态训练 recipe 需要统一组织，且希望保留训练逻辑透明度的团队。	新项目的长期稳定性、文档覆盖和社区案例仍需跟踪。
ColossalAI	低成本大模型训练、多种并行策略和研究复现生态。	教学、复现、成本敏感训练，以及部分视频生成项目关联的开源训练路线。	具体模型路径的维护状态差异较大，生产使用应以目标 recipe 为准。

研究型与轻量底座

Nanotron、LitGPT、LLM Foundry、GPT-NeoX、Lingua 等项目适合建立可读基线。它们未必是最大规模训练的首选，但在数据混合、tokenizer、学习率、checkpoint、评测和 loss 曲线验证阶段具有实际价值。大多数团队在进入大集群前，应先用轻量项目跑通闭环，再把已验证的训练配方迁移到底座型框架。

重型底座的触发条件

模型规模超过单机多卡舒适区，需要 MoE、长上下文、FP8、复杂并行、跨节点容错或严格 checkpoint 管理时，应优先进入 Megatron、DeepSpeed、NeMo、TorchTitan 这一层。

轻量底座的合理位置

团队尚未确认数据质量、tokenizer、训练超参和评测闭环时，Nanotron、LitGPT、LLM Foundry、Lingua 这类项目能更快暴露问题。

SFT、LoRA 与偏好优化

业务微调需要稳定入口。评估重点不只是支持多少算法，而是 tokenizer、chat template、loss mask、packing、VLM processor、adapter 合并、量化和导出验证能否形成一条可复现的训练链路。

常用工作台与组件

项目	强项	适合场景	使用边界
LlamaFactory	统一微调 LLM/VLM，CLI 与 Web UI 成熟，覆盖 SFT、LoRA、DPO、GRPO 等主流路径。	业务团队快速建立中文和通用模型微调流程。	复杂自定义训练逻辑会触及抽象边界，底层行为需要通过最小实验确认。
Axolotl	YAML 驱动，覆盖全参、LoRA/QLoRA、偏好优化、GRPO、奖励建模、多模态和多节点。	希望把训练配置长期沉淀成可审计资产的团队。	配置面广，前期需要建立字段规范和实验模板。
ms-swift	对 Qwen、InternVL、GLM、LLaVA 等中文和多模态生态适配积极，覆盖 CPT/SFT/DPO/GRPO。	主要模型来自 Qwen、ModelScope 或中文多模态生态的场景。	跨生态模型使用前仍需验证模板、processor 和导出兼容性。
TRL + PEFT + Accelerate	HF 原生组合，SFTTrainer、DPOTrainer、GRPOTrainer、RewardTrainer 等可编程性强。	有工程能力、需要精细控制训练逻辑和研究方法的团队。	自由度高，同时意味着数据 glue code、评测和导出治理要自行承担。
Unsloth	低显存、训练加速和本地化体验突出。	个人、小团队、预算敏感的 LoRA/QLoRA 微调。	复杂生产流水线、长期维护和多节点治理需额外评估。
torch tune	PyTorch native 后训练库，训练配方清晰，和 TorchTitan、torchao 路线衔接自然。	希望沿 PyTorch 官方栈建立后训练和量化流程。	生态覆盖不等同于工作台式开箱体验。
XTuner / open-instruct	分别贴近 InternLM/国产模型生态和公开后训练 recipe。	模型族适配、研究复现、开源配方学习。	通用业务生产入口需要按模型和数据格式逐项确认。

微调框架的四个核验点

模型适配要落到细节，README 中的支持列表不能替代 tokenizer、template、vision processor、multi-image collator、loss mask 和导出路径验证。VLM 与 MoE 尤其应先跑小样本。

数据链路要可解释，训练效果异常时，应能区分数据格式错误、assistant mask 错误、packing 影响、样本质量问题 和 评测集波动。无法解释数据流的工作台不适合进入生产闭环。

导出属于训练闭环，adapter 合并、量化、checkpoint 转换、推理一致性和 serving 兼容不应视为训练后的杂项工作。只能训练、不能稳定交付的工具价值有限。

偏好优化需要分层处理，DPO/KTO/ORPO 多数情况下仍可作为离线训练任务；GRPO/PPPO 如果引入在线采样、工具调用或程序化 reward，应转入第五章的 RL 系统评估。正式采用前，可使用同一份 1k 到 5k 样本在候选框架中分别跑最小 LoRA 或 QLoRA，记录显存、吞吐、loss 曲线、样本级 mask、导出后一致性和配置可读性。

RL 后训练系统

RL 后训练从算法问题转为系统问题。在线采样、奖励计算、工具环境、token 轨迹、异步调度、权重同步和可观测性共同决定训练是否可控，单看 PPO、GRPO 或 REINFORCE++ 的算法名不足以完成选型。

重点项目

项目	定位	适合场景	评估重点
verl	HybridFlow 路线的 RL post-training 框架，支持多训练后端和 vLLM/SGLang/HF rollout。	复杂 RL 数据流、多 worker、长链路 agent、高吞吐 rollout。	训练后端选择、rollout 引擎稳定性、权重同步开销、日志粒度。
OpenRLHF	Ray、vLLM、DeepSpeed 组合，覆盖 PPO、REINFORCE++、GRPO、RLOO、DPO/KTO 和 agentic RL。	希望快速搭建 RLHF/GRPO 集群的团队。	Ray 集群治理、reward service、数据生成和训练的资源隔离。
NeMo RL	NVIDIA NeMo 体系下的 RL 后训练库，面向 LLM/VLM reinforcement。	NVIDIA 生态、Megatron 后端、多模态 RL、企业 recipe 复现。	容器环境、Megatron/AutoModel 路线选择、与 NeMo Gym/Evaluator 的接口。
AReAL	连接 foundation model training 与 agent 应用的 RL infrastructure。	工具调用、交互环境、真实任务反馈驱动的 agent 后训练。	环境抽象、trajectory 记录、程序化 reward 和任务隔离。
slime	SGLang-native 的 RL scaling 后训练框架，结合 Megatron 与 SGLang。	关注 SGLang rollout、Megatron 训练和高性能 RL scaling 的团队。	Megatron/SGLang 版本耦合、数据生成接口、异步架构成熟度。
TRL / open-instruct	更轻量的后训练 trainer 与公开 recipe。	离线偏好优化、小规模 GRPO、公开方法复现。	规模边界、rollout 吞吐、工程治理能力。

RL 选型的工程问题

问题	为什么重要	核验方式
rollout 吞吐	在线 RL 的时间主要消耗在生成和打分，推理引擎不稳定会直接放大训练成本。	用目标模型、目标上下文长度和真实 prompt 分布压测 vLLM/SGLang/HF rollout。
reward 可信度	数学、代码、工具调用、多轮任务的 reward 形态不同，错误 reward 会稳定优化错误行为。	抽样审计 reward 分布，保留失败样本和边界样本，评估 reward hacking 风险。
异步与权重同步	异步提高吞吐，也引入 stale policy、版本追踪和调试复杂度。	记录 policy version、rollout version、训练 step 和评测输出的对应关系。
可观测性	RL 失败时 loss 不足以解释问题，需要 token 轨迹、KL、reward 分布、样本质量和环境状态。	在最小任务上先打通日志、样本回放和异常样本定位。

多模态训练

VLM/MLLM 训练不能简单视为文本 SFT 增加一个 image 字段。视觉 encoder、projector、image token、分辨率策略、多图或视频样本、processor 和评测集都会影响训练结果。

生态角色

项目或生态	角色	选型价值	边界
LLaVA / LLaVA-NeXT	视觉指令微调范式和公开基线。	理解 conversation template、图文数据格式和 VLM 评测的基础参照。	不等同于覆盖最新模型族的通用训练平台。
InternVL / Qwen-VL / VILA	高影响力多模态模型族。	决定 ms-swift、XTuner、LlamaFactory、Axolotl 等工具的 processor 和模板适配优先级。	模型仓库开放的训练范围、微调脚本和权重许可需要逐项确认。
MMEngine / MMPreTrain	传统视觉训练和预训练底座。	CV backbone、分类、检索、视觉预训练任务不必强行套 LLM 微调工具。	对 LLM 式对话模板和 VLM 指令微调不是天然入口。
VeOmni / NeMo / Megatron	从零训练多模态模型的分布式底座。	模型规模、模态组合和集群规模进入大训练区间时更有价值。	数据、模态对齐和评测设计仍需团队自行治理。
ms-swift / XTuner / LlamaFactory / Axolotl	多模态微调工作台。	业务 VLM 微调、中文模型生态适配、小规模验证。	多图、视频、长上下文和特定 processor 需要先做最小样本测试。

VLM 微调的最小测试集

十几条样本即可暴露主要问题：单图、多图和空图样本是否都能通过 collator；不同分辨率是否按预期缩放或切块；assistant mask 是否只训练回答；processor 输出是否和推理端一致；adapter 合并后是否能在目标 serving 框架中复现训练期输出。该测试应先于任何长周期微调。

路线建议

中文和通用 VLM 微调优先评估 ms-swift、XTuner、LlamaFactory、Axolotl；研究 LLaVA 范式时保留 LLaVA/LLaVA-NeXT 作为基线；NVIDIA 生态或从零训练 VLM 时回到 NeMo、Megatron、VeOmni 等底座。

图像与视频生成训练

生成模型训练应按模型族而非统一框架名选型。Diffusers 是组件和示例体系，sd-scripts、SimpleTuner、ai-toolkit、OneTrainer 更接近训练工作流；Open-Sora、Wan、HunyuanVideo、CogVideo、LTX-Video、Cosmos、SkyReels、Infinity 则更多体现模型结构、权重、训练报告和生态配方。

图像生成训练栈

项目	定位	适合场景	注意事项
Diffusers	图像、视频、音频扩散模型的 PyTorch 组件库和训练示例。	需要自定义 pipeline、scheduler、UNet/DiT、LoRA 或训练脚本的工程团队。	示例脚本强调可读和可改，生产化仍需自行补齐数据治理和实验管理。
sd-scripts	Stable Diffusion 及相关模型训练脚本生态。	SD/SDXL/SD3/Flux 周边 LoRA、DreamBooth、Textual Inversion 和社区训练。	版本、模型族和社区参数经验变化快，训练前应确认目标分支和文档。
SimpleTuner	面向 image/video/audio diffusion 的通用 fine-tuning kit。	希望统一管理多种扩散模型训练配置的研究或工程团队。	模型支持面广，具体数据格式和显存预算需要按模型族验证。
ai-toolkit	扩散模型 finetuning 工具箱。	Flux 等新图像模型的轻量训练和社区实验。	适合作为训练工具，不应替代系统级实验治理。
OneTrainer	面向 diffusion training 的一站式工具。	偏 GUI、配置化和工作流整合的训练用户。	复杂自定义研究训练仍需回到脚本和组件层。
Infinity	高分辨率图像生成的 autoregressive 模型项目。	观察图像生成路线从 diffusion 向其他建模方式扩展。	不是通用训练工具，更多作为模型方法和研究生态跟踪对象。

视频生成训练栈

项目	定位	适合场景	注意事项
Open-Sora	开源视频生成模型与训练栈，技术报告覆盖数据、架构、训练策略和系统优化。	研究完整视频训练链路和成本控制方法。	完整训练与 LoRA 微调是不同问题，资源预算差异很大。
Wan / HunyuanVideo	大规模视频生成模型项目，提供模型、权重、技术报告和生态接口。	视频生成模型研究、LoRA 生态、推理和二次训练路线评估。	需要分清官方开放的训练代码、推理代码、权重和第三方 tuner。
CogVideo / LTX-Video / Cosmos / SkyReels	视频生成模型族和关联生态。	比较视频生成模型结构、许可、推理成本和训练可获得性。	不要把模型热度直接等同于可训练性。
musubi-tuner / diffusion-pipe	视频 diffusion LoRA 和 pipeline parallel 训练工具。	Hunyuan、Wan、FramePack 等社区训练和显存受限微调。	适合微调或社区训练，不是从零训练视频基础模型的完整替代。
Open-Sora-Plan	Sora 风格 T2V 复现计划。	跟踪开放视频生成研究路线和训练配方。	项目定位偏复现和研究，生产选型需结合目标模型族重新评估。

生成模型训练的真实约束

图像和视频训练的瓶颈往往不在命令行参数，而在数据治理。caption 质量、镜头切分、帧率、时长、分辨率、运动幅度、重复样本、版权和安全过滤都会影响模型表现。训练框架可以降低实验门槛，但不能代替数据筛选和评测设计。

选型方法与边界

选型应从任务、规模、模型族、数据形态和交付物倒推，而不是从项目列表出发。下面的表格给出可执行的起步路线，并标出容易被忽略的验证项。

按任务选择入口

任务	优先评估	补充关注	关键验证项
从零训练 LLM/MoE	Megatron、NeMo、DeepSpeed、TorchTitan	VeOmni、ColossalAI、Nanotron	并行拓扑、checkpoint 恢复、吞吐、MFU、数据管线。
继续预训练	Megatron/DeepSpeed、Axolotl、ms-swift	LitGPT、LLM Foundry、Lingua、Nanotron	数据混合、学习率、tokenizer、评测漂移、模型格式转换。
业务 SFT/LoRA	LlamaFactory、Axolotl、ms-swift、Unsloth	TRL、PEFT、torch tune	chat template、loss mask、packing、adapter 合并、推理一致性。
偏好优化	TRL、LlamaFactory、ms-swift、Axolotl	open-instruct、NeMo	偏好数据质量、reference model、reward 分布、评测集稳定性。
GRPO/PPO/Agentic RL	verl、OpenRLHF、NeMo RL	AResL、slime、TRL	rollout 吞吐、reward service、环境接口、异步和权重同步。
VLM 微调	ms-swift、XTuner、LlamaFactory、Axolotl	LLaVA、InternVL、Qwen-VL、VILA	processor、collator、多图样本、分辨率策略、导出验证。
图像 LoRA / diffusion 微调	Diffusers、sd-scripts、SimpleTuner、ai-toolkit	OneTrainer、模型官方脚本	模型族、caption、VAE/DiT/text encoder、显存预算。
视频 LoRA / 视频研究	Open-Sora、musubi-tuner、diffusion-pipe	Wan、HunyuanVideo、CogVideo、LTX、SkyReels、Cosmos	完整训练与微调边界、帧率、时长、镜头切分、训练开放范围。

正式采用前的检查清单

维度	需要确认	不满足时的处理
训练目标	预训练、继续预训练、SFT、偏好优化、在线 RL、VLM 或生成模型训练是否已明确。	先缩小任务边界，避免把微调工作台当预训练底座使用。
模型族	目标模型的 tokenizer、processor、checkpoint 格式、许可和官方推荐工具链。	优先跑官方最小 recipe，再迁移到统一工作台。
数据形态	文本、偏好对、程序化 reward、多图样本、视频片段、caption 和安全过滤是否可追溯。	先建立数据审计样本，而不是直接延长训练。
系统规模	单卡、单机多卡、多节点、MoE、长上下文、FP8、pipeline 和容错要求。	规模不足时使用轻量工作台；规模上升后回到底座层。
交付链路	adapter 合并、量化、导出、推理一致性、评测和 serving 兼容是否可复现。	把导出验证纳入训练脚本，不作为训练后的人工步骤。
许可证与维护	训练代码、权重、数据和依赖项目的 license 是否允许目标用途。	涉及 AGPL、未声明 license 或模型权重限制时先完成合规评估。

资料口径与限制

本报告优先依据项目官方仓库、官方文档、论文页面和技术报告建立判断。仓库公开元数据用于识别项目状态和生态关注度，不作为质量排序依据；能力描述以官方文档和可复现实验路径为准。项目更新速度较快，正式落地前仍应复核目标版本、目标模型族和目标硬件环境。