

电商图搜 · Reasoning-then-Embed 论文读单 2026

按“电商图搜直接相关 -> 通用推理表征可迁移 -> 组合修改意图 (CIR) -> 低延迟前沿”四层编排的精读读单。对象不是泛化的多模态召回文献集合, 而是 先推理、后表征 这一技术路线在商品理解、非对称图搜、工业召回与重排、组合检索及 latent 加速上的代表性工作。

范围: 15 篇核心工作, 覆盖工业电商图搜、Reasoner->Embedder 训练范式、Composed Image Retrieval, 以及将长文本 CoT 压缩为固定计算预算的 latent think 方法。

读法: 先建立四层结构, 再按任务场景选取 3-5 篇精读。2026 年条目多数仍为 arXiv 预印本; 正文以方法与公开实验为据, 不将其默认等同于正式录用结论。

AS OF

证据日期: 2026-07-13

AXIS

Reasoning-then-Embed /
电商图搜 / CIR / 低延迟

COUNT

15 篇核心 · 4 个阅读层 ·
含工业 A/B 报告

SCOPE

图搜、同款、属性推理、组合
修改意图、服务延迟

作者: Winston

版本: 2026-07-13

证据边界: 文中收益与线上数字均按论文作者公开报告整理; 预印本以 arXiv 公开版本为准, 不默认等同正式录用结论。

| 目录

01	使用说明与阅读边界	02	分层地图与优先序
03	一、直接面向电商图搜：优先精读	04	二、“先推理后表征”通用方法
05	三、找相似+修改意图：CIR	06	四、低延迟前沿探索
07	场景选型与连读路径	08	来源与证据边界

01 · 使用说明与阅读边界

本读单沿一条方法主线组织：检索模型是否先将任务相关结构显式化，再将其压缩为可检索向量。在电商图搜中，该主线对应属性推理、目标区域定位、意图挖掘、组合修改意图，以及固定延迟预算下的可部署性。

关注点

方法上，推理如何进入表征；数据上，商品属性、难负样本与修改文本；系统上，召回、重排、策略路由与延迟预算。

边界

通用 benchmark 的领先结果不能直接外推为可上线的图搜方案；论文作者报告的 GMV 或 CTR 亦不构成独立审计结论。

场景入口

同款 / 近同款：P01-P03；困难 Query 自适应：P07、P11；属性修改意图：P12-P13；高 QPS 约束：P14-P15。

预印本与证据分层

清单中 2026 年工作多数仍为 arXiv 预印本，正文仅将其视为方法与公开实验信号；录用状态、线上收益与跨平台可迁移性分开表述。REVISION 为 WSDM 2026 Full Paper，其余以 arXiv 公开版本为准。

02 · 分层地图与优先序

I · 电商图搜

MOON3.0 / TIGER-FG
Pailitao / TGQ /
REVISION
优先精读 P01-P06

II · 推理->表征

Think Then Embed
UME / Embed-RL /
MMEmb
自适应路由见 Think
When Needed

III · CIR

CIR-CoT · MCoT-MVS
参考图 + 修改文本
相似检索下的属性修改

IV · 低延迟

TTE-Flash · LaME
latent think tokens
固定预算一次前向

系统落点

Query 侧属性或意图推理 -> 256 维或 MRL 向量 -> ANN 召回 -> listwise 重排；仅对困难 Query 启用显式 CoT。工业主干可参考 Pailitao-VL 的 ID 原型 embedding 与 compare-and-calibrate reranker。中长期蒸馏目标是将 MOON3.0 一类推理能力压缩至 LaME / TTE-Flash 形态的低延迟 Query Tower。

#	工作	层	一句话	arXiv / 状态
01	MOON3.0	电商图搜	结构化属性推理后形成统一商品向量	2604.00513
02	TIGER-FG	电商图搜	文本引导隐式细粒度 grounding，处理裁剪图与全图非对称	2605.18434
03	Pailitao-VL	电商图搜	工业统一 embedding + listwise reranker	2602.13704
04	MOON / MOON2.0	电商图搜	生成式表征到推理式表征的演进基础	系列演进
05	TGQ-Former	电商图搜	标题、类目与元数据引导视觉 token，抑制噪声	2605.17366
06	REVISION	电商图搜	无点击意图挖掘与线上策略路由	2510.22739 · WSDM 2026
07	Think Then Embed	通用 RTE	Reasoner 生成检索导向 reasoning 后再编码	2510.05014

#	工作	层	一句话	arXiv / 状态
08	UME-R1	通用 RTE	discriminative 与 generative embedding 双通道	2511.00405
09	Embed-RL	通用 RTE	Embedder 指导 RL, 约束推理指向检索证据	2602.13823
10	MMEmb-R1	通用 RTE	pair-aware 选择: 仅在改善正负间隔时启用 reasoning	2604.06156
11	Think When Needed	通用 RTE	路由门控: 常规样本直出, 困难样本再推理	2605.14448
12	CIR-CoT	CIR	Caption->Reasoning->Conclusion->embedding	2510.08003
13	MCoT-MVS	CIR	推理线索反向选择视觉 patch/instance	2603.17360
14	TTE-Flash	低延迟	以 latent think tokens 替代长文本 CoT	2605.16638
15	LaME	低延迟	固定数量 reason tokens 构成 latent 信息瓶颈	2606.13061

03 · 一、直接面向电商图搜：优先精读

本层直接对应生产图搜：商品多图文、裁剪 Query、复杂背景、同款与近同款、召回后重排及无点击闭环。建议并行阅读 MOON 演进线与工业系统线。

01

MOON3.0: Reasoning-aware Multimodal Representation Learning for E-commerce Product Understanding

精读

arXiv: 2604.00513 · 电商商品统一表征 · 先推理、后表征

- 思路
- 先推理、后表征：由商品图像与标题生成类别、颜色、材质、设计元素等结构化属性，再经 <emb> 表征、原始图文多头融合与 FIRE 细粒度残差增强，输出 256 维向量。
- 收益
- 相对 MOON2.0, MBE3.0 上 Image->MM R@10 由 50.41 升至 56.39, Text->MM 由 35.33 升至 48.10; 分类准确率由 67.27 升至 86.40, 属性准确率由 36.36 升至 49.92。
- 模态
- 图片->图文商品、文本->图文商品、图文->图文、文搜图、图搜文本。
- 阅读价值
- 与“电商商品多模态统一表征 + 推理召回”问题设定最为接近的代表工作。

02

TIGER-FG: Text-Guided Implicit Fine-Grained Grounding for E-commerce Retrieval

精读

arXiv: 2605.18434 · 裁剪 Query 非对称 · 隐式目标定位

- 思路
- 针对裁剪商品 Query 图与“完整商品图 + 文本”之间的模态与粒度非对称，以商品文本引导候选图像完成隐式目标定位，无需额外检测框；再以空间一致性与相似度结构双重蒸馏强化细粒度匹配。
- 收益
- 在标准与复杂背景测试集上，相对最强基线 Recall@1 分别提升 6.1 与 34.4 个百分点；Query 侧参数量 85.7M, 输出 256 维向量。
- 模态
- 裁剪图片 Query -> 完整商品图片 + 标题 / 属性。
- 阅读价值
- 对拍照图、子图、复杂背景与多商品干扰等非对称图搜设定具有直接针对性。

03

Pailitao-VL: Unified Embedding and Reranker for Real-Time Multi-Modal Industrial Search

工业

arXiv: 2602.13704 · 阿里拍立淘 · 召回 + 重排 + 实时部署

- 思路
- 阿里拍立淘工业系统。Embedding 由相对式对比学习转为超大规模 Absolute ID Recognition, 使高纯度商品实例对应稳定的全局语义原型；Reranker 由 pointwise 判定转为 chunk 内比较与跨 chunk 绝对分数校准。
- 收益
- 公开线上 A/B 中，部分 AI 搜索场景作者报告约 20% GMV 增长；Embedding 与 listwise reranker 平均延迟分别约为 67 ms 与 76 ms。
- 模态
- 多模态商品召回、同款 / 近同款检索、召回后高精度重排。
- 阅读价值
- 覆盖召回、重排、线上 A/B 与实时部署闭环的完整工业参考。

04 MOON / MOON2.0: MOON3.0 的基础演进路线

演进

系列演进 · 建议按 MOON -> MOON2.0 -> MOON3.0 顺序阅读

MOON	以生成式 MLLM 学习商品统一表征，引入 guided MoE、核心视觉区域识别与电商难负样本策略，处理商品多图、多文本的 many-to-one 对齐。
2.0	针对图文训练中的模态不平衡、商品内部图文关系利用不足及电商噪声作进一步约束与建模。
模态	商品多图 + 标题 / 属性；支持跨模态检索、分类与属性预测。
阅读价值	连读 MOON 至 MOON3.0，可系统把握从生成式商品表征到推理式商品表征的演进逻辑。

工业报告 · MOON Embedding

MOON Embedding 技术报告称，该系列已部署于淘宝搜索广告的召回、相关性与排序阶段，并报告整体 CTR 预测累计提升约 20%。该数字为系列多次迭代的系统收益，不可单独归因于 MOON3.0 或某一召回模型。报告入口：[MOON Embedding Technical Report \(arXiv: 2511.11305\)](#)。

05 Text-Guided Visual Representation Learning for Robust Multimodal E-Commerce Recommendation

抗噪

arXiv: 2605.17366 · TGQ-Former · 元数据引导视觉 token

思路	提出 TGQ-Former：以商品标题、类目与结构化元数据引导视觉 token 选择；保留 metadata-guided 与 exploratory 两路视觉 query，并以可靠性双门控抑制促销文字、背景与装饰噪声。
收益	在大规模全库商品检索中，平均 Hit Rate@100 提升 6.04%。
模态	商品图片 + 标题 / 类目 / 属性 -> 商品 I2I 或多模态召回。
阅读价值	针对商详海报、促销角标、复杂背景与主体不突出等线上视觉噪声具有明确针对性。

06 REVISION: Reflective Intent Mining and Online Reasoning Auxiliary for E-commerce Visual Search System Optimization

系统

arXiv: 2510.22739 · WSDM 2026 Full Paper · 无点击闭环

思路	针对图搜无点击请求：离线从历史 Query 图、浏览商品与行为日志挖掘用户隐式意图；线上由轻量推理模型生成优化计划，并动态调度检索链路中的策略模块。
收益	作者报告可提高隐式意图挖掘效率并显著降低无点击率；摘要未给出统一量化百分比。
模态	Query 图片 + 历史商品 + 用户行为；重心在系统策略层，而非单一 embedding 模型。
阅读价值	适用于图搜场景识别、兜底通道、策略路由与无点击闭环的系统设计讨论。

04 · 二、“先推理后表征”通用方法：重点迁移

本层给出可迁移的 Reasoner->Embedder 训练与推理范式。对电商图搜而言，关键不在通用 benchmark 名次，而在 CoT 是否服务于正负样本区分、何时启用推理，以及如何控制延迟。

07 Think Then Embed: Generative Context Improves Multimodal Embedding

基线

arXiv: 2510.05014 · Reasoner + Embedder · MMEB-V2

- 思路** Reasoner 先生成与检索任务相关的 Embedding-Centric Reasoning, Embedder 再联合原始输入与 reasoning 生成向量；并比较“大 Reasoner + 小 Embedder”、Reasoner 蒸馏与统一模型等配置。
- 收益** 在 MMEB-V2 上报告当时领先结果；显式 reasoning 对复杂多模态约束与组合意图更为有效。
- 模态** 图片、文本、视频、视觉文档及图文组合 Query。
- 迁移** 可作为除 MOON3.0 外的标准 Reasoner->Embedder 对照基线。

08 UME-R1: Exploring Reasoning-Driven Generative Multimodal Embeddings

双通道

arXiv: 2511.00405 · discriminative + generative embedding

- 思路** 同一模型并行输出 discriminative embedding 与经 reasoning 得到的 generative embedding；训练采用 Cold-start SFT + RL，并考察多次采样生成多组 reasoning / embedding。
- 收益** 相对同数据规模的 DUME，图像、视频与视觉文档任务总分分别提升 4.1、9.0 与 11.1；相对 VLM2Vec-V2 总体提升 2.1。
- 模态** 图像、视频、视觉文档、图文组合检索。
- 迁移** 可用于图搜中“直接向量 + 推理向量”双通道召回及 inference-time sampling 设计。

09 Embed-RL: Reinforcement Learning for Reasoning-Driven Multimodal Embeddings

RL

arXiv: 2602.13823 · Embedder-Guided RL · T-CoT

- 思路** 提出 Embedder-Guided RL：由 Embedder 直接评估 Reasoner 生成的 CoT 是否利于检索；T-CoT 要求推理指明图像与文本中的具体检索证据，而非仅生成泛化说明。
- 收益** 在 MMEB-V2 与 UVRB 上优于文中对照的早期 reasoning embedding 模型，主要提升跨模态一致性与细粒度匹配。
- 模态** 图片 / 图文 Query -> 图片、文本或多模态候选。
- 迁移** 可用于商品属性 reasoning 训练，使推理内容直接服务于正负样本区分。

10 MMEmb-R1: Reasoning-Enhanced Multimodal Embedding with Pair-Aware Selection and Adaptive Control

难负

arXiv: 2604.06156 · pair-level 监督对齐 · 自适应启用 reasoning

- 思路** 指出常规 CoT 监督为 instance-level，而对比学习为 query-target pair-level，二者存在监督错位；通过 pair-aware reasoning selection、反事实比较与自适应控制，仅在 reasoning 能改善正负间隔时启用。
- 收益** 作者报告在提高检索准确率的同时，相对 UME-R1 获得约 2.5x 推理延迟改善。
- 模态** 通用图片、文本、视频、视觉文档检索。
- 迁移** 适用于电商难负样本训练，抑制仅学到格式、类目等无判别信息的空转 reasoning。

11 Think When Needed: Adaptive Reasoning-Driven Multimodal Embeddings

生产

arXiv:2605.14448 · Routing Gate · Reasoning LoRA + Embedding LoRA

思路	共享冻结的 MLLM backbone，分别挂载 Reasoning LoRA 与 Embedding LoRA；Routing Gate 判定当前样本直接编码或先生成 CoT，并以固定 Embedder 作为稳定 RL reward 环境。
收益	在 MMEB-V2 的 78 个任务上报告领先结果；相对 backbone 约增加 3%-5% 参数，reasoning token 最多减少 50%。
模态	通用多模态召回。
迁移	贴近图搜在线约束：常规商品图直接编码，截图、复杂背景与组合约束等困难 Query 再启用推理。

05 · 三、找相似+修改意图: 重点关注 CIR

Composed Image Retrieval 对应“保持版型, 将红色改为黑色”“保留鞋型, 去除图案”等条件检索。此时推理的任务不是事后解释, 而是显式决定应保留、应删除与应新增的视觉语义。

12 CIR-CoT: Towards Interpretable Composed Image Retrieval via End-to-End Chain-of-Thought Reasoning

CIR

arXiv: 2510.08003 · FashionIQ / CIRR / CIRCO

- 思路 输入参考图片与修改文本, 依次生成 Caption、Reasoning、Conclusion, 再将目标检索意图压缩为专用 embedding。
- 收益 在 FashionIQ、CIRR 上取得有竞争力的结果, 并在未参与训练的 CIRCO 上表现较好泛化。
- 模态 参考图片 + 修改文本 -> 目标图片。
- 场景 “保持版型, 将红色改为黑色”“保留鞋型, 去除图案”。

13 MCoT-MVS: Multi-level Vision Selection by Multi-modal CoT Reasoning for Composed Image Retrieval

SOTA

arXiv: 2603.17360 · 视觉区域选择受 reasoning 控制 · 公开代码与模型

- 思路 MLLM 先输出“应保留、应删除、应新增”的文本线索, 据此选择参考图中的 patch-level 与 instance-level 视觉特征, 再融合修改文本与目标描述。
- 收益 作者在 CIRR 与 FashionIQ 上报告新的 SOTA, 并公开代码与模型。
- 模态 参考图 + 商品修改描述 -> 目标商品图。
- 迁移 相较将 CoT 文本直接拼入 embedding, 其 reasoning 可反向控制视觉区域选择, 结构性更强。

06 · 四、低延迟前沿探索

显式文本 CoT 可提升检索准确率，但在高 QPS 图搜中计算代价过高。本层讨论将推理移入 latent space：固定 token 预算、单次前向，以及可蒸馏的 Query Tower。

14

TTE-Flash: Accelerating Reasoning-based Multimodal Representations via Think-Then-Embed Tokens

加速

arXiv: 2605.16638 · latent think tokens · 可解释

- 思路
- 不以自回归方式生成长文本 CoT，而在同一 backbone 中使用 latent think tokens，再由 embedding token 汇总。
- 收益
- TTE-Flash-2B 在 MMEB-V2 上超过其显式 CoT 对照模型；latent token 仍可通过文本与视觉途径解释。
- 模态
- 通用图片、文本、视频及视觉文档。
- 探索价值
- 面向高 QPS 图搜，将数十步文本 decode 压缩为固定 token 的一次前向传播。

15

LaME: Learning to Think in Latent Space for Multimodal Embedding

蒸馏

arXiv: 2606.13061 · 信息瓶颈 · 无需 CoT 文本标签

- 思路
- 以固定数量的 learnable reason tokens 作为信息瓶颈，在 latent space 完成 reasoning；无需 CoT 文本标签，亦无需自回归生成。
- 收益
- 主要优势为单次 forward、固定计算预算，并降低 embedding 对教师 CoT 质量的依赖。
- 模态
- 通用多模态 embedding。
- 探索价值
- 可作为将 MOON3.0 类推理能力蒸馏至低延迟 Query Tower 的长期研究路径。

07 · 场景选型与连读路径

按职责选取 3 篇

- 图搜算法负责人: P01 MOON3.0、P02 TIGER-FG、P03 Pailitao-VL
- 训练与后训练: P07 Think Then Embed、P09 Embed-RL、P10 MMEmb-R1
- 在线系统: P03 Pailitao-VL、P06 REVISION、P11 Think When Needed
- 服饰改款与组合意图: P12 CIR-CoT、P13 MCoT-MVS、P01 属性推理
- 延迟与成本: P11 自适应路由、P14 TTE-Flash、P15 LaME

建议连读路径

- 演进线: MOON -> MOON2.0 -> MOON3.0 -> MOON Embedding 技术报告
- 非对称图搜: TIGER-FG -> TGQ-Former -> Think When Needed
- 工业闭环: Pailitao-VL -> REVISION -> 延迟侧 TTE-Flash / LaME
- 推理训练: Think Then Embed -> Embed-RL -> MMEmb-R1 -> UME-R1
- 修改意图: CIR-CoT -> MCoT-MVS

问题设定	优先阅读	可迁移要点	常见误用
属性细粒度不足，同款混类	P01, P04, P09	结构化属性推理 + 难负样本上的证据型 CoT	无验真地生成 CoT 并直接拼入 embedding
裁剪图 / 拍照图 / 复杂背景召回不足	P02, P05, P11	文本引导 grounding + 抗噪视觉 token + 困难 Query 路由	对全部流量启用大模型长推理，不做常规样本直出
需召回、重排与线上可观测闭环	P03, P06	原型 ID embedding + listwise 校准 + 无点击策略闭环	仅复制离线 R@K，忽略延迟与分场景 A/B
相似检索下的属性修改意图	P12, P13, P01	修改意图 CoT + 视觉区域选择 + 属性结构	将普通 I2I 相似度检索当作 CIR
推理有效但服务 QPS 不足	P11, P14, P15	自适应启用推理；以 latent think 固定预算蒸馏 Query Tower	对全量 Query 做自回归长 CoT

系统组合参考

主干采用可预计算 item embedding、ANN 召回与 listwise 重排 (P03)。Item 侧吸收属性推理与抗噪 (P01 / P05)。Query 侧默认直接编码，困难样本再启用推理 (P11)；中长期以 latent think 蒸馏 (P14 / P15)。裁剪与复杂背景走细粒度 grounding 通道 (P02)。无点击与策略路由独立为系统层 (P06)。CIR 作为修改意图入口，不与同款召回混用 (P12 / P13)。

08 · 来源与证据边界

本读单依据作者公开材料整理方法要点、报告收益与适用模式。线上 GMV、CTR、延迟等数字均为作者报告，不构成独立审计；预印本工作以方法与公开实验为主，不默认等同正式录用结论。下列条目中的 arXiv 编号可直接点击访问。

三类信号宜分开引用

- 离线指标：MBE3.0、MMEB-V2、FashionIQ、CIRR、Recall@1 / H@100 等，用于方法比较，不能单独证明线上可交易性与可部署性。
- 工业 A/B：如 Pailitao-VL 部分场景 GMV、MOON Embedding 全链路 CTR，属于有价值的产业信号；跨平台迁移须对照数据治理、品类结构与延迟预算。
- 系统层收益：如 REVISION 报告的无点击率下降，属于链路策略结果，不宜直接表述为 embedding 模型增益。

引用索引

1. P01 Wu et al., [MOON3.0: Reasoning-aware Multimodal Representation Learning for E-commerce Product Understanding](#). [arXiv:2604.00513](#).
2. P02 Sun et al., [TIGER-FG: Text-Guided Implicit Fine-Grained Grounding for E-commerce Retrieval](#). [arXiv:2605.18434](#).
3. P03 Chen et al., [Pailitao-VL: Unified Embedding and Reranker for Real-Time Multi-Modal Industrial Search](#). [arXiv:2602.13704](#).
4. P04 MOON / MOON2.0 系列：作为 MOON3.0 演进底座阅读；工业部署与 CTR 系统收益见 [MOON Embedding Technical Report](#) ([arXiv:2511.11305](#))，该 CTR 数字为系列累计收益，不可单独归因于 MOON3.0。
5. P05 Guo et al., [Text-Guided Visual Representation Learning for Robust Multimodal E-Commerce Recommendation](#). [arXiv:2605.17366](#).
6. P06 REVISION: Reflective Intent Mining and Online Reasoning Auxiliary for E-commerce Visual Search System Optimization. [arXiv:2510.22739](#). WSDM 2026 Full Paper.
7. P07 Think Then Embed: Generative Context Improves Multimodal Embedding. [arXiv:2510.05014](#).
8. P08 UME-R1: Exploring Reasoning-Driven Generative Multimodal Embeddings. [arXiv:2511.00405](#).
9. P09 Embed-RL: Reinforcement Learning for Reasoning-Driven Multimodal Embeddings. [arXiv:2602.13823](#).
10. P10 MMEB-R1: Reasoning-Enhanced Multimodal Embedding with Pair-Aware Selection and Adaptive Control. [arXiv:2604.06156](#).
11. P11 Think When Needed: Adaptive Reasoning-Driven Multimodal Embeddings. [arXiv:2605.14448](#).
12. P12 CIR-CoT: Towards Interpretable Composed Image Retrieval via End-to-End Chain-of-Thought Reasoning. [arXiv:2510.08003](#).
13. P13 MCoT-MVS: Multi-level Vision Selection by Multi-modal CoT Reasoning for Composed Image Retrieval. [arXiv:2603.17360](#).
14. P14 TTE-Flash: Accelerating Reasoning-based Multimodal Representations via Think-Then-Embed Tokens. [arXiv:2605.16638](#).
15. P15 LaME: Learning to Think in Latent Space for Multimodal Embedding. [arXiv:2606.13061](#).