

电商图搜 · Reasoning-then-Embed 论文读单 2026

一份按“电商图搜直接相关 -> 通用推理表征可迁移 -> 找相似+修改意图 -> 低延迟前沿”排序的精读清单。主线不是再堆一批多模态召回论文，而是把 先推理、后表征 这条路线在商品理解、图搜非对称匹配、工业召回重排、CIR 与 latent 加速上的关键工作串成可读地图。

读单定位：15 篇核心工作，覆盖工业电商图搜、Reasoner->Embedder 通用范式、Composed Image Retrieval，以及把长 CoT 压成固定预算的 latent think。

使用方式：先按四段分层建立地图，再按场景挑 3-5 篇精读。2026 年新作多数仍是 arXiv 预印本；重点看方法与公开实验，不默认视为已正式录用。

AS OF

证据日期：2026-07-13

AXIS

Reasoning-then-Embed /
电商图搜 / CIR / 低延迟

COUNT

15 篇核心 · 4 个阅读层 ·
含工业 A/B 信号

SCOPE

图搜、同款、属性推理、组合
修改意图、生产延迟

作者：Winston

版本：2026-07-13

证据边界：文中收益与线上数字均按论文作者公开报告整理；预印本以 arXiv 公开版本为准，不默认等同正式录用结论。

| 目录

01	怎么用这份读单	02	总览地图与优先序
03	一、直接面向电商图搜：优先精读	04	二、“先推理后表征”通用方法
05	三、找相似+修改意图：CIR	06	四、低延迟前沿探索
07	场景选型与阅读路径	08	来源与证据边界

01 · 怎么用这份读单

这不是“最新多模态论文合集”，而是围绕一条方法主线的读单：模型是否先把任务相关结构显式化，再把结果压成可检索向量。电商图搜里，这条主线对应属性推理、区域定位、意图挖掘、组合修改意图，以及能否在固定延迟预算内完成。

读什么

方法：推理如何进入表征；数据：商品属性、难负样本、修改文本；系统：召回、重排、策略路由、延迟预算。

不读什么

不把通用 benchmark 第一名直接当作可上线图搜方案；不把作者报告的 GMV/CTR 写成独立审计结论。

怎么挑

做同款/近同款：P01-P03；做难 Query 自适应：P07/P11；做改颜色/改材质：P12-P13；做高 QPS：P14-P15。

预印本纪律

2026 年清单中多数工作仍是 arXiv 预印本。正文把它们当作方法与公开实验信号；录用状态、线上收益和跨平台可迁移性分开表述。REVISION 为 WSDM 2026 Full Paper，其余以 arXiv 为准。

02 · 总览地图与优先序

I · 电商图搜

MOON3.0 / TIGER-FG
Pailitao / TGQ /
REVISION
优先精读 P01-P06

II · 推理->表征

Think Then Embed
UME / Embed-RL /
MMEmb
自适应 Think When
Needed

III · CIR

CIR-CoT · MCoT-MVS
参考图 + 修改文本
找相似且改属性 · CIR

IV · 低延迟

TTE-Flash · LaME
latent think tokens
固定预算一次前向

生产链路落点

Query 推理 / 属性结构化 -> 256 维或 MRL 向量 -> ANN 召回 -> listwise 重排 -> 难 Query 才开 CoT。工业主干参考 Pailitao-VL 的 ID 原型 embedding + compare-and-calibrate reranker；推理能力蒸馏目标：MOON3.0 -> LaME / TTE-Flash Query Tower。

#	工作	层	一句话	arXiv / 状态
01	MOON3.0	电商图搜	先结构化属性推理，再得到统一商品向量	2604.00513
02	TIGER-FG	电商图搜	文本引导隐式细粒度 grounding，解决裁剪图非对称	2605.18434
03	Pailitao-VL	电商图搜	工业统一 embedding + listwise reranker	2602.13704
04	MOON / MOON2.0	电商图搜	MOON3.0 的生成式->推理式演进底座	系列演进
05	TGQ-Former	电商图搜	标题/类目/元数据引导视觉 token 抗噪	2605.17366
06	REVISION	电商图搜	无点击意图挖掘与线上策略路由	2510.22739 · WSDM 2026
07	Think Then Embed	通用 RTE	Reasoner 生成 embedding-centric reasoning 再编码	2510.05014

#	工作	层	一句话	arXiv / 状态
08	UME-R1	通用 RTE	直接 embedding 与生成式 embedding 双通道	2511.00405
09	Embed-RL	通用 RTE	Embedder 指导 RL, 强制指向检索证据	2602.13823
10	MMEmb-R1	通用 RTE	pair-aware 选择, 只有在有收益时用 reasoning	2604.06156
11	Think When Needed	通用 RTE	路由门控: 干净样本直出, 难样本再推理	2605.14448
12	CIR-CoT	CIR	Caption->Reasoning->Conclusion->embedding	2510.08003
13	MCoT-MVS	CIR	推理线索反向选择视觉 patch/instance	2603.17360
14	TTE-Flash	低延迟	latent think tokens 替代长文本 CoT	2605.16638
15	LaME	低延迟	固定 reason tokens 的 latent 信息瓶颈	2606.13061

03 · 一、直接面向电商图搜：优先精读

这一层最贴近生产图搜：商品多图文、裁剪 Query、复杂背景、同款近同款、召回后重排、无点击闭环。建议按 MOON 演进线 + 工业系统线两条并行读。

01 MOON3.0: Reasoning-aware Multimodal Representation Learning for E-commerce Product Understanding

精读

arXiv: 2604.00513 · 电商商品统一表征 · 先推理、后表征

- 思路
- 典型“先推理、后表征”。先从商品图像和标题生成类别、颜色、材质、设计元素等结构化属性，再通过 <emb> 表征、原始图文多头融合和 FIRE 细粒度残差增强，得到 256 维向量。
- 收益
- 相较 MOON2.0, MBE3.0 上 Image->MM R@10 从 50.41 提升至 56.39, Text->MM 从 35.33 提升至 48.10；分类准确率从 67.27 提升至 86.40，属性准确率从 36.36 提升至 49.92。
- 模态
- 图片->图文商品、文本->图文商品、图文->图文、文搜图、图搜文本。
- 推荐
- 当前最贴近“电商商品多模态统一表征 + 推理召回”的工作。

02 TIGER-FG: Text-Guided Implicit Fine-Grained Grounding for E-commerce Retrieval

精读

arXiv: 2605.18434 · 裁剪 Query 非对称 · 隐式目标定位

- 思路
- 针对“裁剪商品 Query 图 vs 带背景的完整商品图 + 文本”这一真实图搜非对称问题，用商品文本引导候选图像进行隐式目标定位，无需额外检测框；再通过空间一致性和相似度结构双重蒸馏强化细粒度匹配。
- 收益
- 在标准和复杂背景测试集上，相对最强基线 Recall@1 分别提升 6.1 和 34.4 个百分点；Query 侧仅 85.7M 参数，输出 256 维向量。
- 模态
- 裁剪图片 Query -> 完整商品图片 + 标题 / 属性。
- 推荐
- 对拍照图、子图、复杂背景、多商品干扰等电商图搜问题最直接。

03 Pailitao-VL: Unified Embedding and Reranker for Real-Time Multi-Modal Industrial Search

工业

arXiv: 2602.13704 · 阿里拍立淘 · 召回 + 重排 + 实时部署

- 思路
- 阿里拍立淘工业系统。Embedding 从相对式对比学习转为超大规模 Absolute ID Recognition，让每个高纯商品实例对应稳定的全局语义原型；Reranker 从 pointwise 判断转为 chunk 内比较与跨 chunk 绝对分数校准。
- 收益
- 公开线上 A/B 中，部分 AI 搜索场景报告约 20% GMV 增长；Embedding 与 listwise reranker 平均延迟分别压至约 67 ms 和 76 ms。
- 模态
- 多模态商品召回、同款 / 近同款检索、召回后高精度重排。
- 推荐
- 最值得参考的完整“召回 + 重排 + 线上 A/B + 实时部署”工业方案。

04 MOON / MOON2.0: MOON3.0 的基础演进路线

演进

系列演进 · 建议 MOON -> MOON2.0 -> MOON3.0 连读

MOON	使用生成式 MLLM 学习商品统一表征，引入 guided MoE、核心视觉区域识别及电商难负样本策略，解决商品多图、多文本的 many-to-one 对齐问题。
2.0	进一步解决图文训练中的模态不平衡、商品内部图文关系利用不足以及电商噪声问题。
模态	商品多图 + 标题 / 属性，支持跨模态检索、分类和属性预测。
推荐	按 MOON -> MOON2.0 -> MOON3.0 阅读，可完整理解阿里从生成式商品表征到推理式商品表征的演进。

工业报告补充 · MOON Embedding

MOON Embedding 工业报告称，该系列已部署于淘宝搜索广告的召回、相关性和排序阶段，并报告整体 CTR 预测累计提升约 20%。该数字是 MOON 系列多次迭代的系统收益，不能单独归因于 MOON3.0 或某个召回模型。入口：[MOON Embedding Technical Report \(arXiv: 2511.11305\)](#)。

05 Text-Guided Visual Representation Learning for Robust Multimodal E-Commerce Recommendation

抗噪

arXiv: 2605.17366 · TGQ-Former · 元数据引导视觉 token

思路	提出 TGQ-Former，用商品标题、类目和结构化元数据引导视觉 token 选择；同时保留 metadata-guided 与 exploratory 两路视觉 query，并利用可靠性双门控抑制促销文字、背景和装饰噪声。
收益	在真实大规模全库商品检索中，平均 Hit Rate@100 提升 6.04%。
模态	商品图片 + 标题 / 类目 / 属性 -> 商品 I2I 或多模态召回。
推荐	非常适合解决商详海报、促销角标、背景复杂、商品主体不突出等线上噪声问题。

06 REVISION: Reflective Intent Mining and Online Reasoning Auxiliary for E-commerce Visual Search System Optimization

系统

arXiv: 2510.22739 · WSDM 2026 Full Paper · 无点击闭环

思路	针对图搜无点击请求，离线从历史 Query 图、浏览商品和行为日志中挖掘用户隐式意图；线上由轻量推理模型生成优化计划，并动态调度搜索链路中的策略。
收益	论文报告可提高隐式意图挖掘效率并显著降低无点击率，但摘要未披露统一的具体百分比。
模态	Query 图片 + 历史商品 + 用户行为；更偏系统策略优化，而非单一 embedding。
推荐	适合研究图搜场景识别、兜底通道、策略路由以及无点击问题闭环。

04 · 二、“先推理后表征”通用方法：重点迁移

这一层提供可迁移的 Reasoner->Embedder 训练与推理范式。对电商图搜，价值不在 benchmark 名次本身，而在：如何让 CoT 服务正负商品区分、何时开推理、如何控制延迟。

07 Think Then Embed: Generative Context Improves Multimodal Embedding

基线

arXiv: 2510.05014 · Reasoner + Embedder · MMEB-V2

- 思路** Reasoner 先生成与检索任务相关的 Embedding-Centric Reasoning, Embedder 再联合原始输入和 reasoning 生成向量；同时研究“大 Reasoner + 小 Embedder”、蒸馏 Reasoner 以及统一模型等配置。
- 收益** 论文在 MMEB-V2 上报告当时领先表现，证明显式 reasoning 对复杂多模态约束和组合意图尤其有效。
- 模态** 图片、文本、视频、视觉文档及图文组合 Query。
- 迁移** 可作为 MOON3.0 之外最标准的 Reasoner->Embedder baseline。

08 UME-R1: Exploring Reasoning-Driven Generative Multimodal Embeddings

双通道

arXiv: 2511.00405 · discriminative + generative embedding

- 思路** 同一模型同时输出直接 discriminative embedding 和“生成 reasoning 后得到的 generative embedding”；采用 Cold-start SFT + RL，并探索多次采样产生多个 reasoning / embedding。
- 收益** 相对相同数据规模的 DUME，图像、视频和视觉文档任务总分分别提升 4.1、9.0 和 11.1；相对 VLM2Vec-V2 总体提升 2.1。
- 模态** 图像、视频、视觉文档、图文组合检索。
- 迁移** 适合探索图搜中“直接向量 + 推理向量”双通道召回及 inference-time sampling。

09 Embed-RL: Reinforcement Learning for Reasoning-Driven Multimodal Embeddings

RL

arXiv: 2602.13823 · Embedder-Guided RL · T-CoT

- 思路** 提出 Embedder-Guided RL，由 Embedder 直接评价 Reasoner 生成的 CoT 是否有利于检索；T-CoT 强制推理指出图片、文本中的具体检索证据，而不是只生成泛化解释。
- 收益** 在 MMEB-V2 和 UVRB 上超过其对比的早期 reasoning embedding 模型，重点提升跨模态一致性和细粒度匹配。
- 模态** 图片 / 图文 Query -> 图片、文本或多模态候选。
- 迁移** 非常适合训练商品属性 reasoning，使其真正服务于正负商品区分。

10 MMEB-R1: Reasoning-Enhanced Multimodal Embedding with Pair-Aware Selection and Adaptive Control

难负

arXiv: 2604.06156 · pair-level 监督对齐 · 自适应启用 reasoning

- 思路** 指出普通 CoT 是 instance-level，而对比学习是 query-target pair-level，二者存在监督错位；通过 pair-aware reasoning selection、反事实比较和自适应控制，只在 reasoning 能改善正负间隔时使用它。
- 收益** 论文报告在提高检索准确率的同时，相对 UME-R1 获得约 2.5x 推理延迟改善。
- 模态** 通用图片、文本、视频、视觉文档检索。
- 迁移** 适合电商难负样本训练，避免 reasoning 只学到格式、类目等无判别信息。

11 Think When Needed: Adaptive Reasoning-Driven Multimodal Embeddings

生产

[arXiv:2605.14448](#) · Routing Gate · Reasoning LoRA + Embedding LoRA

思路	共享冻结的 MLLM backbone，分别挂载 Reasoning LoRA 和 Embedding LoRA；Routing Gate 自动决定当前样本走直接 embedding 还是先生成 CoT，并用固定 Embedder 作为稳定 RL reward 环境。
收益	在 MMEB-V2 的 78 个任务上报告领先结果，仅增加 backbone 约 3%-5% 参数，并最多减少 50% reasoning token。
模态	通用多模态召回。
迁移	很适合图搜生产系统--干净商品图直接编码，截图、复杂背景、组合约束等困难 Query 才启动推理。

05 · 三、找相似+修改意图: 重点关注 CIR

Composed Image Retrieval 对应“保持版型, 把红色改成黑色”“保留鞋型, 去除图案”一类需求。推理不再只是解释, 而是要决定保留什么、删除什么、新增什么。

12 CIR-CoT: Towards Interpretable Composed Image Retrieval via End-to-End Chain-of-Thought Reasoning

CIR

arXiv: 2510.08003 · FashionIQ / CIRR / CIRCO

思路	输入参考图片和修改文本, 依次生成 Caption、Reasoning、Conclusion, 最后将目标检索意图压缩到专用 embedding。
收益	在 FashionIQ、CIRR 上取得有竞争力的结果, 并在未参与训练的 CIRCO 上表现出较强泛化。
模态	参考图片 + 修改文本 -> 目标图片。
场景	“保持版型, 将红色改为黑色”“保留鞋型, 去除图案”。

13 MCoT-MVS: Multi-level Vision Selection by Multi-modal CoT Reasoning for Composed Image Retrieval

SOTA

arXiv: 2603.17360 · 视觉区域选择受 reasoning 控制 · 公开代码与模型

思路	MLLM 先输出“应保留、应删除、目标新增”的文本线索, 再用这些线索选择参考图中的 patch-level 和 instance-level 视觉特征, 最后融合修改文本和目标描述。
收益	论文在 CIRR 和 FashionIQ 上报告新的 SOTA, 并公开代码和模型。
模态	参考图 + 商品修改描述 -> 目标商品图。
迁移	比仅将 CoT 文本拼入 embedding 更进一步, 因为 reasoning 会反向控制视觉区域选择。

06 · 四、低延迟前沿探索

显式文本 CoT 在检索准确率上有效，但对高 QPS 图搜过重。这一层探索把“想”放进 latent space：固定 token 预算、单次前向、可蒸馏的 Query Tower。

14

TTE-Flash: Accelerating Reasoning-based Multimodal Representations via Think-Then-Embed Tokens

加速

arXiv: 2605.16638 · latent think tokens · 可解释

思路	不再自回归生成文本 CoT，而是在同一 backbone 中使用 latent think tokens，再由 embedding token 汇总。
收益	TTE-Flash-2B 在 MMEB-V2 上超过其显式 CoT 对照模型，同时 latent token 可通过文本和视觉方式进行解释。
模态	通用图片、文本、视频及视觉文档。
价值	适合高 QPS 图搜，把几十步文本 decode 压缩为固定 token 的一次前向传播。

15

LaME: Learning to Think in Latent Space for Multimodal Embedding

蒸馏

arXiv: 2606.13061 · 信息瓶颈 · 无需 CoT 文本标签

思路	用固定数量的 learnable reason tokens 作为信息瓶颈，在 latent space 完成 reasoning；无需 CoT 文本标签，也无需自回归生成。
收益	核心优势是单次 forward、固定计算预算，并降低 embedding 对教师 CoT 质量的依赖。
模态	通用多模态 embedding。
价值	适合长期研究“MOON3.0 推理能力蒸馏到低延迟 Query Tower”。

07 · 场景选型与阅读路径

按角色挑 3 篇

- 图搜算法 owner: P01 MOON3.0、P02 TIGER-FG、P03 Pailitao-VL
- 训练 / 后训练: P07 Think Then Embed、P09 Embed-RL、P10 MMEmb-R1
- 在线系统: P03 Pailitao-VL、P06 REVISION、P11 Think When Needed
- 服饰改款 / 组合意图: P12 CIR-CoT、P13 MCoT-MVS、P01 属性推理
- 延迟 / 成本: P11 自适应路由、P14 TTE-Flash、P15 LaME

推荐连读路径

1. 演进线: MOON -> MOON2.0 -> MOON3.0 -> MOON Embedding 工业报告
2. 非对称图搜: TIGER-FG -> TGQ-Former -> Think When Needed
3. 工业闭环: Pailitao-VL -> REVISION -> 延迟侧 TTE-Flash / LaME
4. 推理训练: Think Then Embed -> Embed-RL -> MMEmb-R1 -> UME-R1
5. 修改意图: CIR-CoT -> MCoT-MVS

生产问题	优先读	可迁移动作	别先做
商品属性细粒度不足，同款混类	P01, P04, P09	结构化属性推理 + 难负样本上的证据型 CoT	无验真地生成 CoT 直接拼进 embedding
裁剪图 / 拍照图 / 复杂背景召回差	P02, P05, P11	文本引导 grounding + 抗噪视觉 token + 难 Query 路由	一律上大模型长推理，不做干净样本直出
需要召回 + 重排 + 线上可观测	P03, P06	原型 ID embedding + listwise 校准 + 无点击策略闭环	只抄离线 R@K，不看延迟与分场景 A/B
“找相似但改某属性”	P12, P13, P01	修改意图 CoT + 视觉区域选择 + 属性结构	把普通 I2I 相似度当 CIR
推理有效但 QPS 扛不住	P11, P14, P15	自适应开推理; latent think 固定预算蒸馏到 Query Tower	全量 Query 自回归长 CoT

一条可执行的系统拼法

主干: 可预计算 item embedding + ANN 召回 + listwise 重排(P03)。Item 侧吸收属性推理与抗噪(P01 / P05)。Query 侧默认直出向量，困难样本再开推理(P11)，中长期用 latent think 蒸馏(P14 / P15)。裁剪与复杂背景走细粒度 grounding 通道(P02)。无点击与策略路由单独成系统层(P06)。CIR 作为“修改意图”产品入口，不与同款召回混为一谈(P12 / P13)。

08 · 来源与证据边界

本读单按作者公开材料整理思路、收益与适用模态。线上 GMV、CTR、延迟等数字均为作者报告，不是独立审计；预印本工作以方法与公开实验为主，不默认等同正式录用结论。下列编号均可点击跳转 arXiv。

必须分开写的三类信号

- 离线指标：MBE3.0、MMEB-V2、FashionIQ、CIRR、Recall@1 / H@100 等，便于方法比较，不能单独证明线上可买与可部署。
- 工业 A/B：如 Pailitao-VL 部分场景 GMV、MOON Embedding 全链路 CTR，属于高价值产业信号，迁移时要对照数据治理、品类与延迟预算。
- 系统层收益：REVISION 的无点击下降等，属于链路策略结果，不宜直接写成 embedding 模型增益。

引用索引

1. P01 Wu et al., [MOON3.0: Reasoning-aware Multimodal Representation Learning for E-commerce Product Understanding](#). arXiv:2604.00513.
2. P02 Sun et al., [TIGER-FG: Text-Guided Implicit Fine-Grained Grounding for E-commerce Retrieval](#). arXiv:2605.18434.
3. P03 Chen et al., [Pailitao-VL: Unified Embedding and Reranker for Real-Time Multi-Modal Industrial Search](#). arXiv:2602.13704.
4. P04 MOON / MOON2.0 系列：作为 MOON3.0 演进底座阅读；工业部署与 CTR 系统收益见 [MOON Embedding Technical Report](#) (arXiv:2511.11305)，该 CTR 数字为系列累计收益，不可单独归因于 MOON3.0。
5. P05 Guo et al., [Text-Guided Visual Representation Learning for Robust Multimodal E-Commerce Recommendation](#). arXiv:2605.17366.
6. P06 REVISION: Reflective Intent Mining and Online Reasoning Auxiliary for E-commerce Visual Search System Optimization. arXiv:2510.22739. WSDM 2026 Full Paper.
7. P07 [Think Then Embed: Generative Context Improves Multimodal Embedding](#). arXiv:2510.05014.
8. P08 UME-R1: Exploring Reasoning-Driven Generative Multimodal Embeddings. arXiv:2511.00405.
9. P09 Embed-RL: Reinforcement Learning for Reasoning-Driven Multimodal Embeddings. arXiv:2602.13823.
10. P10 MMEB-R1: Reasoning-Enhanced Multimodal Embedding with Pair-Aware Selection and Adaptive Control. arXiv:2604.06156.
11. P11 [Think When Needed: Adaptive Reasoning-Driven Multimodal Embeddings](#). arXiv:2605.14448.
12. P12 CIR-CoT: Towards Interpretable Composed Image Retrieval via End-to-End Chain-of-Thought Reasoning. arXiv:2510.08003.
13. P13 MCoT-MVS: Multi-level Vision Selection by Multi-modal CoT Reasoning for Composed Image Retrieval. arXiv:2603.17360.
14. P14 TTE-Flash: Accelerating Reasoning-based Multimodal Representations via Think-Then-Embed Tokens. arXiv:2605.16638.
15. P15 LaME: Learning to Think in Latent Space for Multimodal Embedding. arXiv:2606.13061.