

电商图搜多模态表征 Paper List 2026: 工业部署、推理增强与低延迟

面向电商图搜的多模态表征精读清单，按“工业与场景直接相关 -> 可迁移的 Reasoner->Embedder -> 组合修改意图 (CIR) -> 低延迟前沿”四层编排。先推理后表征 (Reasoning-then-Embed) 只是其中一类方法，并非全部条目的共同定义；另含 ID 原型 embedding、文本引导 grounding、系统策略推理等相邻工作。

范围：15 篇核心工作，覆盖工业图搜闭环、抗噪与非对称匹配、严格 Reasoner->Embedder、CIR 条件检索，以及 latent think 低延迟路径。

读法：先建立四层结构与方法族归属，再按任务选取 3-5 篇精读。2026 年条目多数仍为 arXiv 预印本；正文以方法与公开实验为据，不默认等同正式录用结论。

AS OF	证据日期：2026-07-13
AXIS	多模态表征 / 工业部署 / 推理增强 / 低延迟
COUNT	15 篇核心 · 4 个阅读层 · 3 个方法族
SCOPE	图搜、同款、抗噪、属性推理、CIR、服务延迟

| 目录

01	使用说明与阅读边界	02	分层地图与优先序
03	一、直接面向电商图搜：优先精读	04	二、“先推理后表征”通用方法
05	三、找相似+修改意图：CIR	06	四、低延迟前沿探索
07	场景选型与连读路径	08	来源与证据边界

01 · 使用说明与阅读边界

本文按电商图搜多模态表征的问题谱系组织，而非假定 15 篇均属同一范式。严格意义的先推理后表征 (Reasoner 显式生成任务相关结构，再编码为检索向量) 主要对应 P01 与第 II、IV 层；第 I 层含工业系统、文本引导 grounding 与抗噪表征，第 III 层为组合修改意图检索。

关注点 方法如何进入可检索表征；商品属性、难负样本与修改文本如何进入训练；召回、重排、策略路由与延迟预算如何约束上线形态。	边界 通用 benchmark 领先不能直接外推为可上线图搜方案；作者报告的 GMV / CTR 不构成独立审计；不得把工业系统文或 grounding 文直接标为 Reasoning-then-Embed。	场景入口 同款 / 近同款：P01-P03；抗噪与非对称：P02、P05；严格 RTE：P07-P11、P14-P15；属性修改意图：P12-P13；无点击策略：P06。
---	--	---

方法族	条目	与 Reasoning-then-Embed 的关系
严格 Reasoner->Embedder	P01, P07-P11, P14-P15	先生成/先 think, 再得到 embedding; 含自适应启用与 latent 压缩变体
推理服务检索, 但非标准 RTE 管线	P06, P12, P13	系统策略推理或 CIR 的 CoT / 视觉选择; 未必是“生成后压成双塔向量”的统一管线
工业表征、抗噪与演进底座	P02-P05	ID 原型 embedding、文本引导 grounding、元数据引导 token、MOON 演进; 与推理增强相邻, 但不宜标为 RTE

预印本与证据分层

清单中 2026 年工作多数仍为 arXiv 预印本，正文仅将其视为方法与公开实验信号；录用状态、线上收益与跨平台可迁移性分开表述。REVISION 为 WSDM 2026 Full Paper，其余以 arXiv 公开版本为准。

02 · 分层地图与优先序

I · 电商图搜 MOON3.0 / TIGER-FG Pailitao / TGQ / REVISION 优先精读 P01-P06	II · 推理->表征 Think Then Embed UME / Embed-RL / MMEmb 严格 RTE 与自适应路由	III · CIR CIR-CoT · MCoT-MVS 参考图 + 修改文本 相似检索下的属性修改	IV · 低延迟 TTE-Flash · LaME latent think tokens 固定预算一次前向
--	--	--	--

系统落点

Query 侧属性或意图推理 -> 256 维或 MRL 向量 -> ANN 召回 -> listwise 重排；仅对困难 Query 启用显式 CoT。工业主干可参考 Pailitao-VL 的 ID 原型 embedding 与 compare-and-calibrate reranker。中长期蒸馏目标是将 MOON3.0 一类推理能力压缩至 LaME / TTE-Flash 形态的低延迟 Query Tower。

#	工作	层	一句话	arXiv / 状态
01	MOON3.0	电商图搜	结构化属性推理后形成统一商品向量	2604.00513
02	TIGER-FG	电商图搜	文本引导隐式细粒度 grounding, 处理裁剪图与全图非对称	2605.18434
03	Pailitao-VL	电商图搜	工业统一 embedding + listwise reranker	2602.13704
04	MOON / MOON2.0	电商图搜	生成式表征到推理式表征的演进基础	系列演进
05	TGQ-Former	电商图搜	标题、类目与元数据引导视觉 token, 抑制噪声	2605.17366
06	REVISION	电商图搜	无点击意图挖掘与线上策略路由	2510.22739 · WSDM 2026
07	Think Then Embed	通用 RTE	Reasoner 生成检索导向 reasoning 后再编码	2510.05014
08	UME-R1	通用 RTE	discriminative 与 generative embedding 双通道	2511.00405
09	Embed-RL	通用 RTE	Embedder 指导 RL, 约束推理指向检索证据	2602.13823
10	MMEmb-R1	通用 RTE	pair-aware 选择: 仅在改善正负间隔时启用 reasoning	2604.06156
11	Think When Needed	通用 RTE	路由门控: 常规样本直出, 困难样本再推理	2605.14448
12	CIR-CoT	CIR	Caption->Reasoning->Conclusion->embedding	2510.08003
13	MCoT-MVS	CIR	推理线索反向选择视觉 patch/instance	2603.17360
14	TTE-Flash	低延迟	以 latent think tokens 替代长文本 CoT	2605.16638
15	LaME	低延迟	固定数量 reason tokens 构成 latent 信息瓶颈	2606.13061

03 · 一、直接面向电商图搜：优先精读

本层直接对应生产图搜：商品多图文、裁剪 Query、复杂背景、同款与近同款、召回后重排及无点击闭环。
建议并行阅读 MOON 演进线与工业系统线。

01

MOON3.0: Reasoning-aware Multimodal Representation Learning for E-commerce Product Understanding

精读

arXiv: 2604.00513 · 电商商品统一表征 · 先推理、后表征

- 思路
- 先推理、后表征：由商品图像与标题生成类别、颜色、材质、设计元素等结构化属性，再经 `<emb>` 表征、原始图文多头融合与 FIRE 细粒度残差增强，输出 256 维向量。
- 收益
- 相对 MOON2.0, MBE3.0 上 Image->MM R@10 由 50.41 升至 56.39, Text->MM 由 35.33 升至 48.10; 分类准确率由 67.27 升至 86.40, 属性准确率由 36.36 升至 49.92。
- 模态
- 图片->图文商品、文本->图文商品、图文->图文、文搜图、图搜文本。
- 阅读价值
- 与“电商商品多模态统一表征 + 推理召回”问题设定最为接近的代表工作。

02

TIGER-FG: Text-Guided Implicit Fine-Grained Grounding for E-commerce Retrieval

精读

arXiv: 2605.18434 · 裁剪 Query 非对称 · 隐式目标定位

- 思路
- 针对裁剪商品 Query 图与“完整商品图 + 文本”之间的模态与粒度非对称，以商品文本引导候选图像完成隐式目标定位，无需额外检测框；再以空间一致性与相似度结构双重蒸馏强化细粒度匹配。
- 收益
- 在标准与复杂背景测试集上，相对最强基线 Recall@1 分别提升 6.1 与 34.4 个百分点；Query 侧参数量 85.7M, 输出 256 维向量。
- 模态
- 裁剪图片 Query -> 完整商品图片 + 标题 / 属性。
- 阅读价值
- 对拍照图、子图、复杂背景与多商品干扰等非对称图搜设定具有直接针对性。

03

Pailitao-VL: Unified Embedding and Reranker for Real-Time Multi-Modal Industrial Search

工业

arXiv: 2602.13704 · 阿里拍立淘 · 召回 + 重排 + 实时部署

- 思路
- 阿里拍立淘工业系统。Embedding 由相对式对比学习转为超大规模 Absolute ID Recognition, 使高纯度商品实例对应稳定的全局语义原型；Reranker 由 pointwise 判定转为 chunk 内比较与跨 chunk 绝对分数校准。
- 收益
- 公开线上 A/B 中，部分 AI 搜索场景作者报告约 20% GMV 增长；Embedding 与 listwise reranker 平均延迟分别约为 67 ms 与 76 ms。
- 模态
- 多模态商品召回、同款 / 近同款检索、召回后高精度重排。
- 阅读价值
- 覆盖召回、重排、线上 A/B 与实时部署闭环的完整工业参考。

04 MOON / MOON2.0: MOON3.0 的基础演进路线

演进

系列演进 · 建议按 MOON -> MOON2.0 -> MOON3.0 顺序阅读

MOON	以生成式 MLLM 学习商品统一表征，引入 guided MoE、核心视觉区域识别与电商难负样本策略，处理商品多图、多文本的 many-to-one 对齐。
2.0	针对图文训练中的模态不平衡、商品内部图文关系利用不足及电商噪声作进一步约束与建模。
模态	商品多图 + 标题 / 属性；支持跨模态检索、分类与属性预测。
阅读价值	连读 MOON 至 MOON3.0，可系统把握从生成式商品表征到推理式商品表征的演进逻辑。

工业报告 · MOON Embedding

MOON Embedding 技术报告称，该系列已部署于淘宝搜索广告的召回、相关性与排序阶段，并报告整体 CTR 预测累计提升约 20%。该数字为系列多次迭代的系统收益，不可单独归因于 MOON3.0 或某一召回模型。报告入口：[MOON Embedding Technical Report \(arXiv: 2511.11305\)](#)。

05 Text-Guided Visual Representation Learning for Robust Multimodal E-Commerce Recommendation

抗噪

arXiv: 2605.17366 · TGQ-Former · 元数据引导视觉 token

思路	提出 TGQ-Former：以商品标题、类目与结构化元数据引导视觉 token 选择；保留 metadata-guided 与 exploratory 两路视觉 query，并以可靠性双门控抑制促销文字、背景与装饰噪声。
收益	在大规模全库商品检索中，平均 Hit Rate@100 提升 6.04%。
模态	商品图片 + 标题 / 类目 / 属性 -> 商品 I2I 或多模态召回。
阅读价值	针对商详海报、促销角标、复杂背景与主体不突出等线上视觉噪声具有明确针对性。

06 REVISION: Reflective Intent Mining and Online Reasoning Auxiliary for E-commerce Visual Search System Optimization

系统

arXiv: 2510.22739 · WSDM 2026 Full Paper · 无点击闭环

思路	针对图搜无点击请求：离线从历史 Query 图、浏览商品与行为日志挖掘用户隐式意图；线上由轻量推理模型生成优化计划，并动态调度检索链路中的策略模块。
收益	作者报告可提高隐式意图挖掘效率并显著降低无点击率；摘要未给出统一量化百分比。
模态	Query 图片 + 历史商品 + 用户行为；重心在系统策略层，而非单一 embedding 模型。
阅读价值	适用于图搜场景识别、兜底通道、策略路由与无点击闭环的系统设计讨论。

04 · 二、“先推理后表征”通用方法：重点迁移

本层给出可迁移的 Reasoner->Embedder 训练与推理范式。对电商图搜而言，关键不在通用 benchmark 名次，而在 CoT 是否服务于正负样本区分、何时启用推理，以及如何控制延迟。

07 Think Then Embed: Generative Context Improves Multimodal Embedding

基线

arXiv: 2510.05014 · Reasoner + Embedder · MMEB-V2

- 思路** Reasoner 先生成与检索任务相关的 Embedding-Centric Reasoning, Embedder 再联合原始输入与 reasoning 生成向量；并比较“大 Reasoner + 小 Embedder”、Reasoner 蒸馏与统一模型等配置。
- 收益** 在 MMEB-V2 上报告当时领先结果；显式 reasoning 对复杂多模态约束与组合意图更为有效。
- 模态** 图片、文本、视频、视觉文档及图文组合 Query。
- 迁移** 可作为除 MOON3.0 外的标准 Reasoner->Embedder 对照基线。

08 UME-R1: Exploring Reasoning-Driven Generative Multimodal Embeddings

双通道

arXiv: 2511.00405 · discriminative + generative embedding

- 思路** 同一模型并行输出 discriminative embedding 与经 reasoning 得到的 generative embedding；训练采用 Cold-start SFT + RL，并考察多次采样生成多组 reasoning / embedding。
- 收益** 相对同数据规模的 DUME，图像、视频与视觉文档任务总分分别提升 4.1、9.0 与 11.1；相对 VLM2Vec-V2 总体提升 2.1。
- 模态** 图像、视频、视觉文档、图文组合检索。
- 迁移** 可用于图搜中“直接向量 + 推理向量”双通道召回及 inference-time sampling 设计。

09 Embed-RL: Reinforcement Learning for Reasoning-Driven Multimodal Embeddings

RL

arXiv: 2602.13823 · Embedder-Guided RL · T-CoT

- 思路** 提出 Embedder-Guided RL：由 Embedder 直接评估 Reasoner 生成的 CoT 是否利于检索；T-CoT 要求推理指明图像与文本中的具体检索证据，而非仅生成泛化说明。
- 收益** 在 MMEB-V2 与 UVRB 上优于文中对照的早期 reasoning embedding 模型，主要提升跨模态一致性与细粒度匹配。
- 模态** 图片 / 图文 Query -> 图片、文本或多模态候选。
- 迁移** 可用于商品属性 reasoning 训练，使推理内容直接服务于正负样本区分。

10 MMEmb-R1: Reasoning-Enhanced Multimodal Embedding with Pair-Aware Selection and Adaptive Control

难负

arXiv: 2604.06156 · pair-level 监督对齐 · 自适应启用 reasoning

- 思路** 指出常规 CoT 监督为 instance-level，而对比学习为 query-target pair-level，二者存在监督错位；通过 pair-aware reasoning selection、反事实比较与自适应控制，仅在 reasoning 能改善正负间隔时启用。
- 收益** 作者报告在提高检索准确率的同时，相对 UME-R1 获得约 2.5x 推理延迟改善。
- 模态** 通用图片、文本、视频、视觉文档检索。
- 迁移** 适用于电商难负样本训练，抑制仅学到格式、类目等无判别信息的空转 reasoning。

11 Think When Needed: Adaptive Reasoning-Driven Multimodal Embeddings

生产

arXiv:2605.14448 · Routing Gate · Reasoning LoRA + Embedding LoRA

思路	共享冻结的 MLLM backbone，分别挂载 Reasoning LoRA 与 Embedding LoRA；Routing Gate 判定当前样本直接编码或先生成 CoT，并以固定 Embedder 作为稳定 RL reward 环境。
收益	在 MMEB-V2 的 78 个任务上报告领先结果；相对 backbone 约增加 3%-5% 参数，reasoning token 最多减少 50%。
模态	通用多模态召回。
迁移	贴近图搜在线约束：常规商品图直接编码，截图、复杂背景与组合约束等困难 Query 再启用推理。

05 · 三、找相似+修改意图: 重点关注 CIR

Composed Image Retrieval 对应“保持版型, 将红色改为黑色”“保留鞋型, 去除图案”等条件检索。此时推理的任务不是事后解释, 而是显式决定应保留、应删除与应新增的视觉语义。

12 CIR-CoT: Towards Interpretable Composed Image Retrieval via End-to-End Chain-of-Thought Reasoning

CIR

arXiv: 2510.08003 · FashionIQ / CIRR / CIRCO

思路	输入参考图片与修改文本, 依次生成 Caption、Reasoning、Conclusion, 再将目标检索意图压缩为专用 embedding。
收益	在 FashionIQ、CIRR 上取得有竞争力的结果, 并在未参与训练的 CIRCO 上表现较好泛化。
模态	参考图片 + 修改文本 -> 目标图片。
场景	“保持版型, 将红色改为黑色”“保留鞋型, 去除图案”。

13 MCoT-MVS: Multi-level Vision Selection by Multi-modal CoT Reasoning for Composed Image Retrieval

SOTA

arXiv: 2603.17360 · 视觉区域选择受 reasoning 控制 · 公开代码与模型

思路	MLLM 先输出“应保留、应删除、应新增”的文本线索, 据此选择参考图中的 patch-level 与 instance-level 视觉特征, 再融合修改文本与目标描述。
收益	作者在 CIRR 与 FashionIQ 上报告新的 SOTA, 并公开代码与模型。
模态	参考图 + 商品修改描述 -> 目标商品图。
迁移	相较将 CoT 文本直接拼入 embedding, 其 reasoning 可反向控制视觉区域选择, 结构性更强。

06 · 四、低延迟前沿探索

显式文本 CoT 可提升检索准确率，但在高 QPS 图搜中计算代价过高。本层讨论将推理移入 latent space：固定 token 预算、单次前向，以及可蒸馏的 Query Tower。

14

TTE-Flash: Accelerating Reasoning-based Multimodal Representations via Think-Then-Embed Tokens

加速

arXiv: 2605.16638 · latent think tokens · 可解释

- 思路
- 不以自回归方式生成长文本 CoT，而在同一 backbone 中使用 latent think tokens，再由 embedding token 汇总。
- 收益
- TTE-Flash-2B 在 MMEB-V2 上超过其显式 CoT 对照模型；latent token 仍可通过文本与视觉途径解释。
- 模态
- 通用图片、文本、视频及视觉文档。
- 探索价值
- 面向高 QPS 图搜，将数十步文本 decode 压缩为固定 token 的一次前向传播。

15

LaME: Learning to Think in Latent Space for Multimodal Embedding

蒸馏

arXiv: 2606.13061 · 信息瓶颈 · 无需 CoT 文本标签

- 思路
- 以固定数量的 learnable reason tokens 作为信息瓶颈，在 latent space 完成 reasoning；无需 CoT 文本标签，亦无需自回归生成。
- 收益
- 主要优势为单次 forward、固定计算预算，并降低 embedding 对教师 CoT 质量的依赖。
- 模态
- 通用多模态 embedding。
- 探索价值
- 可作为将 MOON3.0 类推理能力蒸馏至低延迟 Query Tower 的长期研究路径。

07 · 场景选型与连读路径

按职责选取 3 篇

- 图搜算法负责人: P01 MOON3.0、P02 TIGER-FG、P03 Pailitao-VL
- 训练与后训练: P07 Think Then Embed、P09 Embed-RL、P10 MMEmb-R1
- 在线系统: P03 Pailitao-VL、P06 REVISION、P11 Think When Needed
- 服饰改款与组合意图: P12 CIR-CoT、P13 MCoT-MVS、P01 属性推理
- 延迟与成本: P11 自适应路由、P14 TTE-Flash、P15 LaME

建议连读路径

- 演进线: MOON -> MOON2.0 -> MOON3.0 -> MOON Embedding 技术报告
- 非对称图搜: TIGER-FG -> TGQ-Former -> Think When Needed
- 工业闭环: Pailitao-VL -> REVISION -> 延迟侧 TTE-Flash / LaME
- 推理训练: Think Then Embed -> Embed-RL -> MMEmb-R1 -> UME-R1
- 修改意图: CIR-CoT -> MCoT-MVS

问题设定	优先阅读	可迁移要点	常见误用
属性细粒度不足，同款混类	P01, P04, P09	结构化属性推理 + 难负样本上的证据型 CoT	无验真地生成 CoT 并直接拼入 embedding
裁剪图 / 拍照图 / 复杂背景召回不足	P02, P05, P11	文本引导 grounding + 抗噪视觉 token + 困难 Query 路由	对全部流量启用大模型长推理，不做常规样本直出
需召回、重排与线上可观测闭环	P03, P06	原型 ID embedding + listwise 校准 + 无点击策略闭环	仅复制离线 R@K，忽略延迟与分场景 A/B
相似检索下的属性修改意图	P12, P13, P01	修改意图 CoT + 视觉区域选择 + 属性结构	将普通 I2I 相似度检索当作 CIR
推理有效但服务 QPS 不足	P11, P14, P15	自适应启用推理; 以 latent think 固定预算蒸馏 Query Tower	对全量 Query 做自回归长 CoT

系统组合参考

主干采用可预计算 item embedding、ANN 召回与 listwise 重排 (P03)。Item 侧吸收属性推理与抗噪 (P01 / P05)。Query 侧默认直接编码，困难样本再启用推理 (P11); 中长期以 latent think 蒸馏 (P14 / P15)。裁剪与复杂背景走细粒度 grounding 通道 (P02)。无点击与策略路由独立为系统层 (P06)。CIR 作为修改意图入口，不与同款召回混用 (P12 / P13)。

08 · 来源与证据边界

本文依据作者公开材料整理方法要点、报告收益与适用模式。线上 GMV、CTR、延迟等数字均为作者报告，不构成独立审计；预印本工作以方法与公开实验为主，不默认等同正式录用结论。下列条目中的 arXiv 编号可直接点击访问。

三类信号宜分开引用

- 离线指标：MBE3.0、MMEB-V2、FashionIQ、CIRR、Recall@1 / H@100 等，用于方法比较，不能单独证明线上可交易性与可部署性。
- 工业 A/B：如 Pailitao-VL 部分场景 GMV、MOON Embedding 全链路 CTR，属于有价值的产业信号；跨平台迁移须对照数据治理、品类结构与延迟预算。
- 系统层收益：如 REVISION 报告的无点击率下降，属于链路策略结果，不宜直接表述为 embedding 模型增益。

引用索引

1. P01 Wu et al., [MOON3.0: Reasoning-aware Multimodal Representation Learning for E-commerce Product Understanding](#). [arXiv:2604.00513](#).
2. P02 Sun et al., [TIGER-FG: Text-Guided Implicit Fine-Grained Grounding for E-commerce Retrieval](#). [arXiv:2605.18434](#).
3. P03 Chen et al., [Pailitao-VL: Unified Embedding and Reranker for Real-Time Multi-Modal Industrial Search](#). [arXiv:2602.13704](#).
4. P04 MOON / MOON2.0 系列：作为 MOON3.0 演进底座阅读；工业部署与 CTR 系统收益见 [MOON Embedding Technical Report](#) ([arXiv:2511.11305](#))，该 CTR 数字为系列累计收益，不可单独归因于 MOON3.0。
5. P05 Guo et al., [Text-Guided Visual Representation Learning for Robust Multimodal E-Commerce Recommendation](#). [arXiv:2605.17366](#).
6. P06 REVISION: Reflective Intent Mining and Online Reasoning Auxiliary for E-commerce Visual Search System Optimization. [arXiv:2510.22739](#). WSDM 2026 Full Paper.
7. P07 Think Then Embed: Generative Context Improves Multimodal Embedding. [arXiv:2510.05014](#).
8. P08 UME-R1: Exploring Reasoning-Driven Generative Multimodal Embeddings. [arXiv:2511.00405](#).
9. P09 Embed-RL: Reinforcement Learning for Reasoning-Driven Multimodal Embeddings. [arXiv:2602.13823](#).
10. P10 MMEB-R1: Reasoning-Enhanced Multimodal Embedding with Pair-Aware Selection and Adaptive Control. [arXiv:2604.06156](#).
11. P11 Think When Needed: Adaptive Reasoning-Driven Multimodal Embeddings. [arXiv:2605.14448](#).
12. P12 CIR-CoT: Towards Interpretable Composed Image Retrieval via End-to-End Chain-of-Thought Reasoning. [arXiv:2510.08003](#).
13. P13 MCoT-MVS: Multi-level Vision Selection by Multi-modal CoT Reasoning for Composed Image Retrieval. [arXiv:2603.17360](#).
14. P14 TTE-Flash: Accelerating Reasoning-based Multimodal Representations via Think-Then-Embed Tokens. [arXiv:2605.16638](#).
15. P15 LaME: Learning to Think in Latent Space for Multimodal Embedding. [arXiv:2606.13061](#).