

TECHNICAL FIELD GUIDE · 2026

具身智能入门与 技术栈全景报告 2026

从机器人身体、数据闭环、VLA 模型、世界模型到产业格局与学习路线：给
希望从 0 到 1 建立完整判断框架的技术读者。

Winston

V1.0 · 2026-05-20

独立技术教程与产业研究笔记

| 目录

01	执行摘要：具身智能到底在解决什么	03
02	概念地图：从 AI 到机器人行动	04
03	完整架构：一个具身系统怎样闭环	06
04	机器人基础：身体、坐标、控制与安全	08
05	数据工程：机器人学习的燃料与瓶颈	10
06	算法谱系：从模仿学习到 VLA 与世界模型	13
07	主流技术栈：从实验室到真实部署	15
08	国内外大厂与创业公司工作图谱	17
09	发展方向：未来三到五年的关键赌点	19
10	0 到 1 学习路线：怎样真正入门	21
11	前景判断：机会、限制与风险	23
12	术语表、阅读清单与参考资料	25

执行摘要：具身智能到底在解决什么

具身智能不是“给机器人接一个大模型”这么简单。它要解决的是一个更硬的问题：让系统在带噪声、带延迟、会碰撞、会失误的真实世界里，把语言目标转化为可验证的身体行动。这个领域的核心资产不是单个模型，而是 **身体、数据、模型、控制、安全、运维** 组成的闭环。

五个结论先放在前面

1. 具身智能的难点在行动闭环。文本模型可以一次性输出答案，机器人必须持续感知、规划、执行、纠错。一个 2 秒任务可能包含几十到几百个控制步，每一步都可能被摩擦、遮挡、物体形变、人类干预打断。
2. 数据是最大瓶颈。互联网文本可以低成本爬取，机器人数据需要真实设备、遥操作、仿真、标注、失败采样和安全复现。Open X-Embodiment、DROID、LeRobot、AgiBot World 这类公开数据集的价值，正是把机器人学习从孤岛实验推向跨平台复用。
3. VLA 是当前最重要的范式之一。VLA 指 Vision-Language-Action，即把视觉、语言和动作放在同一个模型接口里。RT-2、OpenVLA、Octo、Physical Intelligence 的 π 系列、Figure Helix、NVIDIA GR00T 和 Google Gemini Robotics 都在围绕这个方向推进。
4. 产业落地会先从受控场景开始。仓储、制造、质检、搬运、分拣、简单装配、门店后场和医院物流比开放家庭更早商业化。原因不是家庭价值低，而是家庭环境过于开放，物体长尾、人的偏好、责任边界和售后成本都更难控制。
5. 未来三到五年的胜负手是数据飞轮。硬件可买，模型可跟进，算法论文会扩散。真正难复制的是高频真实场景、低成本采集、自动评测、失败回流、仿真再生成和安全上线组成的工程系统。

本文档回答的问题

读完后你应该能回答四个问题：具身智能和传统机器人、普通大模型有什么区别；一个可部署系统由哪些层组成；主流算法和工具链各自解决什么；如果今天从零入门，前三个月应该怎样学习和做项目。

这份报告怎样读

前半部分给出概念、架构和方法论，适合从零建立框架。中间部分拆技术栈和公司版图，适合判断行业趋势。最后给出学习路径、项目建议和前景判断。每章都尽量遵守一个原则：先讲为什么需要这一层，再讲它怎么做，最后讲它失败时会发生什么。

事实边界

本文的公开资料边界是 **2026-05-20**。公司产品、模型版本、订单、量产进度和市场预测会变化。正文中涉及企业进展时，优先采用官方博客、论文、GitHub、模型仓库、企业新闻稿和政府/行业报告；对第三方预测只作为趋势参考，不当作事实结论。

概念地图：从 AI 到机器人行动

理解具身智能，先不要从“人形机器人”开始。人形只是身体形态之一。更稳的起点是：任何智能体只要需要借助身体在环境中感知、行动、改变世界，并从结果中学习，就进入了具身智能的范畴。

定义：具身智能的四个必要条件

条件	含义	为什么必要	典型反例
身体	有可执行动作的物理载体或仿真载体	行动能力受关节、末端执行器、传感器和动力学限制	只聊天的网页助手
环境	任务发生在可变化的空间中	环境会反馈成功、失败、碰撞、遮挡和人类干预	离线分类器
闭环	感知、决策、执行、再感知连续发生	真实世界不能靠一次性答案完成任务	单次文本生成
学习	系统能从数据、反馈、失败或仿真中改进行为	手写规则无法覆盖物体、任务和场景长尾	固定脚本机械臂

具身智能和传统机器人有什么不同

传统机器人也可以很强。工业机械臂在焊接、喷涂、码垛、搬运上已经长期稳定工作。差异不在“有没有机器人”，而在 **任务是否足够固定**。如果物体、位置、流程、夹具、节拍都稳定，传统机器人可以用确定性工程做到极高可靠性。如果任务开放，物体不固定，语言目标会变化，人会进入工作区，机器人就需要更强的感知、泛化和失败恢复能力。

维度	传统自动化	具身智能	判断标准
任务描述	坐标、工序、轨迹、PLC 程序	语言目标、视觉目标、上下文约束	换任务时是否需要工程师重编程
环境假设	夹具固定，物体姿态受控	物体位置、遮挡、形变和干扰常变化	任务现场是否能被完全结构化
控制方式	显式轨迹和控制律	学习策略加低层控制	动作是否由数据学习出来
失败恢复	停机报警，由人排查	识别失败，重新抓取，调整计划	失败是否被纳入正常流程
扩展方式	复制产线方案	复用数据、模型和技能库	新增物体/任务的边际成本

具身智能和大模型有什么不同

大语言模型主要处理符号世界，输入输出是文本、图像、音频或代码。具身系统必须把抽象目标落到物理动作上。这里出现三个额外约束：第一，动作有时间成本和安全成本；第二，真实世界状态不能被完全观测；第三，错误会改变环境本身，甚至造成损坏。

文本模型的错误通常可以重试；机器人错误可能把杯子打碎、夹伤人、撞坏设备，或者把现场状态变成另一个更难恢复的状态。因此具身智能必须把“安全、约束、可回退、可观察”放进架构，而不是把模型输出直接接到电机。

能力分级：从遥控设备到通用具身体

层级	能力形态	系统特征	典型评价
L0 远程控制	人控制机器人	机器人是人的延伸，无自主决策	遥操作延迟、稳定性、视角质量
L1 固定自动化	固定脚本执行	流程受控，异常由人处理	节拍、停机率、安全联锁
L2 感知辅助	看见物体后执行预设技能	视觉定位加抓取/导航技能	识别率、抓取成功率、误检漏检
L3 任务级自主	根据目标组合技能	能分解任务、选择工具、失败重试	任务成功率、恢复率、平均完成时长
L4 跨场景泛化	新物体、新场景可迁移	依赖大规模数据、多模态模型和仿真	零样本/少样本任务表现
L5 开放世界助手	长期、多目标、人类共处	需要记忆、社会规范、责任边界和持续学习	长期可靠性、信任、安全与成本


为什么现在突然加速

加速来自四个条件同时成熟。第一，多模态基础模型让视觉和语言接口统一，机器人不再只依赖窄域识别器。第二，遥操作和低成本硬件降低了真实数据采集门槛。第三，仿真平台和世界模型让合成数据更有用。第四，仓储、制造、养老、服务业的人力缺口给自动化提供了明确需求。任何一个条件单独存在都不足以改变行业，四者叠加才构成这一轮具身智能热潮。

完整架构：一个具身系统怎样闭环

具身智能系统可以看成是一个持续运行的控制闭环：传感器把世界变成状态，模型把状态和任务变成动作，控制器把动作变成力和运动，安全层持续检查边界，数据系统把成功和失败带回训练流程。

FIGURE 1 EMBODIED AI SYSTEM LOOP



判断一个具身系统成熟度，不看演示视频的顺滑程度，而看它是否具备失败采样、版本回滚、场景覆盖和安全门控。

图 1：具身智能系统的核心不是一个模型节点，而是模型与身体、安全、数据和运维共同组成的闭环。

分层架构：每一层各管什么

层	职责	常见实现	失败模式
任务层	接收人类目标，维护任务上下文	自然语言、工单、UI、规则模板	目标歧义，权限不足，任务约束漏掉
语义理解层	把目标映射到对象、区域、工具、步骤	VLM、LLM、场景图、检索记忆	物体指代错误，常识过度泛化
状态估计层	估计机器人与环境状态	SLAM、视觉伺服、物体姿态估计、触觉反馈	遮挡、漂移、反光、透明物体
策略层	决定下一段动作或技能	VLA、扩散策略、ACT、技能库、行为树	动作不稳定，长时任务忘记目标
控制层	把动作转成轨迹、力矩和电机命令	PID、MPC、阻抗控制、运动规划	震荡、过冲、碰撞、力控失稳
安全层	约束动作边界并处理中断	急停、速度限制、碰撞检测、权限门控	模型绕过约束，异常无法降级
数据层	采集、清洗、标注、训练和评测	日志系统、RLDS/LeRobot 数据格式、仿真回放	数据偏置，成功样本过多，失败不可复现

快慢双系统：为什么不能所有事都交给大模型

真实机器人通常需要两个速度层。慢系统负责语义理解、任务规划、场景重构和策略选择，频率可以是 1 到 10 Hz。快系统负责关节控制、平衡、避障、力控和安全制动，频率可以是 100 到 1000 Hz。大模型适合慢系统，不适合直接闭环控制高速电机。把慢系统输出限制在技能、目标位姿、动作块或约束条件上，再交给低层控制执行，是更稳妥的工程划分。

动作表示：模型到底输出什么

动作表示	例子	优点	风险
离散技能	抓取、放置、开门、导航到货架	安全可控，便于业务编排	泛化能力受技能库限制
末端位姿	夹爪移动到某个 6D 姿态	适合机械臂操作，解释性较好	需要稳定姿态估计和运动规划
关节增量	每步输出多个关节的角度变化	表达能力强，可端到端学习	安全风险高，对数据和控制频率敏感
动作 token	把连续动作离散化成词表	便于复用语言模型训练框架	量化误差与长序列稳定性问题
轨迹块	一次输出未来若干步动作	降低推理频率，动作更平滑	遇到突发干扰时需要快速重规划

评估口径：不要只看单次成功视频

具身智能最容易被演示视频误导。严肃评估至少要看四类指标：任务成功率、失败恢复率、平均完成时间和安全事件数。更进一步，还要按物体、光照、视角、场景、操作者、机器人个体和时间段分层统计。如果模型只在熟悉物体、固定机位和剪辑过的视频里成功，它还不能被称为可部署能力。

机器人基础：身体、坐标、控制与安全

从 AI 背景进入具身智能，最容易低估机器人本体约束。模型输出的“拿起杯子”在物理系统里会变成相机标定、坐标变换、逆运动学、轨迹规划、力控、碰撞检测和异常处理。

机器人身体：形态决定任务边界

形态	适合任务	优势	短板
固定机械臂	抓取、装配、质检、上下料	稳定、承载强、定位精度高	工作空间固定，场景需要结构化
移动底盘加机械臂	仓储拣选、实验室自动化、医院物流	可移动，可操作，落地场景清晰	导航和操作耦合，安全复杂度上升
四足机器人	巡检、复杂地形移动、安防	越障能力强，稳定性高	精细操作能力通常依赖外挂手臂
人形机器人	为人类空间设计的通用任务	可使用现有人类环境、工具和通道	成本、功耗、平衡、手部灵巧性和可靠性都难
灵巧手	小物体操作、工具使用、装配	动作空间丰富	触觉、力控和数据采集难度极高

坐标系：具身智能的“语法”

机器人系统里常见坐标包括世界坐标、底盘坐标、相机坐标、末端执行器坐标、物体坐标和任务坐标。一个简单抓取任务也需要把相机看到的像素点，转成相机坐标中的三维点，再经过外参变换转到底盘或机械臂基座坐标，最后求出末端执行器应该到达的位姿。任何一步标定错误，都会表现为“模型看懂了，但手伸歪了”。

入门时要先熟悉三个词：pose 是位置加姿态，通常是 3D 平移加旋转；kinematics 是关节和末端位置之间的几何关系；calibration 是让传感器、机器人和世界坐标对齐。没有这三件事，VLA 模型输出再漂亮也落不到真实动作。

控制：高层智能和低层稳定性的分工

控制层负责把目标动作变成可执行运动。常见控制方式包括位置控制、速度控制、力矩控制、阻抗控制和模型预测控制。位置控制适合简单搬运，力控适合插拔、擦拭、装配和接触丰富的任务。越接近真实操作，越不能只看“到达目标点”，还要控制接触力、速度、路径和安全距离。

问题	高层模型负责	低层控制负责	工程边界
把杯子放到托盘	识别杯子与托盘，选择放置区域	规划抓取姿态、避障、释放动作	模型不直接输出电机电流
开抽屉	理解抽屉把手位置和动作意图	沿约束方向施力并保持接触	需要力控或视觉伺服
人靠近机器人	识别人类进入工作区	限速、停止、撤离轨迹	安全策略优先于任务策略
双足行走	选择目标路径和步态意图	平衡、落脚点、关节力矩	高频控制不适合大模型直接闭环

传感器：视觉之外还有身体感觉

视觉是目前具身智能中最常用的输入，但仅靠视觉不足以处理接触任务。力矩传感器能告诉系统是否碰到物体，触觉传感器能感知滑动和压力分布，IMU 能用于姿态估计，编码器能提供关节状态，麦克风和语音接口可用于人机协作。高阶具身能力往往来自多传感器融合，而不是单个视觉模型的提升。

安全：不是最后一层补丁

安全应该从系统设计初期进入，而不是上线前加一个急停按钮。最低要求包括速度和力限制、碰撞检测、工作区边界、人类接近降速、策略置信度门控、异常状态回退、日志留存和版本回滚。对人形机器人和移动操作机器人来说，还要考虑跌倒、夹伤、隐私、远程接管和责任归属。

数据工程：机器人学习的燃料与瓶颈

具身智能最稀缺的不是模型参数，而是覆盖真实任务分布的数据。语言模型可以从互联网上学习大量文本，机器人却必须亲自经历物体、空间、接触、失败和恢复。

数据来源：每一种都有代价

来源	获得方式	适合学习	主要问题
人工遥操作	人用手柄、VR、外骨骼或同构设备控制机器人	高质量操作策略、复杂动作	成本高，操作者风格差异大
自主执行日志	机器人上线后记录成功和失败轨迹	真实场景分布、故障模式	早期模型能力不足，失败数据有安全成本
仿真数据	在 MuJoCo、Isaac、ManiSkill 等平台生成	大规模探索、危险场景、域随机化	仿真到现实的差距仍然存在
互联网视频	从人类行为视频中学习目标、物体和动作先验	常识、动作语义、长时任务理解	缺少机器人可执行动作标签
合成数据	用生成模型、世界模型或程序化场景生成	稀有场景、视觉多样性、预训练	如果物理不准，会放大错误先验
公开数据集	Open X-Embodiment、DROID、AgiBot World 等	跨机器人预训练、基准比较	动作空间和硬件差异需要对齐

数据结构：一条轨迹包含什么

机器人数据的基本单位通常是 episode，也就是一次任务轨迹。它至少包含时间戳、图像、机器人状态、动作、任务描述和终止标记。更完整的数据还会包含深度图、点云、触觉、力矩、相机外参、物体标签、成功标记、失败原因和人工接管记录。数据质量不只看数量，也看字段是否足以复现当时发生了什么。

```
episode = {
  "instruction": "把红色杯子放到左侧托盘",
  "observations": {
    "rgb": [T, H, W, 3],
    "depth": [T, H, W],
    "joint_state": [T, J],
    "end_effector_pose": [T, 7]
  },
  "actions": {
    "delta_pose": [T, 7],
    "gripper": [T, 1]
  },
  "metadata": {
    "robot": "mobile_manipulator",
    "camera_calibration": "...",
    "success": true,
    "failure_reason": null
  }
}
```

数据闭环: 比单次训练更重要

成熟团队不会把数据采集看成一次性工程。更合理的流程是：先用遥操作和公开数据训练基础策略，再部署到受控场景收集失败，按失败类型重采样和标注，然后在仿真中扩大变体，最后做离线回归测试和小流量上线。每次模型更新都应该回答两个问题：它在哪些任务上变好，在哪些已知能力上退化。

FIGURE 2 ROBOT DATA FLYWHEEL




图 2: 机器人数据飞轮的核心是失败回流。没有失败样本，模型只是在重复熟悉动作。

数据质量的十个检查点

- 1. 相机、机器人本体和环境坐标是否可复现。
- 2. 成功与失败是否都被记录，而不是只留好看的轨迹。
- 3. 任务描述是否和实际动作对齐。
- 4. 动作空间是否一致，例如末端位姿、关节增量或离散 token。
- 5. 是否记录人类接管、急停和异常。
- 6. 不同物体、光照、背景、操作者、机器人个体是否覆盖。

7. 训练集、验证集和真实部署场景是否泄漏。
8. 标注是否只标结果，还是标失败原因。
9. 数据格式是否便于流式训练、检索和回放。
10. 每次模型更新是否能追溯到数据变更。

算法谱系：从模仿学习到 VLA 与世界模型

具身智能的算法不是单线进化。经典规划、控制理论、模仿学习、强化学习、多模态基础模型、世界模型和安全验证会长期共存。真正的系统能力来自组合，而不是某篇论文单独解决一切。

模仿学习：先让机器人学会像人一样做

模仿学习把人类演示映射为策略。最简单形式是行为克隆：输入观测，输出动作，用监督学习拟合。它的优点是稳定、工程简单、适合真实数据；缺点是遇到训练分布外状态时容易积累误差。ACT 把动作切成一段一段预测，适合低成本双臂遥操作数据；Diffusion Policy 用扩散模型生成动作序列，能表达多峰动作分布，适合接触丰富的操作。

强化学习：让系统从试错中优化

强化学习可以在仿真中大规模探索，适合运动控制、平衡、抓取策略和奖励明确的任务。问题是现实试错成本高，奖励设计难，仿真到现实存在差距。今天更常见的路线是：在仿真里训练低层技能或策略先验，再用真实数据微调，或者把强化学习用于局部能力而不是直接训练全栈通用机器人。

VLA：把看、说、做接到一个接口里

VLA 模型把视觉输入、语言指令和机器人动作放在同一建模框架下。RT-2 将视觉语言知识迁移到机器人控制；OpenVLA 和 Octo 推动开源复现；Physical Intelligence 的 π 系列强调跨机器人、跨场景泛化；Figure 的 Helix 把 VLA 用在人形机器人控制；Google Gemini Robotics 继续沿着多模态推理和物理行动扩展。这条路线的关键问题是：动作空间如何表示，跨硬件如何对齐，失败如何评测，安全边界如何注入。

方法	核心思想	适合阶段	主要短板
行为克隆	用演示数据监督学习动作	入门项目、受控任务	分布外状态恢复差
ACT	预测动作块，降低遥操作噪声	双臂、桌面操作、低成本硬件	依赖演示质量，长时任务仍难
Diffusion Policy	用扩散过程生成连续动作序列	接触丰富、多解操作	推理成本和稳定性需要工程优化
强化学习	通过奖励最大化学习策略	仿真训练、运动控制、局部技能	奖励设计、样本效率、安全成本
VLA	视觉、语言、动作统一建模	跨任务泛化、开放指令	数据规模、动作对齐、实时性
世界模型	预测环境未来状态，用于规划和生成数据	仿真增强、物理推理、策略验证	物理精度和长时预测误差
层级策略	高层选技能，低层执行动作	复杂长任务、可靠部署	技能边界和接口设计难

世界模型：让机器人先在脑内试一遍

世界模型的目标是预测动作会怎样改变环境。它可以用于三件事：生成训练数据，评估候选动作，帮助长期规划。NVIDIA Cosmos 和 Meta V-JEPA 2 都把物理世界建模作为重点方向。世界模型不能替代真实世界，因为接触、摩擦、材料形变和人类行为仍然难预测；但它能减少真实试错成本，并让系统在上线前看到更多边界场景。

层级智能：从“下一步动作”到“长期任务”

开放任务通常需要层级结构。高层负责理解目标，例如“整理桌面”；中层把目标拆成子任务，例如“识别垃圾、拿起杯子、归位书本”；低层负责连续控制，例如“夹爪闭合到合适力”。层级结构的价值是降低每一层的问题难度，也让系统更容易解释和回退。纯端到端策略有吸引力，但在商业部署里通常还需要规则、技能库和安全层共同工作。

一个实用判断：什么时候该用端到端，什么时候该用模块化

场景特征	更适合端到端	更适合模块化
数据量	同类任务有大量真实轨迹	数据少但规则清楚
任务变化	物体和动作组合多，规则难写	流程稳定，异常可枚举
安全要求	可在低风险环境充分试错	靠近人、贵重设备或危险物品
解释需求	允许黑盒策略，只看统计效果	需要审计、追责、合规和回滚
实时性	推理延迟可接受	低层控制需要毫秒级稳定

主流技术栈：从实验室到真实部署

具身智能技术栈横跨机器人、机器学习、系统工程和产品运营。入门时不要试图一次掌握所有工具。先理解每一层要解决什么，再按项目需要选择最小可行栈。

全栈清单


层	主流工具/框架	用途	入门优先级
机器人中间件	ROS 2、DDS、MoveIt 2	节点通信、传感器接入、运动规划	高
仿真	MuJoCo、NVIDIA Isaac Lab/Sim、ManiSkill、Habitat	物理模拟、数据生成、策略评估	高
控制	PID、MPC、阻抗控制、运动规划器	把目标位姿变成稳定动作	高
数据格式	RLDS、LeRobot dataset、HDF5、Parquet	轨迹存储、训练和回放	高
模型训练	PyTorch、JAX、Transformers、Diffusers	策略模型、VLA、扩散策略训练	高
开源机器人学习	LeRobot、OpenVLA、Octo、openpi	复现算法、微调模型、跑基线	高
感知	SAM 系列、GroundingDINO、VLM、点云网络、SLAM	物体、区域、姿态、地图和语义理解	中
部署	ONNX、TensorRT、Triton、Jetson、边缘 GPU	模型压缩、低延迟推理、设备部署	中
观测运维	日志、回放、指标平台、版本管理、远程接管	现场问题定位和策略迭代	高
安全	急停、碰撞检测、工作区限制、权限系统	保证模型不能越过物理和业务边界	高

三套入门栈

目标	硬件/仿真	软件栈	适合做的第一个项目
纯软件入门	MuJoCo 或 ManiSkill	Python、PyTorch、Gymnasium、LeRobot 数据格式	用行为克隆训练一个抓取或推方块策略
桌面机械臂	低成本机械臂加 RGB-D 相机	ROS 2、MoveIt 2、LeRobot、OpenCV	遥操作采集 100 条轨迹，训练 pick-and-place
移动操作	移动底盘加机械臂或仿真移动机械臂	ROS 2 Nav2、SLAM、任务规划、策略模型	让机器人按语言指令去指定区域抓取物体

推荐的最小项目架构

一个合理的入门项目不应该一上来做人形机器人。更可控的项目是桌面机械臂完成 3 到 5 类物体的抓取和放置。系统可以拆成六个节点：相机节点发布图像；标定节点维护相机到机械臂的变换；策略节点读取图像和指令输出末端位姿；规划节点调用运动规划；控制节点执行轨迹；日志节点记录每一步观测、动作和结果。



工程选型原则

- 1. 能用仿真复现的错误，不要直接拿真机试。
- 2. 能用传统控制稳定解决的低层问题，不要交给大模型赌运气。
- 3. 数据格式要先统一，再谈模型对比。
- 4. 每次训练都保留模型版本、数据版本和评测结果。
- 5. 任何可以伤人、撞设备或损坏物体的动作，都必须经过安全层。
- 6. 演示视频只是沟通材料，不是评测报告。

常见坑

坑	表现	修正方式
忽略标定	视觉识别对了，手总是偏	系统学习手眼标定、坐标变换和误差传播
只采成功样本	模型一偏离轨迹就崩	记录失败、接管和恢复过程
仿真调得过美	仿真成功率高，真机失败	域随机化、真实噪声回放、少量真机微调
把 LLM 当控制器	动作慢、抖动、不可控	LLM 负责任务层，控制层保持确定性
无回归测试	新模型修好 A，弄坏 B	建立固定场景、固定物体、固定指标的评测集

国内外大厂与创业公司工作图谱

产业版图可以按三条线看：做基础模型与平台的公司，做机器人本体和场景落地的公司，以及做数据、仿真、工具链和生态的公司。大厂强在算力、模型、平台和客户场景，创业公司强在专注硬件形态和高频迭代。

国际大厂与研究机构

机构	公开工作	核心方向	解读
Google DeepMind	RT-2、Open X-Embodiment/RT-X、Gemini Robotics、Gemini Robotics-ER 1.6	多模态推理到机器人动作，跨机器人数据复用	路线清晰：用基础模型承接语义和物理推理，再把动作接口接到真实机器人。
NVIDIA	Cosmos、Isaac、GR00T N1/N1.7、Jetson Thor、Omniverse 生态	物理 AI 平台、仿真、数据生成、模型和算力	不只做模型，更想成为机器人时代的训练和部署基础设施。
Meta	Habitat、PARTNR、V-JEPA 2	仿真环境、世界模型、物理推理和协作基准	Meta 更偏研究平台和表征学习，短期商业机器人动作较少。
Amazon	仓储机器人、Vulcan 触觉机器人	物流自动化、仓库操作、触觉抓取	场景封闭、数据密集、ROI 清晰，是具身智能最现实的落地区域之一。
Toyota Research Institute	Large Behavior Models，与 Boston Dynamics Atlas 协作	大行为模型、家务和操作任务	汽车厂背景决定其重视安全、可靠性和长期真实任务。
Boston Dynamics	电动 Atlas、Spot、Stretch	高性能运动控制和机器人平台	强项是本体和运动能力，正在与学习型模型结合。
Tesla	Optimus、车端 AI/仿真/制造体系	人形机器人、自动驾驶经验迁移、规模化制造	最大看点是能否把汽车数据工程、硬件供应链和真实工厂场景迁移到 Optimus。

国际创业公司

公司	公开工作	重点	观察点
Physical Intelligence	$\pi 0$ 、 $\pi 0.5$ 、 $\pi 0.7$ 、openpi	跨机器人通用策略和可控 VLA	代表“先做通用策略模型，再接多种身体”的路线。
Figure AI	Figure 02/03、Helix、Helix 02、BMW 场景	人形本体加端到端 VLA 控制	看点是工厂部署数据能否形成持续飞轮。
Agility Robotics	Digit、GXO/RaaS 部署	物流搬运和人形商业化	比家庭场景更聚焦，商业路径更务实。
Apptронik	Apollo，2025 年宣布大额融资并披露 Google 相关合作	通用人形机器人平台	需要观察本体量产、应用场景和模型生态。
1X	NEO 家用机器人	家庭人形助手	家用场景价值高但开放度极高，可靠性和售后是核心挑战。
Skild AI	通用机器人“大脑”路线	跨本体 foundation model	强调从多形态机器人数据中学习通用策略。

中国公司与生态

机构/公司	公开工作	重点	解读
智元机器人 AGIBOT	AgiBot World 2026、X2、MWC 2026 全系列展示	本体、数据集、开源生态和多产品线	国内少数同时强调真实数据、硬件产品和生态建设的玩家。
宇树科技 Unitree	G1、人形/四足硬件、SDK 和开源页面	高性价比硬件、开发者生态	其优势是硬件可获得性和成本，对教育、研究和开发者扩散有帮助。
优必选 UBTECH	Walker S1/S2、工业人形机器人公开订单与交付信息	工业制造场景和人形机器人产品化	更靠近应用交付，关键在稳定量产和场景复用。
腾讯 Robotics X / 混元视觉团队	HY-Embodied-0.5 模型与论文	具身基础模型、真实世界智能体	大厂模型能力向具身接口延展的代表。
阿里巴巴	开源具身基础模型相关披露	多模态模型与机器人推理/控制结合	大模型生态会自然向机器人数据和动作接口延伸。
政策与标准体系	2026 年公开的中国人形机器人与具身智能标准框架	基础术语、安全、性能、接口与应用规范	标准化会影响量产、验收、认证和采购，不能只看模型论文。

如何读懂公司宣传

判断一家机器人公司，不要只看“通用”“量产”“端到端”这些词。应该问六个问题：机器人在哪个真实场景连续运行；任务成功率如何定义；失败由谁处理；数据是否能回流训练；硬件成本和维护成本是多少；安全事故由什么机制兜底。能回答这些问题的公司，比只展示剪辑视频的公司更值得认真看。

产业格局一句话

2026 年的具身智能还没有进入“赢家通吃”阶段。平台型大厂在模型、仿真和算力上占优，硬件公司在真实数据和场景上占优，真正的壁垒会在两者结合处形成。

发展方向：未来三到五年的关键赌点

具身智能未来不是单点突破，而是多条技术线同时推进。下面这些方向会决定这个领域从演示走向产业化的速度。

方向一：跨本体通用策略

不同机器人有不同关节、相机、夹爪和动作空间。跨本体学习要解决的是：能否从一种机器人学到的能力迁移到另一种机器人。Open X-Embodiment、Octo、OpenVLA、Physical Intelligence 的 π 系列、NVIDIA GR00T 都在不同程度上处理这个问题。成功的关键是动作表示标准化、机器人状态对齐、任务语义对齐和足够多样的数据。

方向二：世界模型与合成数据

真实机器人数据贵，仿真数据便宜但不完全真实。世界模型试图在两者之间搭桥：用视频和物理先验预测未来，让机器人先在模型里尝试，再选择真实动作。短期内，它更可能用于训练数据扩增、危险场景生成和动作候选评估，而不是完全替代物理仿真或真机实验。

方向三：灵巧操作和触觉

抓一个方块和系鞋带不是同一个问题。开放世界里的高价值任务往往需要接触、滑动、挤压、插入、旋转和双手协调。仅靠 RGB 图像很难判断接触状态，触觉和力反馈会变得更重要。Amazon Vulcan 公开强调触觉能力，也说明工业场景已经开始重视“手感”而不是只看视觉抓取。

方向四：长时任务和记忆

短视频演示常常只展示 10 到 60 秒任务，真实应用需要数分钟到数小时的连续运行。长时任务需要任务记忆、环境记忆、失败恢复、资源管理和用户偏好。模型必须知道自己已经做过什么，哪些状态已改变，哪些目标仍未完成。

方向五：安全、合规与责任边界

机器人进入工厂、医院、门店和家庭后，风险不再是论文指标。速度限制、力限制、数据隐私、人机共处、远程接管、日志审计、责任归属和标准认证都会成为商业化前置条件。中国 2026 年公开的相关标准框架也说明，具身智能正在从研究话题进入产业治理阶段。

方向六：低成本硬件和开发者生态

模型进步需要更多真实数据，而真实数据需要更多人能买得起、修得起、改得动机器人。低成本机械臂、人形开发平台、开源 SDK、LeRobot 这类开源工具和公开数据集会降低入门门槛。硬件成本下降不是附属变量，而是数据规模化的前提。

技术赌点矩阵

赌点	如果成功	如果失败	最该跟踪的指标
VLA 泛化	新物体、新指令学习成本下降	每个场景仍需重采数据	少样本成功率、跨场景评测
世界模型	仿真和真实之间的数据缺口缩小	合成数据只能做视觉增强	预测误差、真机迁移收益
触觉和力控	装配、整理、工具使用能力提升	仍停留在简单抓放	接触任务成功率、损坏率
人形量产	本体成本下降，更多场景可测试	数据和部署规模受限	BOM、维护成本、连续运行小时数
标准化	采购、验收、数据格式和安全测试更清晰	各家系统继续割裂	接口标准、测试基准、认证流程

0 到 1 学习路线：怎样真正入门

具身智能入门不能只读论文，也不能只搭硬件。最稳的路线是：先理解机器人基本约束，再用仿真跑通闭环，然后采集真实数据训练小策略，最后接触 VLA 和世界模型。

前置知识

方向	必须掌握	够用标准	不必一开始深挖
Python 与深度学习	PyTorch、数据集、训练循环、调参	能训练并调试一个视觉模型	分布式训练细节
机器人基础	坐标变换、运动学、控制、ROS 2 基础	能解释相机坐标如何变成机械臂目标位姿	复杂动力学推导
计算机视觉	相机模型、目标检测、分割、深度图	能从图像里定位目标并给出 3D 点	所有 SOTA 模型细节
机器学习策略	行为克隆、强化学习、扩散策略	能说清每种方法适合什么数据	复杂证明
系统工程	日志、版本、回放、测试、部署	能复现一次失败并定位层级	大型云平台架构

十二周学习计划

阶段	目标	任务	验收标准
第 1-2 周	建立机器人直觉	学习坐标系、运动学、ROS 2 节点通信；用 MuJoCo 跑一个机械臂环境	能画出传感器到动作的闭环，并解释每个坐标系
第 3-4 周	跑通仿真策略	用行为克隆训练一个简单抓取或推物体任务	有固定评测集和成功率记录
第 5-6 周	理解数据工程	把轨迹保存成统一格式，写回放工具，记录失败原因	任意一次失败可以从日志重放
第 7-8 周	接触真实设备或更真实仿真	采集遥操作数据，训练 ACT 或扩散策略基线	模型能在未见过的物体摆放上完成任务
第 9-10 周	接入语言和视觉	用 VLM 做目标定位，用语言指令选择任务	能从 3 条不同指令选择对应物体和放置区域
第 11-12 周	做系统复盘	整理评测、失败分类、改进计划和安全边界	形成一份可复现项目报告，而不是只留视频

第一个完整项目：桌面抓放系统

项目目标：机器人根据指令把指定物体放到指定区域。硬件可以是真实低成本机械臂，也可以是仿真环境。最小版本只需要 RGB-D 相机、机械臂状态、末端位姿和夹爪开合。不要一开始追求“通用家务”，先让一个小任务可评测、可回放、可改进。

- 定义 3 类物体和 2 个放置区域。
- 采集 50 到 200 条遥操作轨迹，记录成功和失败。
- 训练行为克隆基线，输入图像和指令，输出末端位姿增量。
- 加入固定评测集：不同光照、不同物体位置、不同背景。
- 统计成功率、失败原因和平均完成时间。
- 再尝试 ACT、扩散策略或 OpenVLA/LeRobot 相关基线。

论文和资料阅读顺序

顺序	主题	推荐资料	读的时候看什么
1	机器人学习总览	Open X-Embodiment、DROID	数据如何组织，跨机器人为什么难
2	模仿学习	ACT、Diffusion Policy、LeRobot 示例	动作表示和误差累积
3	VLA	RT-2、OpenVLA、Octo、 $\pi 0$	视觉语言知识如何变成动作
4	世界模型	Cosmos、V-JEPA 2	预测未来和真实物理之间的差距
5	产业落地	Figure、NVIDIA、Amazon、UBTECH、AGIBOT 等官方资料	场景、数据、成本和安全如何表述

入门判断标准

当你能独立解释一次失败来自感知、数据、策略、控制还是硬件，并能设计下一轮实验去验证，你才算真正进入具身智能的工程语境。

前景判断：机会、限制与风险

具身智能的长期空间很大，但短期落地会比大众想象更克制。它不是“模型一强，机器人马上进家”的问题，而是成本、可靠性、责任、安全和服务网络共同决定的产业化问题。

最可能先落地的场景

场景	为什么可能先落地	主要阻力	能力门槛
仓储物流	任务重复，环境相对可控，ROI 容易算	高峰期稳定性和异常处理	搬运、分拣、货架操作、触觉抓取
制造辅助	工位固定，数据可采，客户愿为效率付费	节拍、安全认证、维护成本	上下料、质检、简单装配、工具递送
实验室自动化	流程标准，样本贵，自动化价值明确	液体、耗材、污染和精细操作	抓取、移液、开关设备、记录流程
商业服务后场	人力短缺，任务有限，可半封闭部署	空间狭窄，人机混行	清洁、补货、配送、整理
家庭	潜在市场大，任务价值直观	开放世界、偏好差异、隐私和售后	长时记忆、通用操作、安全共处

市场预测怎么看

Goldman Sachs 曾给出到 2035 年人形机器人市场规模可达 380 亿美元的预测，IFR 的 World Robotics 2025 则提供工业机器人需求和安装趋势。此类数字有参考价值，但不能替代具体场景的 unit economics。更实用的测算方式是：机器人每小时综合成本、可替代或增强的人工时长、停机和维护成本、场景改造成本、安全事故成本，以及部署后能否持续产生新数据。

职业机会

方向	核心能力	适合背景	作品集建议
机器人学习工程师	策略训练、数据处理、评测	机器学习、计算机视觉	公开一个可复现仿真到真实项目
机器人系统工程师	ROS、控制、传感器、部署	机器人、自动化、嵌入式	展示完整闭环和故障定位能力
VLA/多模态研究	基础模型、动作表示、跨本体泛化	大模型、多模态、强化学习	微调开源 VLA 并做严格评测
仿真与数据平台	物理引擎、合成数据、回放系统	图形学、后端、ML infra	做一个可复现的数据飞轮 demo
产品与解决方案	场景拆解、ROI、安全流程	行业运营、自动化实施	写出场景任务树和验收指标

主要风险

1. 演示泡沫。剪辑视频会放大能力，掩盖失败率和人工干预。
2. 硬件成本下降慢。如果本体价格、维护和能耗降不下来，很多场景无法算账。
3. 数据闭环难建立。没有高频真实场景，模型迭代会停在论文或实验室。

4. 安全事故影响信任。机器人一旦进入人类空间，单次事故可能拖慢整个品类。
5. 标准割裂。不同硬件、数据格式和动作接口不统一，会降低生态复用效率。

长期判断

具身智能会先成为“高价值场景里的自动化增量”，再逐步走向“通用身体助手”。2026 年最值得关注的不是谁宣称通用，而是谁能在真实场景里持续采集数据、稳定降低失败率，并把一次部署经验复用到下一批场景。技术热度会波动，但机器人进入物理世界工作的方向不会逆转。

术语表、阅读清单与参考资料

核心术语表

具身智能：智能体通过身体与环境交互，在感知、行动和反馈中完成任务的能力。	Sim-to-Real：把仿真中学到的策略迁移到真实机器人的过程。
VLA: Vision-Language-Action，把视觉、语言和动作统一建模的机器人模型接口。	域随机化：在仿真中随机改变纹理、光照、摩擦、质量等，提高迁移能力。
世界模型：预测环境未来状态的模型，用于规划、数据生成或策略评估。	末端执行器：机器人与环境直接交互的部件，例如夹爪、手、吸盘。
模仿学习：从人类或专家演示中学习策略的方法。	位姿：位置和姿态的组合，常用于描述机器人末端或物体状态。
行为克隆：把策略学习转成监督学习，输入观测，输出动作。	阻抗控制：控制机器人与环境接触时的力和柔顺性。
扩散策略：用扩散模型生成动作序列，适合表达多种可行动作。	技能库：可复用的动作模块，例如抓取、放置、开门、导航。
遥操作：人远程控制机器人，用于任务执行或数据采集。	回归测试：用固定任务集检查新模型是否破坏已有能力。

推荐阅读路线

1. 先读 ROS 2、MuJoCo、LeRobot 文档，建立工具直觉。
2. 再读 DROID、Open X-Embodiment，理解机器人数据为什么难。
3. 接着读 RT-2、OpenVLA、Octo 和 Physical Intelligence π 系列，理解 VLA 路线。
4. 补读 NVIDIA Cosmos、GR00T、Meta V-JEPA 2，理解平台和世界模型方向。
5. 最后看 Figure、Amazon、AGIBOT、UBTECH、Unitree 等资料，训练自己从商业场景读技术。

参考资料

完整来源见同目录 sources.md 与 data/source-map.tsv。以下列出正文最核心的公开资料。

1. Google DeepMind, RT-2: <https://deepmind.google/blog/rt-2-new-model-translates-vision-and-language-into-action>
2. Open X-Embodiment: <https://arxiv.org/abs/2310.08864>
3. Gemini Robotics: <https://deepmind.google/blog/gemini-robotics-brings-ai-into-the-physical-world/>
4. Gemini Robotics-ER 1.6: <https://deepmind.google/blog/gemini-robotics-er-1-6/>
5. OpenVLA: <https://openvla.github.io/>
6. Octo: <https://github.com/octo-models/octo>
7. Physical Intelligence $\pi 0.7$: <https://www.pi.website/blog/pi07>
8. NVIDIA Cosmos: <https://nvidianews.nvidia.com/news/nvidia-launches-cosmos-world-foundation-model-platform-to-accelerate-physical-ai-development>
9. NVIDIA GR00T N1: <https://nvidianews.nvidia.com/news/nvidia-isaac-gr00t-n1-open-humanoid-robot-foundation-model-simulation-frameworks>
10. Figure Helix: <https://www.figure.ai/news/helix>

11. Amazon Vulcan: <https://www.aboutamazon.eu/news/company-news/introducing-vulcan-amazons-first-robot-with-a-sense-of-touch>
12. AGIBOT World 2026: <https://www.agibot.com/article/231/detail/54.html>
13. UBTECH Walker S2: <https://www.ubtrobot.com/en/humanoid/products/WalkerS2>
14. Tencent HY-Embodied-0.5: <https://huggingface.co/tencent/HY-Embodied-0.5>
15. ROS 2 docs: <https://docs.ros.org/>
16. MuJoCo docs: <https://mujoco.readthedocs.io/en/stable/overview.html>
17. LeRobot: <https://github.com/huggingface/lerobot>
18. Stanford AI Index 2025: https://hai.stanford.edu/assets/files/hai_ai_index_report_2025.pdf

最后的学习建议

具身智能看上去很宽，但入门路径可以很窄：选一个小任务，建立可复现实验，认真记录失败，逐步替换感知、策略、控制和数据模块。不要急着追“通用机器人”，先把一个具体任务从演示做成可统计、可回放、可迭代的系统。能做到这一点，就已经走过了从 0 到 1 最关键的一步。