

生成式推荐技术全史与产业落地报告

从协同过滤、深度排序、序列建模到语义 ID、生成式检索、LLM 推荐、扩散推荐和推荐智能体的系统性报告，面向希望从 0 到 1 建立完整认知并能进入工程落地讨论的读者。

Winston

资料口径截至 2026-05-15

Primary papers · official engineering sources · public industrial systems

| 目录

01	执行摘要	为什么 GR 是推荐范式变化，不只是 LLM 接口
02	概念边界	推荐系统、生成式推荐、生成式检索的关系
03	发展史	从协同过滤到基础模型推荐
04	推荐系统基本功	目标、反馈、召回、排序、重排和评估
05	经典与深度算法	MF、FM、Wide & Deep、DIN、MIND、SASRec、DLRM
06	生成式推荐算法谱系	语义 ID、序列转导、LLM、扩散、生成式重排
07	语义 ID 与生成式检索	把候选集搜索改写成 token 生成
08	LLM、扩散与多模态推荐	模型能力如何进入推荐链路
09	海外大厂实践	Google、Meta、Amazon、Netflix、Pinterest
10	国内大厂实践	Alibaba、ByteDance、Kuaishou、Tencent 等
11	工程落地方法	从离线实验到线上系统的路线图
12	评估、治理与风险	指标、A/B、偏差、隐私、安全和内容生态
13	趋势判断	2026 之后的主线和开放问题
14	附录	阅读路径、术语表和来源映射

01 · EXECUTIVE SUMMARY

执行摘要

生成式推荐(Generative Recommendation, GR)不是“用大模型写推荐理由”的窄概念,而是把推荐链路中的候选生成、偏好建模、列表决策、内容理解、解释交互和新内容生成逐步改写为**生成任务**。它继承推荐系统的工程约束,也引入基础模型的 token 化、序列建模、对齐、推理成本和安全治理问题。

FINDING 01

推荐系统仍是三段式工程

召回、排序、重排和策略层不会因为 GR 消失。变化在于:召回可以由模型生成候选标识,排序可以吃更长行为序列,重排可以直接优化列表,交互层可以理解自然语言意图。

FINDING 02

语义 ID 是 GR 的关键接口

商品、视频、广告和内容不能直接放进 LLM 词表。语义 ID 将物品压缩成低基数离散 token,使生成模型能“说出”物品,同时保留内容语义和协同信号。

FINDING 03

大模型推荐有四种落点

LLM 可做特征增强、用户理解、候选生成、解释对话和模拟器。线上主链路是否直接调用 LLM,取决于延迟、成本、候选规模、可控性和安全要求。

FINDING 04

产业主线不是单模型替代

Meta 的 HSTU、Google 的 TIGER、Pinterest 的 PinRec、淘宝 AIGQ、快手 OneMall、腾讯 TencentGR 共同指向一个方向:用生成式建模重构部分推荐环节,而非一次性替换全系统。

FINDING 05

实时性仍决定上限

ByteDance Monolith 说明推荐系统对新反馈、稀疏特征和概念漂移极端敏感。GR 若不能和实时样本、近线训练、特征服务、索引更新协同,离线提升很难转化为线上收益。

FINDING 06

治理问题会更难

GR 不仅推荐已有内容,还可能生成查询、广告创意、解释、图像或完整购物路径。偏见、过滤气泡、版权、安全、广告合规和可申诉性会从排序问题扩大为生成问题。

本文回答的核心问题

- 推荐系统为什么从“打分排序”走向“生成候选、生成列表、生成解释和生成内容”?
- 语义 ID、生成式检索、HSTU、LLM 推荐、扩散推荐各自解决什么问题,彼此如何组合?
- Google、Meta、Alibaba、ByteDance、Kuaishou、Tencent 等公开材料说明了哪些可落地路径?
- 企业要引入 GR 时,应如何设定实验、指标、系统边界和风险控制?

阅读建议

如果读者没有推荐系统背景,先读第 2 至第 5 章;如果已经熟悉召回排序链路,可直接读第 6 至第 8 章;如果目标是产业落地,重点读第 9 至第 12 章。附录给出术语表和来源编号,可作为后续复核入口。

概念边界

讨论 GR 前，必须先把“推荐系统”“生成式推荐”“生成式检索”和“LLM 推荐”拆开。概念混用会导致错误预期：把聊天式购物助手当作完整推荐系统，或把语义 ID 召回当作全部生成式推荐。


四个层级

概念	简明定义	核心对象	典型输出	常见误解
推荐系统	在给定用户、上下文、候选库和业务目标下，选择并排序最合适的物品或动作。	用户、物品、上下文、反馈、策略。	候选集、排序列表、页面布局、通知、广告。	只等于一个排序模型；忽略召回、策略、实验和反馈闭环。
生成式推荐	把推荐链路中的候选、列表、解释、查询、内容或交互动作表述为生成问题。	离散 token、语义 ID、行为序列、自然语言、多模态内容。	物品 ID 序列、推荐列表、解释文本、个性化内容、任务动作。	只等于把 LLM 接到推荐页。
生成式检索	用序列模型直接生成目标文档或物品的标识，而不是先向量召回再 ANN 搜索。	文档 ID、物品 ID、语义 ID、树状 ID。	一个或多个候选标识。	一定会完全替代向量检索；现实中常与 ANN 和规则召回混合。
LLM 推荐	使用大语言模型进行用户理解、特征增强、候选生成、重排、解释、对话或仿真。	文本、行为描述、item metadata、prompt、tool。	推荐理由、候选标题、排序判断、对话回复、用户画像。	LLM 直接对全库逐项打分即可上线；现实中成本和延迟通常不允许。

生成式推荐的四种实际含义

- 第一种是生成候选：模型根据用户行为序列生成下一个物品的离散标识。TIGER 把物品表示成语义 ID，再用序列到序列模型预测下一物品 ID，是这一方向的标志性工作 [S18]。
- 第二种是生成用户行为：把用户动作当作语言，建模“下一次点击、播放、购买、停留、跳过”。Meta 的 HSTU 论文把大规模推荐表述为序列转导任务，并声称在公开和生产场景观察到随训练计算量扩展的规律 [S20]。
- 第三种是生成推荐表达：LLM 输出解释、比较、问答、购物路径、查询改写或广告创意。它提升交互和冷启动，但对主排序链路的延迟、事实性和安全性提出更高要求。
- 第四种是生成可消费内容：系统不只推荐已有视频、图片、商品页或广告，还能按用户偏好生成素材、摘要、封面、标题或组合商品。这是推荐和 AIGC 最深的交汇处，也是版权与生态治理最敏感的区域。

FIGURE 1 GR IN THE RECOMMENDER PIPELINE



GR 插入推荐系统的多个位置，而不是单点替换召回或排序。

03 · HISTORY

发展史

推荐系统的发展可以理解为一 条主线：系统不断寻找更好的方式表示“人、物品、上下文、反馈和目标”。生成式推荐的出现，不是跳出这条线，而是把表示学习、序列建模和基础模型能力汇合到同一个可生成接口上。

从协同过滤到 GR 的阶段划分

阶段	代表思想	关键模型或系统	解决的问题	遗留问题
1990s	协同过滤	用户邻域、物品邻域、显式评分预测。	不用理解内容，只根据相似用户或相似物品推荐。	稀疏、冷启动、规模化和实时更新困难。
2003-2009	工业化相似物品与矩阵分解	Amazon item-to-item、Netflix Prize、SVD、ALS、隐式反馈 MF [S01][S02]。	把大规模用户物品矩阵压缩成低维向量，显著改善稀疏评分预测。	难表达上下文、多目标、短期兴趣和内容语义。
2010-2016	大规模特征工程与深度排序	LR/GBDT/FM/FFM、DSSM、Wide & Deep、YouTube DNN [S03][S04]。	将稀疏特征、交叉特征和 embedding 引入线上 CTR/CVR 预测。	手工特征重、用户兴趣常被压成定长向量。
2017-2020	兴趣建模和序列建模	DeepFM、NCF、DIN、DIEN、MIND、SIM、SASRec、BERT4Rec [S05-S12]。	捕捉多兴趣、兴趣演化、长行为序列和候选相关激活。	仍以判别式打分为主，物品 ID 与语义之间存在断层。
2018-2022	图、实时、系统规模化	PinSage、DLRM、TorchRec、Monolith [S13-S16]。	图结构、超大 embedding、近实时训练、生产平台化。	模型越大，工程复杂度越高；推荐模型 scaling law 仍不清晰。
2022-2024	语言化推荐与生成式检索	P5、Chat-REC、TALLRec、TIGER、HSTU [S17-S20][S25-S28]。	把任务、物品、用户和反馈转成 token 序列，探索推荐基础模型。	延迟、候选规模、无效生成、语义 ID 质量和在线稳定性。
2024-2026	多模态、扩散、产业 GR	PinRec、OneMall、AIGQ、TencentGR、扩散推荐综述 [S23][S24][S32-S36]。	工业数据集、广告和电商场景、生成式重排、查询生成、多模态 token。	统一评估、系统互操作、合规和生成内容生态治理。

为什么 2023 之后 GR 突然变得重要

- 第一，推荐对象变复杂。短视频、直播、广告、商品、服务、搜索 query、笔记、长视频、AI 生成素材都进入同一用户时间线。单个 item ID 已经难以承载内容理解、跨域泛化和冷启动。
- 第二，行为序列变长。Meta HSTU 论文强调大规模推荐面对高基数、异质特征和每天数百亿级用户动作，需要处理更长、更非平稳的行为序列 [S20]。这和语言模型处理长上下文的技术路线发生共振。
- 第三，交互方式变化。用户不只点击推荐，还会用自然语言表达“帮我找适合通勤的降噪耳机”“不要再推这个主题”“给我更短的视频”。传统推荐系统擅长从隐式反馈中学习，不擅长直接理解和执行这种指令。

第四，内容生产被生成模型改变。当平台可以生成标题、封面、广告创意、商品描述和短视频时，推荐系统不再只是从固定库中选择，还要决定生成什么、给谁生成、何时生成、如何评估生成后的真实价值。

04 · FUNDAMENTALS

推荐系统基本功

任何 GR 方案都必须回到推荐系统基本功：目标函数、反馈数据、候选库、召回排序重排、线上实验和反馈闭环。忽略这些约束，生成模型会给出漂亮的离线样例，却很难稳定改善真实业务。

推荐问题的抽象

在时间 t ，系统观察用户 u 、上下文 c_t 、历史行为 H_u 和候选集合 I ，输出一个列表 $L_t = [i_1, i_2, \dots, i_k]$ 。目标不是“预测用户喜欢什么”这么简单，而是在点击、停留、转化、满意度、商家收益、内容生态、安全和长期留存之间做约束优化。

```
score(u, i, c) = E[utility | user=u, item=i, context=c, history=H_u]
ranked_list = argmax_L \sum position_weight(j) * utility(u, L[j], c)
subject to: policy constraints, diversity, freshness, safety, inventory, latency
```

反馈信号的层次

信号	例子	优点	风险	GR 下的新问题
显式反馈	评分、点赞、收藏、不感兴趣。	语义清晰，解释性强。	覆盖率低，用户表达有偏。	自然语言偏好可加入，但需要解析、记忆和冲突处理。
隐式反馈	曝光、点击、播放、停留、购买、跳过。	规模大，接近真实行为。	位置偏差、选择偏差、曝光偏差。	生成候选改变曝光分布，离线日志的反事实问题更严重。
序列反馈	一次 session 中的点击、搜索、加购、成交。	能表达短期意图和兴趣演化。	噪声、突发事件、多人共用账号。	长序列建模成本上升，需要区分稳定偏好和临时意图。
文本反馈	评论、搜索词、对话指令、申诉。	能表达原因和约束。	事实性、讽刺、歧义、语言差异。	LLM 可解析，但解析结果必须能回写到可控策略。
生成反馈	对生成解释、生成封面、生成商品组合的反应。	能直接评估生成内容价值。	新颖性与误导性混杂。	推荐系统需要同时学习“推荐什么”和“生成什么”。

召回、排序、重排和策略层

召回从百万到十亿级候选库中取回数百到数千个候选。传统路线包括 item-to-item、向量召回、图召回、规则召回、搜索召回和热度召回。GR 的生成式检索试图让模型直接生成候选 ID，但生产上常与其他召回源融合。

排序对候选进行精细打分。主流模型处理稀疏特征、连续特征、上下文、历史行为、候选特征和多目标标签。Wide & Deep、DeepFM、DIN、DIEN、DLRM 都属于这一脉络。

重排关心列表整体，而非单个 item。它处理多样性、去重、疲劳、商家公平、预算、广告频控和页面结构。生成式重排把列表当作序列生成或序列决策，能更自然地表达全局约束。

策略层连接模型输出和产品规则。安全、隐私、合规、广告预算、库存、冷启动扶持、内容治理和商业化目标都在这一层显性化。GR 增强模型能力，但不会取消策略层。判断推荐系统是否成熟，不能只看模型结构；真正的成熟度体现在特征和样本是否可追溯、召回源是否可解释、排序指标是否和长期价值一致、线上实验是否能隔离偏差、策略变化是否能快速回滚。

05 · CLASSICAL AND DEEP MODELS

经典与深度算法

理解 GR 不能跳过传统推荐算法。许多生成式方法的目标、数据和工程接口都来自经典推荐：矩阵分解定义了协同信号，DSSM 和双塔定义了向量召回，DIN/DIEN 定义了候选相关兴趣，SASRec/BERT4Rec 定义了行为序列语言化的早期形态。

经典算法族

算法族	核心思想	代表方法	优势	局限
邻域协同过滤	相似用户喜欢相似物品，或相似物品被相似用户喜欢。	UserCF、ItemCF、Amazon item-to-item [S01]。	直观、可解释、工程实现早期成熟。	稀疏和冷启动严重；实时重算和跨域泛化困难。
矩阵分解	把用户和物品映射到低维隐空间，通过内积预测偏好。	SVD、ALS、BPR、隐式反馈 MF、Netflix Prize [S02]。	协同信号强，训练和存储相对高效。	难处理复杂上下文、非线性特征和多模态内容。
因子分解机	用低维向量表示稀疏特征交叉。	FM、FFM、DeepFM [S05]。	适合广告和 CTR 稀疏特征场景。	高阶交互和序列兴趣需要深度结构补充。
Learning to Rank	把推荐看作排序优化。	Pointwise、Pairwise、Listwise、LambdaMART。	和线上列表目标更接近。	候选生成和长期价值仍需单独处理。
上下文与 bandit	在探索和利用之间平衡，在线学习反馈。	Contextual bandit、多臂老虎机、广告和封面测试。	适合冷启动、创意选择和动态流量。	探索成本真实存在，安全和业务约束强。

深度推荐算法族

方向	代表模型	解决的问题	和 GR 的关系
宽深结合	Wide & Deep、DeepFM、xDeepFM、DCN。	记忆高频交叉，同时泛化低频组合。Google Wide & Deep 在 Google Play 场景公开验证 [S03]。	仍是判别式打分，但 embedding 与特征交叉是 GR 的基础输入。
神经协同过滤	NCF、AutoRec、MultVAE。	用非线性结构替代纯内积，或用生成模型重构用户行为。	VAE 类方法是早期“生成式推荐”的前史。
双塔召回	DSSM、YouTube candidate generation、two-tower。	用户塔和物品塔分别编码，再用向量相似度召回。	生成式检索首先挑战的就是“向量召回 + ANN”范式。
候选相关兴趣	DIN、DIEN、DSIN、SIM。	用户兴趣不是固定向量，而应随候选 item 激活。DIN 和 DIEN 均来自 Alibaba 公开工作 [S07][S08]。	GR 中的 prompt、query 和候选生成也需要条件化用户兴趣。
多兴趣召回	MIND、ComiRec。	一个用户有多个兴趣簇，用多个向量召回不同方向 [S09]。	语义 ID 可进一步把多个兴趣方向转成可生成 token。
序列推荐	GRU4Rec、SASRec、BERT4Rec。	将历史行为按序列建模，预测下一物品或 mask 物品 [S11][S12]。	这是 HSTU、TIGER 和自回归 GR 的直接前置技术。
图推荐	PinSage、LightGCN、异构图召回。	利用用户、物品、内容、社交和行为图结构。PinSage 是 Pinterest 的网页规模 GCN 推荐实践 [S13]。	图 embedding 可作为语义 ID 学习和多模态 token 化的输入。
超大 sparse 模型	DLRM、TorchRec、Monolith。	处理高基数稀疏特征和超大 embedding 表 [S14-S16]。	GR 若进入主链路，必须面对同等的稀疏、实时和规模问题。

从判别式到生成式的分水岭

传统深度推荐通常学习 $p(y|u, i, c)$ ：给定用户、物品和上下文，预测点击、转化或满意度。生成式推荐倾向于学习 $p(i|u, c)$ 、 $p(list|u, c)$ 或 $p(action|u, c, instruction)$ ：直接生成候选、列表或动作。二者不是互斥关系。生产系统更可能采用混合式：生成式召回提供一部分候选，判别式 ranker 精排，多目标重排控制最终页面。

判别式推荐擅长什么

对给定候选做稳定打分，融入复杂业务特征，满足低延迟和可控上线要求。CTR、CVR、观看时长、GMV、留存等指标仍主要依赖判别式模型。

生成式推荐补上什么

减少人工召回路径，改善冷启动和长尾泛化，统一多任务表达，利用长行为序列和自然语言意图，并让系统具备解释、对话和生成内容的能力。

06 · GR TAXONOMY

生成式推荐算法谱系

GR 不是单一算法，而是一组把推荐问题语言化、token 化、序列化和生成化的方法。最重要的区分不是“是否用了 LLM”，而是生成对象是什么：物品标识、行为序列、列表、解释、查询、广告创意还是完整交互动作。

六类主流路线

路线	生成对象	代表工作	适用位置	主要挑战
语义 ID 生成式检索	物品的离散 token 序列。	TIGER、Semantic IDs、PinRec、TencentGR [S18][S19][S23][S24]。	召回、跨域召回、冷启动。	ID 学习质量、无效 ID、beam 成本、候选覆盖、索引更新。
序列转导式推荐	下一行为、下一物品、未来 action 序列。	HSTU、M-FALCON、Meta generative recommenders [S20][S21]。	长序列行为建模、基础推荐模型。	训练成本、在线延迟、非平稳数据、系统可解释性。
LLM 增强推荐	文本画像、推荐理由、候选、排序判断、对话。	P5、Chat-REC、TALLRec、GenRec、LLMRec [S25-S30]。	冷启动、解释、对话、query 理解、特征增强。	事实性、成本、延迟、幻觉、私域数据安全。
扩散推荐	用户偏好向量、交互矩阵、候选分布、生成素材。	DiffRec、Diffusion recommender surveys [S31][S32]。	数据增强、去噪表示、序列/图推荐、内容展示。	采样效率、离散物品建模、线上服务复杂度。
生成式重排	完整列表或列表编辑动作。	Taobao generative re-ranking [S35]。	多目标列表优化、广告和电商页面。	列表级评估、约束满足、与 ranker 和策略层协调。
生成内容推荐	标题、封面、广告创意、商品描述、个性化内容。	GeneRec、GEMRec、Meta GEM 相关材料 [S17][S36][S39]。	广告创意、内容个性化、购物助手。	内容质量、版权、误导、品牌安全和生态激励。

GR 的数据形态

传统推荐样本通常是 (user, item, context, label)。GR 样本会变成序列：
[user tokens, context tokens, history item tokens, instruction tokens] -> [target item tokens or action tokens]。一旦进入这种格式，推荐系统开始继承语言模型训练中的问题：tokenizer 设计、长度截断、mask、teacher forcing、beam search、无效 token、对齐数据和推理约束。

GR 的训练目标

目标	形式	适合场景	注意点
下一物品预测	最大化 $p(\text{SID}_i \mid \text{history})$ 。	序列召回、session 推荐。	离线 Recall/NDCG 不等于线上收益；要控制曝光偏差。
多目标行为预测	预测点击、转化、停留或多种 action token。	广告、内容流、电商。	不同目标存在冲突，需在训练和重排中显式建模。
文本到推荐	从自然语言需求生成候选或解释。	对话推荐、搜索推荐、购物助手。	自然语言和物品库之间要有可验证 grounding。
列表生成	自回归生成一组 item 或位置动作。	多样性、搭配、页面布局。	需要避免重复、无效 item 和策略约束违反。
去噪与重构	从加噪偏好或交互恢复真实偏好分布。	扩散推荐、鲁棒表示。	采样步数和线上延迟要可控。

核心判断

GR 的价值不在“生成”这个词本身，而在它是否降低召回碎片化、提高长尾泛化、吸收多模态语义、利用长序列行为、支持自然语言控制，并且能在真实延迟和成本约束下通过线上实验。

07 · SEMANTIC IDS

语义 ID 与生成式检索

语义 ID 是当前 GR 最重要的技术接口之一。它解决的不是“给物品重新编号”这么简单，而是把物品从不可学习的高基数 ID，变成模型能生成、能组合、能泛化的离散语义 token。

为什么原始 item ID 不适合生成

推荐平台的 item 数可以达到百万、千万甚至更高。若把每个 item 当作一个 token，词表过大、冷启动困难、相似物品没有共享结构。若直接让 LLM 输出商品标题或视频标题，又会出现标题歧义、重复命名、库外生成和不可控召回。语义 ID 试图在两者之间折中：每个物品由若干个离散 codeword 组成，例如 [18, 203, 7, 41]，不同物品可共享前缀或局部 token，从而表达相似性。

语义 ID 的生成方法

方法	输入	机制	优点	风险
RQ-VAE / 残差量化	内容 embedding、协同 embedding 或多模态 embedding。	逐层量化残差，得到固定长度 code。	TIGER 使用的经典路线，易与 Transformer seq2seq 结合 [S18]。	tokenizer 与推荐目标可能错配，热门和长尾物品用同样长度不一定高效。
层次聚类 / 树状 ID	物品向量或行为图表示。	按树路径生成 ID，每一层表示粗到细的语义。	便于前缀约束和分层 beam。	树结构一旦固化，新增物品和语义漂移处理困难。
内容派生 ID	标题、描述、图像、视频、多模态模型表示。	用内容语义生成离散 token。	冷启动强，对新物品友好。	可能缺少协同信号，热门偏好和行为模式表达不足。
协同派生 ID	共现、点击、购买、播放、图结构。	用交互数据学习离散 token。	贴近推荐目标。	冷启动弱，数据偏差和曝光偏差会固化到 ID。
双对齐 ID	多模态内容和协同信号。	同时对齐内容语义和推荐目标。	DAS 等工作试图解决内容 ID 与推荐目标错配 [S22]。	训练复杂，评价要同时看召回、泛化和在线可用性。
可变长 ID	物品频率、语义复杂度和 catalog 分布。	热门物品用短 ID，长尾物品用更长描述。	更贴近自然语言和 Zipf 分布 [S24]。	解码、约束和 batch 训练更复杂。

生成式检索的典型流程

1. 用内容、行为或多模态表示为每个 item 学习语义 ID。
2. 把用户历史 item 序列替换为对应语义 ID 序列。
3. 训练自回归模型或 seq2seq 模型，根据历史预测目标 item 的语义 ID。
4. 推理时用 beam search 生成多个候选 ID，并通过字典映射回真实 item。
5. 对无效 ID、重复候选、已曝光候选、规则过滤和策略约束做后处理。
6. 将生成候选与双塔召回、图召回、规则召回、热度召回合并，送入 ranker。

优势与代价

维度	传统向量召回	生成式检索	落地判断
候选表达	用户向量和物品向量在同一空间近邻搜索。	模型直接生成候选语义 ID。	生成式检索更统一，但 ANN 工程成熟度仍有优势。
冷启动	依赖物品内容塔或规则。	内容语义 ID 可让新物品共享已有 token。	内容丰富的短视频、电商、广告更受益。
可解释结构	向量维度难解释。	前缀或 codeword 可对应粗粒度语义。	解释性取决于 ID 学习方式，不自动成立。
推理成本	编码用户向量后 ANN 检索。	自回归生成多个 token，并进行 beam。	长 ID 和大 beam 会带来延迟压力。
错误形态	近邻不准或索引过期。	生成无效 ID、库外 ID、重复 ID、热门坍塌。	必须有 constrained decoding 和 fallback 召回。

工程要点

语义 ID 系统上线前应单独监控 ID 覆盖率、无效生成率、beam 去重率、新物品召回率、长尾召回率、热门集中度、前缀分布漂移、ID 重建周期和与 ANN 召回的重合度。只看 Recall@K 不足以判断可上线性。

08 · LLM AND DIFFUSION

LLM、扩散与多模态推荐

LLM 和扩散模型给推荐系统带来的不是一个统一答案，而是新的表示能力、生成能力和交互能力。它们最适合进入语义理解、冷启动、多模态内容、解释对话、用户模拟和创意生成；是否进入主链路，要由延迟、成本和可控性决定。

LLM 推荐的五种模式

模式	做法	代表工作	适合场景	主要风险
特征增强	用 LLM 生成 item 标签、摘要、类目、知识图谱边或用户画像。	LLMRec、RLMRec 等 [S30]。	冷启动、内容理解、跨域语义。	生成标签可能不稳定，需要离线审计和版本化。
文本化推荐	把推荐任务改写为自然语言输入输出。	P5、GenRec、LLM-Rec [S25][S28][S29]。	统一多任务、解释、少样本。	物品 grounding 和大规模候选检索困难。
对话推荐	LLM 与用户多轮澄清需求，再调用检索和排序工具。	Chat-REC [S26]。	购物助手、旅游、本地生活、长决策链商品。	对话满意不等于成交；需要可控工具调用和记忆治理。
LLM 重排	对小候选集进行语义判断、解释或列表比较。	多篇 LLM reranking 和 instruction tuning 工作。	候选较小、解释价值高、可离线或近线处理。	成本高，难直接覆盖高 QPS 主链路。
用户模拟器	用 LLM 模拟用户反馈或生成交互数据。	LLM-powered simulator 相关研究。	冷启动策略、RL 环境、产品原型评估。	模拟器偏差会诱导错误优化，不能替代线上实验。

扩散推荐的三类作用

数据工程与表示增强：扩散模型可用于去噪交互、数据增强、补全稀疏行为或提升用户物品表示。相关综述将扩散在推荐中的作用归纳为数据工程与编码、直接推荐模型、内容展示生成三类 [S31]。

直接推荐模型：模型从噪声或部分行为出发，逐步恢复用户偏好或候选分布。这一方向的挑战在于离散 item、采样步数、实时服务和与现有召回排序链路融合。

内容呈现生成：扩散模型能生成广告创意、商品图、封面、搭配图或个性化展示素材。此时推荐系统要优化的不只是 item 选择，还包括 presentation 选择，即同一个商品以什么图、文案、封面呈现给哪个用户。

多模态推荐为什么天然适合 GR

短视频、电商、广告和本地生活中的物品本来就不是单一 ID。一个视频包含画面、音频、字幕、标题、作者、互动图谱；一个商品包含图片、标题、参数、评价、价格、商家和物流；一条广告包含素材、落地页、预算和人群约束。多模态基础模型能把这些信号统一到语义空间，而语义 ID 或生成式模型能把这些语义空间接入推荐任务。

LLM 适合做控制面

理解用户指令、生成解释、调用检索工具、维护对话状态、输出策略约束。它更像推荐系统的语义控制层，而非必然替代 ranker。

多模态模型适合做表示层

把图像、视频、文本、音频和商品属性转为可比较表示，再通过语义 ID、双塔或图模型进入召回和排序。

09 · INTERNATIONAL PRACTICE

| 海外大厂实践

海外公开实践显示，GR 并未脱离传统推荐工程。Google、Meta、Amazon、Netflix 和 Pinterest 的公开材料分别代表五条线：两阶段深度推荐、超大稀疏模型、内容冷启动、多层页面个性化、图和生成式检索。

Google 与 YouTube：两阶段系统到生成式检索

Google Wide & Deep 将线性模型的记忆能力与深度网络的泛化能力结合，并在 Google Play 这类大规模 app 推荐场景中生产化 [S03]。YouTube 2016 年公开的深度推荐架构则将系统划分为 candidate generation 和 ranking 两个网络，用候选生成先从巨大视频库中取回数百个候选，再由 ranking 使用更丰富特征精排 [S04]。

TIGER 代表 Google 系研究者在生成式检索方向的探索：先为 item 学习语义 ID，再训练 Transformer 序列模型根据用户 session 生成下一 item 的语义 ID [S18]。这一思路不是把 YouTube 两阶段架构作废，而是尝试改变召回阶段的表示和检索方式。

Meta：DLRM、TorchRec、HSTU 与 GEM

Meta 在推荐系统上的公开路线长期围绕超大稀疏特征、embedding 表和生产平台。DLRM 是其用于 CTR 预测的代表性模型；TorchRec 则提供大规模 embedding 表分片、规划和并行训练能力，官方仓库说明其支持 Meta 生产级推荐模型 [S14][S15]。

HSTU 论文把推荐问题重新表述为序列转导，针对高基数、异质、非平稳的流式推荐数据设计 Hierarchical Sequential Transduction Units。论文摘要中报告了 1.5 万亿参数 HSTU-based GR、线上 A/B 指标改善和 multi-surface 部署等公开声明 [S20]。这说明 Meta 的 GR 不是聊天助手路线，而是直接针对长行为序列和计算扩展规律的推荐基础模型路线。

Meta 2026 年官方业务材料还提到 Generative Ads Recommendation Model (GEM)，并称 2025 年 Q4 加倍用于训练最新 ads ranking model 的 GPU，使用更高效的 sequence-learning architecture，带来 Facebook ad clicks 和 Instagram conversions 的提升 [S39]。这类材料虽不是论文细节，但说明生成式和序列学习已经进入广告排序叙事。

Amazon：从 item-to-item 到内容冷启动

Amazon 2003 年 item-to-item collaborative filtering 是工业推荐史的标志：把“买了 A 的人也买 B”工程化为可扩展相似物品推荐 [S01]。在视频推荐等现代场景，Amazon Science 公开材料显示 two-tower 可结合异构 metadata，如类别、文本描述和封面图，用于冷启动标题个性化 [S40]。这条线与 GR 的关系在于：当内容 metadata 越丰富，越值得用多模态模型和语义 ID 提升新物品泛化。

Netflix: 多层页面个性化

Netflix 官方帮助中心将首页推荐描述为多层个性化: 选择 row、选择 row 内 title、排序 title; 并强调近期互动会逐步覆盖初始偏好 [S41]。这说明成熟推荐系统不是单列表排序, 而是页面结构、行级选择、内容排序和视觉呈现的组合。GR 进入 Netflix 式系统时, 可能作用于标题理解、素材个性化、解释生成和页面级列表决策, 而不仅是单 item 打分。

Pinterest: 图推荐到 PinRec

Pinterest 的 PinSage 展示了网页规模图卷积推荐, 用图结构学习 pin 和用户表示 [S13]。2025 年 PinRec 则进一步提出 outcome-conditioned multi-token generative retrieval, 用于 Pinterest 产业级推荐系统 [S23]。Pinterest 场景天然多模态: 图片、文本、board、query 和购物意图高度耦合, 因此从图 embedding 走向语义 token 和生成式召回有清晰逻辑。

10 · CHINA PRACTICE

国内大厂实践

国内公开材料集中在电商、广告、短视频、直播和本地化实时推荐。Alibaba 强在电商兴趣建模和生成式电商链路, ByteDance 强在实时推荐系统, Kuaishou 强在短视频、电商和多场景 GR, Tencent 公开了工业广告 GR 数据集和竞赛基准。

Alibaba 与 Taobao: 从兴趣网络到电商 GR

DIN 提出候选相关的 local activation: 用户历史兴趣不应压成固定向量, 而应随候选广告自适应激活。论文报告使用 Alibaba 超过 20 亿样本的生产数据, 并已部署到 Alibaba online display advertising system [S07]。DIEN 进一步建模兴趣抽取和兴趣演化, AAAI 页面明确写到其部署在 Taobao display advertisement system, 并取得 20.7% CTR improvement [S08]。

MIND 面向 Tmall 首页召回阶段, 用动态路由为一个用户学习多个兴趣向量, 并公开说明已处理 Mobile Tmall App 首页主要线上流量 [S09]。SIM 则用 search-based interest model 处理 lifelong sequential behavior, 把长行为检索引入 CTR 预测 [S10]。这些工作构成 Alibaba 系推荐从候选相关兴趣、多兴趣召回到长行为建模的基础。

到 2025-2026 年, 淘宝公开工作开始明显进入生成式链路。AIGQ 将淘宝首页 HintQ 查询推荐做成端到端 hybrid generative architecture, 面向预搜索 query recommendation [S34]。Taobao generative re-ranking 则把电商列表级多目标优化表述为生成式重排问题 [S35]。这说明电商 GR 不只生成商品, 也生成 query、列表和多目标决策。

ByteDance: Monolith 与实时推荐

ByteDance Monolith 论文指出通用深度学习框架在推荐场景中面临动态稀疏特征、批训练和服务分离等问题, 提出 collisionless embedding table 与在线训练架构, 并声明已落地 BytePlus Recommend [S16]。它不是 GR 论文, 但对 GR 落地极关键: 生成式候选如果不能跟上实时兴趣变化, 主链路价值会受限。

短视频推荐尤其强调分钟级甚至秒级反馈。用户连续划走、完整播放、复看、评论、关注和分享都改变当前 session 意图。GR 的长序列建模和自然语言理解必须与实时训练或近线更新结合, 否则会输给更朴素但新鲜的召回和排序特征。

Kuaishou: OneMall、DiffusionGS 与直播数据

Kuaishou 公开论文显示其在电商和内容推荐中积极探索 GR。OneMall 提出面向 Kuaishou E-Commerce 的 end-to-end generative recommender family, 强调 one model, more scenarios [S33]。DiffusionGS 探索 query-conditioned diffusion for generative search in Kuaishou [S37]。KuaiLive 则发布直播推荐实时交互数据集, 说明直播场景对动态互动和序列反馈的特殊要求 [S38]。

快手场景的难点在于内容流、电商、直播和作者关系交织。用户不是简单购买商品, 也会被主播、内容节奏、价格机制和即时互动影响。生成式推荐如果用于这里, 应同时建模 item、author、live room、商品、价格和 session 状态。

Tencent: TencentGR 工业广告基准

Tencent Advertising Algorithm Challenge 2025 的论文将 GR 定义为把 collaborative identifiers 和 multi-modal content 映射到离散 token 空间, 并用自回归序列模型建模用户行为。论文发布 TencentGR-1M 和 TencentGR-10M 两个去标识广告日志数据集, 后者包含 1000 万用户, 并区分 click 与 conversion 事件 [S24]。这是产业界少见的 all-modality generative recommendation 公开基准, 对研究者理解广告 GR 很有价值。

其他国内平台的公开边界

JD、Meituan、Baidu、小红书、Bilibili 等平台也长期深耕推荐, 但“生成式推荐”层面的公开一手资料分散, 且部分只以会议分享、专利或非公开工程材料存在。严谨做法是不把未公开细节写成事实。本报告只在有论文、官方页面或开源材料支持时给出具体落地描述。

11 · ENGINEERING PLAYBOOK

工程落地方法

企业引入 GR, 不应从“训练一个大模型”开始, 而应从推荐链路中最明确的瓶颈开始: 长尾召回、冷启动、多模态理解、query 推荐、解释对话、列表重排或广告创意。不同瓶颈对应完全不同的工程路线。

落地路线图

阶段	目标	关键动作	通过标准
0. 问题定位	确认 GR 要解决的具体问题。	拆分召回不足、排序不准、冷启动差、解释差、query 低质、创意低效等问题。	能用现有日志和线上指标描述问题，而不是只说“需要大模型”。
1. 离线基线	建立传统强基线。	双塔召回、item-to-item、序列模型、现有 ranker、规则召回和热度召回。	GR 必须对强基线有增量，而非只击败弱 baseline。
2. 表示与 token 化	建立 item 语义空间。	内容 embedding、协同 embedding、多模态 embedding、RQ-VAE 或聚类 ID。	ID 覆盖、重建、长尾泛化、内容一致性和协同一致性达标。
3. 生成模型训练	预测候选、query、列表或解释。	构造序列样本，训练自回归模型或 LLM/adapter，设置 constrained decoding。	离线 Recall/NDCG、无效率、重复率、延迟和成本可接受。
4. 混合召回与重排	接入现有推荐链路。	与 ANN、图召回、规则召回合并；ranker 精排；策略层过滤。	GR 候选贡献可追踪，不破坏主链路稳定性。
5. 小流量线上实验	验证真实增量。	A/B、holdout、分人群分品类分析、冷启动和长尾切片。	核心指标提升且护栏指标不降；异常可回滚。
6. 闭环治理	长期稳定迭代。	监控漂移、无效生成、安全、库存、合规、用户反馈和模型版本。	形成版本化训练、评估、上线、回滚和审计流程。

不同场景的优先切入点

场景	优先 GR 方向	不建议优先做	原因
短视频内容流	长序列行为建模、多模态语义 ID、冷启动召回。	直接用 LLM 在线重排全候选。	QPS 和延迟压力极高，实时反馈比解释更关键。
电商首页	多兴趣召回、query 生成、列表重排、搭配推荐。	完全替代现有 ranker。	GMV、转化、库存、商家公平和促销约束复杂。
广告系统	多模态广告理解、生成式创意、长序列 ads ranking。	无约束生成广告文案或落地页。	广告合规、品牌安全和转化归因要求高。
长视频平台	内容冷启动、封面/标题个性化、页面行级推荐。	只优化单 title 点击。	观看完成率、会员满意度和内容供给结构更重要。
本地生活/旅游	对话推荐、约束理解、行程或套餐生成。	只做 item 相似召回。	用户需求含预算、位置、时间、同行人和偏好约束。
企业内容推荐	LLM 解释、权限感知检索、个性化知识流。	黑盒生成无引用答案。	事实性、权限和审计比娱乐点击更重要。

系统架构建议

生产级 GR 应保持分层：离线或近线训练语义 ID 和生成模型；在线召回只生成可控候选；主 ranker 继续吸收高价值实时特征；重排层处理多样性和约束；LLM 控制层只在需要自然语言交互、解释或复杂推理时介入。这样做不是保守，而是尊重推荐系统对延迟、稳定性和可回滚性的要求。

最小可行实验

推荐先做“生成式召回作为新增召回源”的实验：选择一个冷启动或长尾明显的垂类，为 item 学习语义 ID，训练下一物品生成模型，生成 top-N 候选后与现有召回混合。线上只看新增候选贡献、去重后覆盖、长尾曝光、核心业务指标和护栏指标。不要第一步就替换排序主模型。

12 · EVALUATION AND GOVERNANCE

评估、治理与风险

GR 的评估比传统推荐更复杂，因为它可能改变候选分布、生成内容、解释理由和用户交互路径。离线指标仍必要，但必须结合线上实验、切片分析、反事实评估和安全治理。

指标体系

层级	指标	适用对象	注意点
召回质量	Recall@K、NDCG@K、HitRate、coverage、novelty。	生成式检索、双塔、图召回。	要去看去重后贡献、库外生成和长尾切片。
排序质量	AUC、GAUC、logloss、calibration、NDCG。	ranker、LLM reranker。	离线排序指标容易受曝光偏差影响。
业务目标	CTR、CVR、GMV、观看时长、留存、订阅、广告 ROI。	线上 A/B。	短期点击可能损害长期满意度。
列表体验	多样性、去重、疲劳、覆盖、serendipity。	重排和页面生成。	多样性不能脱离相关性和业务目标。
生成质量	事实性、grounding、可读性、安全性、品牌一致性。	解释、对话、广告创意、标题封面。	需要人工审计和自动安全规则结合。
系统质量	延迟、吞吐、成本、失败率、回滚时间。	全链路。	GR 的 token 生成成本必须纳入主指标。

GR 特有风险

无效生成：模型生成不存在的 item ID、过期商品、不可售库存或策略禁止内容。解决方式包括 trie 约束、候选字典校验、库存和安全过滤、fallback 召回。

热门坍缩：生成模型可能过度生成高频 token，导致热门更热门、长尾更难曝光。需要监控 token 频率、item 频率、作者/商家覆盖和新物品曝光。

解释错配：LLM 给出的推荐理由可能听起来合理，但并非真实排序原因。解释层必须与可验证特征、用户意图和 item 属性绑定，避免“好听但不真实”。

反馈污染：生成封面、标题或广告创意会改变用户反馈，导致模型学到的是呈现方式效果，而非 item 本身价值。训练样本需要记录 presentation version。

合规扩大：当系统开始生成广告、商品描述、健康建议、金融推荐或本地服务路径，责任边界从“排序展示”扩大到“内容生成和决策辅助”。

A/B 实验设计

实验对象	推荐设计	关键切片	护栏指标
生成式召回	作为新增召回源混入，不替换主召回。	新 item、长尾 item、低活用户、新用户、垂类。	延迟、重复率、无效率、举报率、核心指标。
LLM 解释	只改变解释文案，保持推荐列表一致。	高价商品、低信任类目、新用户。	误导投诉、转化后退款、跳出率。
生成式重排	限定候选池和策略约束，比较列表级收益。	多目标冲突场景、广告/自然混排、活动页。	商家集中度、内容重复、用户疲劳。
生成创意	创意版本随机化，记录素材 lineage。	广告主、类目、人群、素材类型。	品牌安全、审核拒绝率、负反馈、归因波动。

13 · TRENDS

趋势判断

2026 之后，GR 的核心竞争不会是“谁把 LLM 接入推荐页”，而是谁能把语义 ID、长序列行为、多模态内容、实时反馈、列表决策和安全治理整合进可扩展系统。

十个发展趋势

1. 语义 ID 从固定长度走向自适应。热门、长尾、新物品和复杂多模态内容需要不同信息量，可变长和分层 ID 会持续发展。
2. 生成式召回与 ANN 长期共存。生成模型负责语义泛化和长尾候选，传统向量、图和规则召回负责稳定覆盖和低延迟。
3. 推荐基础模型会先在大平台内部成熟。HSTU 类路线需要海量行为序列、算力、特征系统和线上实验，小团队更适合从垂类语义 ID 或 LLM 增强开始。
4. LLM 成为推荐控制面。它会理解意图、解释结果、维护偏好记忆、调用工具和生成约束，但主链路 ranker 不会被简单替代。
5. 多模态 token 化成为电商和短视频标配。图像、视频、文本和互动图谱会共同决定 item 表示，单纯 title embedding 不够。
6. 列表级生成会进入电商和广告。多目标优化天然 是列表问题，生成式重排比逐 item 打分更容易表达组合约束。
7. 实时 GR 是关键分水岭。离线生成候选若不能快速吸收新反馈，会被实时双塔、规则召回和近线 ranker 超越。
8. 推荐和生成内容合并。广告创意、商品图、封面和标题的生成会与推荐系统共同优化，presentation 将成为样本的一等字段。
9. 评估从点击走向长期满意和生态健康。更强生成能力会放大诱导点击、信息茧房和内容同质化问题，平台必须维护长期指标。
10. 合规和可审计性成为工程门槛。生成式解释、广告创意和个性化内容需要记录来源、版本、理由、过滤规则和用户申诉路径。

开放问题

问题	为什么难	可能方向
语义 ID 如何同时对齐内容和行为？	内容相似不等于协同相似，协同相似又受曝光偏差影响。	双对齐训练、端到端可微 tokenizer、动态 ID 更新。
如何避免生成式召回的库外和无效输出？	自回归模型天然可能生成未注册序列。	约束解码、prefix trie、有效 ID 语言模型、后验校验。
推荐基础模型是否有稳定 scaling law？	推荐数据非平稳、多目标、强反馈闭环，不同于互联网文本。	公开基准、跨域数据、长期线上指标、计算量系统研究。
LLM 推荐如何避免幻觉？	推荐理由和排序原因容易分离。	工具调用、引用 item metadata、特征级解释、可验证 grounding。
生成内容如何不破坏生态？	模型可能批量生成迎合点击的低质内容。	内容来源标记、质量审核、创作者激励、长期满意度约束。
如何评估 agentic recommendation？	多轮交互、工具调用和长期任务目标难以用单次点击衡量。	任务成功率、用户确认、长期留存、可回放轨迹和模拟器校准。

最终判断

GR 的近期价值主要来自增强召回、增强表示、增强交互和增强内容呈现；中期价值来自统一多场景推荐建模；长期价值才可能是推荐基础模型和推荐智能体。对多数企业，正确路线是从局部可验证增量开始，而不是直接追求端到端替代。

附录

A. 从 0 到 1 学习路径

阶段	应掌握内容	建议阅读	产出检验
入门	协同过滤、矩阵分解、隐式反馈、召回排序。	Amazon item-to-item、Netflix MF、YouTube DNN。	能手写一个双塔召回和一个简单 ranker 的训练数据格式。
深度推荐	Wide & Deep、DeepFM、DIN、DIEN、MIND、SASRec、BERT4Rec。	第 5 章论文列表。	能解释候选相关 attention 和多兴趣召回的差异。
系统工程	embedding 表、特征服务、在线训练、A/B、实时反馈。	DLRM、TorchRec、Monolith。	能画出召回、排序、重排、策略、日志闭环。
GR 核心	语义 ID、生成式检索、beam、约束解码、HSTU。	TIGER、HSTU、PinRec、TencentGR。	能设计一个生成式召回作为新增召回源的实验。
扩展方向	LLM 推荐、扩散推荐、多模态 token、agentic 推荐。	P5、Chat-REC、LLMRec、diffusion survey、FM4RecSys survey。	能判断 LLM 应进入控制层、表示层还是主链路。

B. 术语表

语义 ID (Semantic ID): 将物品映射成一串低基数离散 token，使生成模型能输出物品标识，并在 token 结构中保留语义或协同相似性。

- 生成式检索(Generative Retrieval):** 由模型直接生成目标文档或物品标识的检索范式, 区别于“编码 query 后在向量库中近邻搜索”。
- 召回(Candidate Generation / Retrieval):** 从大候选库中快速取回小候选集, 为后续精排降低计算量。
- 排序(Ranking):** 对召回候选进行精细打分, 通常预测点击、转化、停留或多目标效用。
- 重排(Re-ranking):** 在排序结果上做列表级优化, 处理多样性、去重、策略、预算和用户疲劳。
- 长尾(Long Tail):** 互动少、曝光少或新上线的物品集合。长尾推荐质量对内容生态和冷启动很关键。
- 曝光偏差(Exposure Bias):** 日志只记录被系统展示后的反馈, 未展示物品的潜在反馈不可直接观察。
- Presentation:** 同一物品的展示方式, 包括封面、标题、摘要、广告创意、价格信息和解释文案。

C. 来源映射

编号	来源	用途
S01	Amazon.com Recommendations: Item-to-Item Collaborative Filtering	工业 item-to-item 协同过滤。
S02	Matrix Factorization Techniques for Recommender Systems	Netflix Prize 与矩阵分解。
S03	Google Wide & Deep	深度排序和生产化推荐。
S04	Deep Neural Networks for YouTube Recommendations	两阶段推荐架构。
S05	DeepFM	低阶与高阶特征交互。
S06	Neural Collaborative Filtering	神经协同过滤。
S07	DIN	候选相关兴趣激活。
S08	DIEN	兴趣演化和淘宝广告部署声明。
S09	MIND	多兴趣召回和天猫首页。
S10	SIM	长行为序列检索式兴趣建模。
S11	SASRec	自注意力序列推荐。
S12	BERT4Rec	双向 Transformer 序列推荐。
S13	PinSage	Pinterest 图推荐。
S14	DLRM	Meta 稀疏推荐模型。
S15	TorchRec	Meta 大规模推荐训练库。
S16	Monolith	ByteDance 实时推荐系统。
S17	Generative Recommendation: Towards Next-generation Recommender Paradigm	GR 概念和 GeneRec。
S18	TIGER	语义 ID 生成式检索。
S19	Better Generalization with Semantic IDs	语义 ID 泛化。
S20	HSTU / Trillion-Parameter Sequential Transducers	Meta 生成式推荐和 scaling。
S21	meta-recsys/generative-recommenders	HSTU/M-FALCON 开源仓库。
S22	DAS	双对齐语义 ID。
S23	PinRec	Pinterest 产业级生成式检索。
S24	TencentGR	腾讯广告全模式 GR 基准。
S25	P5	推荐语言化统一范式。
S26	Chat-REC	交互式可解释 LLM 推荐。
S27	TALLRec	LLM 与推荐对齐。
S28	GenRec LLM	LLM 生成式推荐。
S29	LLM-Rec	prompting LLM 做个性化推荐。
S30	LLMRec	LLM 图增强推荐。
S31	Diffusion Models for Recommender Systems survey	扩散推荐分类。
S32	Gen-RecSys survey / FM4RecSys survey	生成模型和基础模型推荐综述。

编号	来源	用途
S33	Kuaishou OneMall	快手电商端到端 GR。
S34	Taobao AIGQ	电商 query 生成推荐。
S35	Taobao generative re-ranking	列表级多目标生成式重排。
S36	GEMRec	生成模型推荐概念。
S37	Kuaishou DiffusionGS	扩散式生成搜索。
S38	KuaiLive	直播推荐实时交互数据。
S39	Meta AI Drives Performance 2026	GEM ads ranking 官方业务材料。
S40	Amazon Science two-tower video recommendation	异构 metadata 和冷启动。
S41	Netflix Help Center recommendation system	多层页面个性化。