

TECHNICAL REPORT · EVIDENCE CUT 2026-06-22

GLM-5.2

技术报告深度解读

GLM-5.2 把 1M 上下文、稀疏注意力索引复用、推测解码、KV cache 工程、长轨迹强化学习与评测防作弊连成一套长时任务系统。

Winston

V1.0 · 2026-06-22

证据范围：官方博客、模型配置、论文、推理框架文档与独立评测平台

结论边界：未进行 744B 权重本地推理或训练复现

| 目录

01	执行摘要：GLM-5.2 改变了什么	03
02	事实边界：哪些是发布方结论，哪些已有外部证据	04
03	模型骨架没有扩张，长任务链路被重新设计	05
04	IndexShare：把稀疏注意力的索引成本压下来	06
05	MTP：20% 接受长度增益如何出现	07
06	长轨迹后训练：slime、OPD、PPO 与反作弊	08
07	评测证据：标准编码与数小时工程任务	10
08	外部分析：能力跃升伴随更高 token 消耗	12
09	部署与成本：1M 上下文首先是内存问题	13
10	局限与误读：1M、开放权重和 benchmark 都有边界	14
11	实践方法：怎样判断 GLM-5.2 是否适合自己的任务	16
12	术语表、延伸阅读与来源	17

执行摘要：GLM-5.2 改变了什么

GLM-5.2 于 2026 年 6 月发布。它沿用约 744B 总参数、每 token 约 40B 参数参与计算的 GLM-5 系列骨架，把最大上下文标称值从 200K 扩到 1,048,576 token，并把训练、推理和评测都向数小时级 Agent 任务重新校准。官方发布将其定位为长时任务模型，独立评测则确认它已进入开放权重模型的第一梯队。[\[S01\]](#)[\[S02\]](#)[\[S13\]](#)

核心判断

GLM-5.2 的主要增量可以压缩成一条工程链路：**IndexShare 降低 1M 上下文的稀疏索引计算**，改造后的 Multi-Token Prediction (MTP，多 token 预测) 提高推测解码的平均接受长度，slime 支撑更长、更异构的 Agent 轨迹训练，critic-based PPO 接住压缩后长度不一的子轨迹，在线反作弊保护可验证奖励不被投机行为污染。任一环节缺失，1M 只是一个接口上限。[\[S01\]](#)[\[S05\]](#)[\[S06\]](#)[\[S07\]](#)

观察层	可核验变化	工程含义
模型	约 744B 总参数、每 token 约 40B 参数参与计算，规模与 GLM-5.1 基本不变	能力增量主要来自训练与系统配方，不是参数扩张
上下文	200K → 1M，配置最大序列长度为 1,048,576	这是模型配置能力；实际可交付长度仍受服务栈、显存与并发约束
注意力	每 4 层共享一次稀疏索引，官方称 1M 下每 token FLOPs 降低 2.9×	索引器不再逐层重复完成高度相似的 top-k 搜索
解码	MTP 消融中的接受长度从 4.56 升至 5.47，约 +20%	更少目标模型验证轮次，长输出的收益更明显
后训练	10 余个专家模型并行 OPD，官方称约 2 天完成	能力合并从顺序蒸馏改成可并行的数据与 rollout 流程
外部评测	Artificial Analysis Intelligence Index v4.1 得分 51	截至 2026-06-22 为开放权重模型领先者，但 token 消耗偏高

表中参数、上下文与架构来自官方模型配置和发布材料；Artificial Analysis 数据为独立平台测量。[\[S01\]](#)[\[S02\]](#)[\[S03\]](#)[\[S13\]](#)

结论

如果任务能在几十分钟内完成，GLM-5.2 更像一款能力更强的编码模型。如果任务需要持续读仓库、改实现、跑测试、压缩历史并继续工作数小时，它才显示出与 GLM-5.1 不同的设计重心。当前证据支持「领先的开放权重长时工程模型」，还不足以支持「所有 1M token 任务都稳定」或「已经等同最强闭源模型」。

02 · EVIDENCE BOUNDARY

事实边界：哪些是发布方结论，哪些已有外部证据

GLM-5.2 尚无独立的完整技术报告。公开技术细节分布在发布博客、GLM-5 技术报告、IndexCache 论文、模型配置和推理框架文档中。阅读时需要把产品新增、沿用基座和外部测量分开，否则容易把 GLM-5 的训练事实误写成 GLM-5.2 的新增贡献。

2.1 三层证据

证据层	本文如何使用	代表来源
PRIMARY 发布方事实	模型配置、训练方法、官方消融、许可与支持框架	Z.ai 博客、Hugging Face、GLM-5 报告、slime
INDEPENDENT 外部测量	独立 benchmark、成本、速度、token 用量与当前排名	Artificial Analysis、FrontierSWE、PostTrainBench
ANALYSIS 本文推断	模块之间的因果关系、适用场景、部署选择与风险	基于多来源交叉后的工程判断

2.2 已发现的口径冲突

PostTrainBench 排名发生过同日变化。Z.ai 发布博客写 GLM-5.2 仅次于 Opus 4.8，PostTrainBench 在 6 月 17 日把 Opus 4.8 Max 从单次 37.2% 更新为两次平均 34.1%，GLM-5.2 因此升到第一。本文采用评测方当前页面，并保留变更原因。[\[s01\]](#)[\[s16\]](#)

参数量有 743B、744B 与 753B 三种写法。GLM-5 技术报告给出 744B 总参数、每 token 约 40B 参数参与计算，vLLM recipe 写约 743B/39B，Artificial Analysis 文章写 744B/40B，其模型页显示 753B/40B。差异更像计数口径或元数据更新，不足以证明存在另一版权重。正文采用官方报告的约 744B/40B，并在引用外部页面时保留原值。[\[s04\]](#)[\[s10\]](#)[\[s13\]](#)[\[s14\]](#)

IndexShare 与 IndexCache 指向同一条方法线。发布博客把产品中的四层索引复用称为 IndexShare，所链接论文标题为 IndexCache。论文描述通用的跨层索引复用方法，产品配置中的 `index_topk_freq: 4` 和 `shared/full` 模式给出了 GLM-5.2 的具体实例。[\[s01\]](#)[\[s03\]](#)[\[s05\]](#)

证据日期: 本文按 2026-06-22 可访问页面核验。排行榜、价格、框架版本和服务配额会变化；技术架构与论文结论相对稳定，产品状态必须按日期阅读。

2.3 本文没有做什么

本文没有下载并运行 744B 权重，没有复现 1M token 端到端吞吐，没有重跑官方 benchmark，也没有把社交媒体体验当成性能证据。所有「领先」「接近」和「第一」都限定在具体榜单、日期与评测执行框架(harness)下。官方没有披露 GLM-5.2 的完整训练数据构成、训练算力、1M 数据占比或逐阶段模型检查点(checkpoint)，因此这些内容不作推测。

03 · MODEL BACKBONE

模型骨架没有扩张，长任务链路被重新设计

GLM-5.2 没有靠扩大总参数拉开与 5.1 的差距。公开配置显示，它仍是一款采用 DeepSeek Sparse Attention (DSA) 与 Mixture-of-Experts (MoE, 混合专家) 的自回归模型：78 层、256 个路由专家、每 token 选择 8 个路由专家，另有 1 个共享专家，前三层使用 dense MLP。每 token 参与计算的参数约 40B，占 744B 总参数的约 5.4%；推理成本仍由专家计算、跨卡通信、KV cache 和上下文长度共同决定。[\[S02\]](#)[\[S03\]](#)[\[S04\]](#)

3.1 配置快照

字段	GLM-5.2	解释
总参数 / active params	约 744B / 40B	active params 指每 token 前向路径参与计算的参数量，不是运行时激活张量内存
Transformer 层数	78	模型配置文件的 num_hidden_layers
路由专家	256	每 token 选择 8 个，另有 1 个共享专家
隐藏维度	6,144	主干 residual width
注意力头	64	头维度与 MLA/DSA 投影配合
稀疏 top-k	2,048	每个 query 选择的历史 token 数
索引复用频率	4 层	1 个 full indexer 服务后续 3 个 shared 层
配置最大序列长度	1,048,576	max_position_embeddings 声明的位置索引上限；不等于所有服务都能交付完整 1M

参数规模沿用 GLM-5 报告与外部核验，其他字段取自 GLM-5.2 config.json。[\[S03\]](#)[\[S04\]](#)[\[S13\]](#)

3.2 从 GLM-5 到 GLM-5.2 的连续性

GLM-5 已经建立了 744B MoE、DSA、Muon Split 优化配方、共享参数 MTP、28.5T token 预训练与异步 Agentic RL 基线。GLM-5.2 在这一骨架上调整索引器、MTP、长上下文训练和后训练，而不是再发布一套从头改写的基础架构。[\[S04\]](#)

GLM-5.2 的能力跃升不能全部归因于 IndexShare，也不能只看 1M 上下文。官方博客没有给出各新增模块对最终 benchmark 的完整逐项消融，现有公开证据只能确认各模块改善了局部计算、接受长度或训练组织，无法精确分摊最终得分。

FIGURE 1 · GLM-5.2 的长时任务链路




图 1, 1M 上下文要进入实际任务，需要模型结构、解码、后训练和评测约束同时成立。示意重绘，依据 Z.ai 发布博客与公开配置。[\[S01\]](#)[\[S03\]](#)[\[S07\]](#)

04 · INDEXSHARE

IndexShare: 把稀疏注意力的索引成本压下来

DSA 把完整注意力的主计算从 $O(L^2)$ 降到 $O(Lk)$ ，但负责选择 top-k token 的轻量索引器仍要进行 $O(L^2)$ 级点积打分与 top-k 选择。上下文到 1M 后，索引器本身会成为显著成本。IndexCache 论文观察到相邻层选出的 top-k 高度相似，因此保留少量 full 层计算索引，其余 shared 层复用最近结果。[\[S05\]](#)

4.1 四层共享的计算账

GLM-5.2 的具体模式是每 4 层只在第一层运行 indexer，接下来的 3 层复用同一组 top-k。配置文件中的 `indexer_types` 呈现 full、shared、shared、shared 的周期，`index_topk_freq` 为 4，`index_topk` 为 2,048。官方称，这一设计在 1M 上下文下把每 token FLOPs 降低 $2.9\times$ 。[\[S01\]](#)[\[S03\]](#)


```

Layer n      : query → indexer → top-2048 → sparse attention
Layer n + 1  : query —————→ reuse      → sparse attention
Layer n + 2  : query —————→ reuse      → sparse attention
Layer n + 3  : query —————→ reuse      → sparse attention

```

4.2 复用为什么没有直接破坏质量

论文观察到连续层的选择结果存在可利用的冗余。训练无关版本用校准集搜索保留哪些 full 层，训练感知版本让保留的 indexer 学习它所服务多层的平均注意力分布。30B DSA 实验中，论文报告可移除 75% indexer 计算，质量下降很小，prefill 最多加速 1.82×，decode 最多加速 1.48×。这些是研究模型结果，不应直接写成 GLM-5.2 的服务速度。^[S05]

GLM-5.2 从序列长度 128K 的中期训练(mid-training)开始加入 IndexShare，并在官方长上下文 benchmark 上超过 GLM-5.1。公开资料没有给出 1M 长度下逐层 top-k 重合率、端到端时延消融或不同任务的退化曲线，因此「2.9× FLOPs」只能解释计算项，不能替代真实吞吐测试。^[S01]

1M 下的收益来源：上下文长度 L 增长时，稀疏注意力主路径保持 $O(Lk)$ ，索引器仍含 $O(L^2)$ 部分。复用减少的是增长更快的计算项。短上下文里省掉的计算可能被通信、kernel 启动和 CPU 调度掩盖，长上下文里更容易显现。

4.3 代价与适用边界

跨层复用假设相邻层对重要 token 的判断足够接近。需要快速切换关注目标的任务、极端长距离引用或索引器分布漂移，都可能放大共享误差。训练感知方法能缓和这一点，但 GLM-5.2 没有公开逐任务失效样本。工程上应把 IndexShare 看作降低索引成本的结构选择，不是证明百万上下文无损的证书。

05 · MULTI-TOKEN PREDICTION

MTP: 20% 接受长度增益如何出现

Multi-Token Prediction(MTP, 多 token 预测)让轻量草稿模型(draft model)一次预测多个后续 token，再由目标模型并行验证。吞吐是否提高取决于平均接受长度：预测得多但经常被拒绝，只会增加验证成本。GLM-5.2 的改动集中在训练与推理分布对齐。^{[S01][S06]}

5.1 GLM-5.1 的偏差来自混合 KV

多步 MTP 的第二步开始同时看到目标模型产生的历史 hidden state 和 MTP 自己生成的新 state，对应 KV cache 混合了两种分布。训练阶段若只见目标模型状态，推理时就会遇到分布偏差。GLM-5.2 在 MTP 步之间复用第一步的 top-k 与 KV，只让后续步骤访问来自目标模型的历史 KV，避免把 draft 自己的新 KV 混进上下文。^[S01]

5.2 拒绝采样与 TV loss 直接优化接受概率

GLM-5.2 引入概率拒绝采样与端到端 Total Variation(TV) loss。Bebop 论文给出的解释是，RL 阶段目标模型的熵会波动，target-only sampling 的接受率随熵上升明显下降；概率拒绝采样利用目标分布与草稿分布的重叠，TV loss 则直接优化多步拒绝采样的接受概率，比只用交叉熵或 KL 散度更贴近推测解码的真实目标。论文在 Qwen3.5、3.6、3.7 的异步 RL 实验中报告最高 95% 接受率、额外 25% 推理吞吐和最高 1.8× 端到端 RL 加速，这些结果说明方法原理，不是 GLM-5.2 的直接测速。[\[s06\]](#)

GLM-5.1 backbone 消融	接受长度	相对基线
Baseline	4.56	0%
+ IndexShare + KVShare	5.10	+11.8%
+ Rejection Sampling	5.29	+16.0%
+ End-to-end TV Loss	5.47	+20.0%

官方消融固定 GLM-5.1 backbone 与训练数据，训练和推理都设置 7 个 MTP steps。部署 recipe 的参数语义不同：vLLM 使用 5 个 speculative tokens；SGLang 低时延配置使用 5 个 steps、最多 6 个 draft tokens。不能把这些值与消融中的 7 steps 直接比较。[\[s01\]](#)[\[s10\]](#)[\[s11\]](#)

5.3 对真实服务的含义

推测解码对长输出、推理和编码任务更有价值，因为目标模型的验证轮次更多。vLLM 与 SGLang 都要求根据服务器报告的 accept length 调整 draft 数量；平均接受长度显著低于 draft-token 上限时应缩短草稿。合成随机 token 压测往往低估 MTP，因为随机分布与真实代码、推理输出不同。[\[s10\]](#)[\[s11\]](#)

判断

「接受长度 +20%」是固定消融设置下的局部结果。最终收益取决于输出长度、任务熵、batch、KV cache、draft token 数和 kernel 实现。部署时应同时记录接受长度、每秒输出 token、端到端时延与 GPU 利用率。

| 长轨迹后训练：slime、OPD、ppo 与反作弊

长时 Agent 训练的困难不只在轨迹变长。不同采样轨迹(rollout)会产生数量和长度都不同的压缩片段，工具环境异构，生成侧耗时长尾明显，可验证奖励还会诱导模型偷看答案。GLM-5.2 把训练基础设施、优化算法与评测防作弊一起调整。[\[s01\]](#)[\[s07\]](#)

6.1 slime 把 rollout 与训练解耦

slime 以 Megatron 负责训练、SGLang 负责 rollout, Data Buffer 连接两侧。它支持白盒与黑盒 rollout、紧凑轨迹、子 Agent 工作流、异步生成、权重同步、prefill-decode(PD)分离和外部推理服务。GLM-5.2 用它组织更大规模的 Agentic RL 与 On-Policy Distillation(OPD, 在线策略蒸馏), 官方称 10 余个专家模型通过并行 OPD 合并, 整个过程约 2 天。[S01][S07]

约 2 天只对应所述并行 OPD 阶段, 不是 GLM-5.2 的总训练时间。公开博客没有给出 GPU 数量、每个专家的样本规模或等价串行成本, 不能据此计算完整后训练算力。

6.2 critic-based PPO 接住压缩后的不规则轨迹

长任务会通过上下文压缩(compaction)把历史拆成多个子轨迹, 同一个 prompt 的不同 rollout 可能产生不同数量的训练片段。组相对方法要求组内样本结构可比较, 这里很难成立。GLM-5.2 改用 critic-based PPO, 从单条 rollout 学习 token 级优势(advantage), 并把所有压缩子轨迹纳入训练, 再用 token 级 loss 处理长度不平衡。[S01]

这个选择说明 compaction 已经进入训练分布, 而不只是推理客户端的补丁。模型在训练中见过「保留摘要、丢弃原轨迹、继续执行」的状态, 长任务的恢复能力因此有了明确训练入口。官方没有公开 critic 结构、广义优势估计(GAE)参数或与组相对方法的最终 benchmark 消融, 算法优势仍主要来自问题适配, 而非完整对照实验。

6.3 可验证奖励会诱导模型攻击评测

编码任务常用测试通过率做奖励。模型能力越强, 越可能发现比修复代码更短的路径, 比如读取隐藏测试、复制上游提交、从网络下载目标文件, 或修改评测脚本。GLM-5.2 的在线反作弊先用规则筛出高召回的可疑调用, 再由 LLM 判别器(LLM judge)判断意图; 确认作弊后阻断调用并返回占位信息, 但不中止整条 rollout。[S01]

```
# 评测环境必须拦截的典型路径
find /workspace -name "*hidden*"
cat /workspace/.eval/secret_cases.json
curl "$UPSTREAM_SOURCE_URL"

# 合理动作仍应保留
pytest -q
git diff --check
python benchmark.py --public-suite
```

保留 rollout、只阻断违规调用, 可以避免训练样本突然消失, 降低训练崩溃(model collapse)的风险; 模型仍有机会回到正常求解路径。PostTrainBench 的独立分析也记录了多种污染与规则规避行为, 说明反作弊不是发布方自设的边缘问题。[S16]

迁移到企业 Agent 训练时，隐藏测试、基准答案、生产密钥、外部网络和评分脚本应分属不同权限域。只在系统提示里写「禁止查看」无法形成边界，工具层必须能拒绝并记录访问。

07 · EVALUATION

评测证据：标准编码与数小时工程任务

GLM-5.2 的评测优势主要出现在编码、科学推理和长时 Agent 任务。官方表格覆盖标准 benchmark 与三个长任务平台，外部页面能确认其中部分排名。所有结果都依赖评测执行框架(harness)、推理档位、上下文上限、输出上限和日期，不能合成一个无条件的「综合能力」。[\[S01\]](#)[\[S13\]](#)[\[S15\]](#)[\[S16\]](#)[\[S17\]](#)

7.1 相比 GLM-5.1，增量集中在哪里

Benchmark	GLM-5.1	GLM-5.2	变化	来源
Terminal-Bench 2.1, Terminus-2	63.5	81.0	+17.5 pt	[S01]
SWE-bench Pro	58.4	62.1	+3.7 pt	[S01]
NL2Repo	42.7	48.9	+6.2 pt	[S01]
DeepSWE	18.0	46.2	+28.2 pt	[S01]
FrontierSWE Dominance	30.5	74.4	+43.9 pt	[S01] [S15]
PostTrainBench	20.1	34.3	+14.2 pt	[S01] [S16]
SWE-Marathon	1.0	13.0	+12.0 pt	[S01] [S17]

FIGURE 2 · GLM-5.1 到 5.2 的编码与长任务增量




图 2，多项长时任务显示出较大的代际增量。各指标定义不同，图中只比较同一 benchmark 内的 GLM-5.1 与 GLM-5.2，不能跨行比较绝对高低。[S01][S15][S16]

7.2 FrontierSWE 说明了什么

FrontierSWE 由开放式实现、性能优化和 ML 研究任务组成，单项可持续数小时到数十小时。当前页面显示 GLM-5.2 使用 Claude Code harness，平均排名 4.32、Dominance 74%，与 Opus 4.8 的 4.24/75% 接近，低于后来加入的 Claude Fable 5。GLM-5.2 在分子性质预测研究任务中取得最佳结果，在 Git to Zig 实现任务中取得 28% 测试通过率。[S15]

这类任务比 SWE-bench 更接近「从空白开始做一个系统」，也更容易受 harness、超时时间和随机探索影响。Mean@5(5 次运行均值)比单次结果更稳，但样本任务仍少，适合判断能力形状，不适合推算日常代码产出比例。

7.3 PostTrainBench 测的是 AI 研发自动化

PostTrainBench 给 Agent 一张 H100、10 小时和 4 个小型基础模型，目标是在 7 个下游 benchmark 上做出更好的后训练模型。它同时考验数据构造、方法选择、训练稳定性和时间管理。页面在 6 月 17 日更新 Opus 4.8 Max 两次运行均值后，GLM-5.2 升到当前第一。[S16]

评测方也记录了多个模型读取评测集、复制函数、调用禁用 API 或提交现成 instruct 模型的行为。GLM-5.2 发布中的 anti-hack 设计与这一外部观察相互印证：能优化奖励信号的 Agent 也会利用评测漏洞。

7.4 SWE-Marathon 仍暴露明显差距

SWE-Marathon 包含 20 个多小时软件工程任务，覆盖库复刻、完整产品与 ML 工程。官方发布表中 GLM-5.2 得分 13，Opus 4.8 为 26；评测站点说明前沿 Agent 的解题率仍低于 26%。长时能力已有进步，多数任务依然失败。[\[S01\]](#)[\[S17\]](#)

08 · EXTERNAL ANALYSIS

| 外部分析：能力跃升伴随更高 token 消耗

独立评测对 GLM-5.2 的判断比发布材料更完整：质量进入开放权重第一梯队，科学推理、长上下文和 Agent 工作显著改善，但每任务输出 token 增长，成本和时间优势没有能力分数那么突出。[\[S13\]](#)[\[S14\]](#)

8.1 Artificial Analysis：51 分与 43K 输出 token 要一起看

指标	GLM-5.1	GLM-5.2	外部解读
Intelligence Index v4.1	40	51	开放权重模型领先
CritPt	5%	21%	科学推理增量最大之一
HLE	28%	40%	复杂知识与推理提升
AA-LCR	62%	71%	长上下文推理改善
Terminal-Bench v2.1	62%	78%	独立实现也确认大幅增长
每任务输出 token	26K	43K	能力提高伴随更长推理
每任务成本	\$0.25	约 \$0.46	同能力水平有竞争力，但高于多数开放权重同行

HLE 指 Humanity’s Last Exam；AA-LCR 指 Artificial Analysis Long Context Reasoning。文章发表于 2026-06-17，指标与价格会继续更新。[\[S13\]](#)[\[S14\]](#)

Artificial Analysis 将 GLM-5.2 放在 Intelligence 与 Cost per Task 的 Pareto frontier 上，理由是同等 intelligence 水平下成本最低。不过在开放权重同规模模型中，它的输入和输出单价仍偏高，43K 平均输出 token 也高于 MiniMax M3、Kimi K2.6 与 DeepSeek V4 Pro。成本优势来自能力水平对比，不等于绝对便宜。

8.2 Jie Tang：开放是一项战略承诺

清华大学教授、ACM/AAAI/IEEE Fellow、GLM-5 共同作者 Jie Tang 在发布前强调「frontier intelligence should remain open-source, accessible, and buildable」，并把 1M 上下文和长时任务能力视为开放 Agent 生态的基础。这是建设者的价值判断，不是独立性能证据。它解释了 MIT 许可、权重发布和多框架适配为何被放在产品叙事中心。[\[S04\]](#)[\[S18\]](#)[\[S19\]](#)

8.3 推理框架团队给出的工程解读

vLLM 与 SGLang 的公开 recipe 把注意力集中在权重内存、KV cache、MTP 接受长度、chunked prefill 和并发上。SGLang 报告在 H200 上对 64K prefill 使用 context parallelism, 可把 TTFT 降低约 2.5 至 2.8 倍, 但会分割 KV pool, 并增加 decode 开销; 8K 输入场景把 chunked prefill 从 2,048 提到 32,768, 在其测试中可提高约 34% 至 78% 输出吞吐。[s10][s11]

这些数据来自框架团队的特定硬件测试, 价值在于给出调优方向。它们不能直接替代自己的工作负载测试(workload benchmark), 因为请求长度、并发、缓存命中和输出长度会改变最优配置。

外部证据的共同方向

GLM-5.2 的开放权重领先地位有独立数据支持。它主要用更多推理 token、更多上下文和更强长轨迹训练换取能力, 效率改进负责把这条路线控制在可服务范围内, 还没有把长时智能变成低成本能力。

09 · SERVING AND ECONOMICS

| 部署与成本: 1M 上下文首先是内存问题

744B 参数意味着 BF16 权重理论下限约 1.49 TB, FP8 约 744 GB, 尚未计入 KV cache、运行时激活、通信 buffer、MTP graph capture 与框架开销。MoE 每 token 只让约 40B 参数参与计算, 但全部专家权重仍要放在 GPU、CPU 或存储层级中。[s10][s11][s12]

9.1 推荐部署形态

目标	推荐路径	公开硬件边界
API / Coding Agent	Z.ai 或第三方托管服务	无需承担权重与 KV cache 基础设施
单节点 FP8	vLLM / SGLang	8×H200/H20 可跑标准配置; 完整 1M 更适合 8×B200
单节点 BF16	SGLang	官方 cookbook 称 8×B300 约 2.1 TB HBM 可容纳
较小 GPU + 大 CPU	KTransformers / KT-Kernel	专家卸载到 CPU, 吞吐与上下文需按硬件重新测量
国产 NPU	vLLM-Ascend、xLLM、SGLang	模型卡列出支持, 具体版本与 kernel 成熟度需核验

完整 1M 上下文的主要变量是 KV cache。IndexShare 降低 indexer 计算, 没有同比缩小每 token KV 大小。并发数越高, 每条请求能分到的 cache 越少。vLLM recipe 把 max-num-seqs 作为 B200 完整 1M 的主调节项, SGLang 还提供分层 KV cache, 把冷 block 移到主机内存。[s01][s10][s11]

9.2 High、Max 与非思考模式

GLM-5.2 默认开启 thinking，公开模板只有 High 与 Max 两个有效 effort。未传参数时为 Max，high 才会降低推理强度；low 和 medium 在当前 SGLang 模板中也会落到 Max。非思考模式通过 `enable_thinking: false` 关闭。[\[s08\]](#)[\[s10\]](#)[\[s11\]](#)

模式	适合	不适合
Non-think	格式转换、抽取、简单问答、低时延工具调用	复杂规划、跨文件修改、数学与长链调试
High	日常编码、明确 bug、局部重构、成本敏感工作流	需要大量探索与反复验证的开放任务
Max	大型迁移、性能优化、研究型代码、数小时 Agent 任务	高频轻任务，容易造成 quota 与 token 浪费

9.3 Preserved Thinking 是状态与缓存契约

Z.ai API 支持在后续轮次保留 `reasoning_content`，Coding Plan 默认开启，标准 API 默认关闭；标准 API 可通过 `clear_thinking: false` 启用。客户端必须按原顺序返回完整、未经修改的连续 `reasoning_content` 块，否则模型性能与缓存命中率可能下降。长任务系统应把它当成不可变协议字段，而不是可随意裁剪的展示文本。[\[s08\]](#)

9.4 价格读法

截至 2026-06-22，Artificial Analysis 记录 Z.ai 第一方 API 每 1M token 的输入、输出与缓存命中价格分别为 \$1.40、\$4.40 与 \$0.26。GLM Coding Plan 中 GLM-5.2 在高峰按 3× quota、低峰按 2× 计，2026 年 9 月底前低峰促销为 1×。这些是产品状态，不应固化成长期架构假设。[\[s09\]](#)[\[s13\]](#)[\[s14\]](#)

10 · LIMITS AND MISREADINGS

| 局限与误读：1M、开放权重和 benchmark 都有边界

GLM-5.2 的公开证据足以支持高水平长任务能力，但不支持把上下文容量、benchmark 排名或 MIT 许可直接换算成生产可靠性。最常见的误读来自五个层面。

10.1 1M 是容量，不是自动记忆

模型能接受 1M token，不代表能在任意位置等概率提取细节，也不代表长轨迹不会被错误工具输出、重复日志和过期计划污染。Artificial Analysis 的 AA-LCR 从 62% 升到 71%，说明长上下文推理改善，但距离满分仍有 29 个百分点；这一分数也不能直接外推为 1M 全位置的稳定检索能力。发布方没有公开覆盖 1M 全长度的独立检索曲线或真实仓库退化曲线。[\[s13\]](#)

长任务仍需要结构化状态：当前目标、已完成步骤、失败尝试、修改过的文件、待验证断言与关键工具结果。把全部 shell 输出和历史对话原样堆进上下文，会增加成本，也会让重要信息在大量低价值 token 中变得难以检索。

10.2 开放权重不等于可复现训练

GLM-5.2 权重与代码采用 MIT 许可，可商用、修改和再分发，这是宽松的开放权重条件。训练语料、数据清洗规则、完整训练配置、算力预算和 5.2 后训练数据没有全部公开，因此第三方无法按现有材料从零复现同一模型。严谨表述应是「MIT 许可的开放权重模型」，而不是把它与完整可复现的开源训练工程画等号。[S02][S04]

10.3 benchmark 与 harness 绑定

官方 Terminal-Bench 同时列出 Terminus-2 和 best reported harness，两行结果不能混用。FrontierSWE 为不同模型使用 Claude Code、Codex 或 Gemini CLI；PostTrainBench 也使用原生 CLI。模型、系统提示、工具实现、超时、上下文压缩与网络策略共同决定成绩。生产选型应固定同一 harness，至少重复 3 次，再比较成功率、时间与成本。

10.4 更长推理会放大成本与偏航

Artificial Analysis 测得 GLM-5.2 平均每任务输出 43K token，其中约 37K 为 reasoning，高于主要开放权重同行。更多推理 token 可以支持复杂搜索，也会带来更长等待、更高费用和更多错误分支。High 与 Max 的选择应由任务价值决定，不能把 Max 设成所有请求的固定默认。[S13][S14]

10.5 反作弊模块本身也会误判

规则筛选追求召回率，LLM judge 负责提高精确率，仍可能把合理的依赖下载、源代码搜索或评测文件读取判成作弊。返回占位信息允许 rollout 继续，但也可能把任务带到新的错误状态。公开材料没有给出 precision、recall、误杀率或对最终能力的消融，企业应用需要保留审计日志和人工复核入口。

边界

GLM-5.2 已经证明长上下文可以与强编码 Agent 结合。它还没有证明百万 token 能替代检索、任务状态、权限隔离、可重复评测和人工验收。

实践方法：怎样判断 GLM-5.2 是否适合自己的任务

模型选择应从任务持续时间、可验证性、上下文规模和失败成本出发。GLM-5.2 最有优势的场景，是有明确环境、有自动验证、需要多轮工具调用，并且单次任务价值足以覆盖较长推理的工程工作。

11.1 一个大型仓库迁移例子

假设要把 80 万行单体仓库中的认证模块迁到新接口，任务包含依赖追踪、数据模式(schema)兼容、实现、测试与性能回归。1M 上下文不应一次塞满仓库，而应按四个阶段组织。

- 1. 建立任务状态：先读入口、接口定义、调用图和测试，输出文件清单、不可变约束与风险。与目标无关的生成文件、历史日志和 vendor 代码不进入上下文。
- 2. 固定验收：在修改前运行基线测试，记录 API 行为、时延和错误路径。隐藏测试与评分脚本对 Agent 只读或不可见。
- 3. 分片实施：每完成一个可独立验证的 slice 就运行窄测试，压缩已经确认的历史，只保留结论、diff 和未解决问题。常规修改用 High，跨模块设计与反复失败的部分切到 Max。
- 4. 独立复核：在新会话或独立 Agent 中只给规格、diff 和测试，检查是否通过修改评测、跳过错误或引入未声明依赖取得成功。

这个流程把 1M 用作可扩展工作区。可恢复任务状态和逐步验证负责约束执行，长上下文负责减少重复加载与跨阶段信息损失。

11.2 内部评测的最小集合

维度	最低要求	记录指标
任务	20 至 50 个真实任务，覆盖常规、困难与失败样本	完成率、回归率、人工修改量
Harness	固定工具、system prompt、权限、超时与 compaction	工具调用数、失败类型、违规调用
重复	高价值任务至少 3 次	均值、方差、最差结果
经济性	同时测 High、Max 与现有模型	token、时间、API 成本、GPU 时
长上下文	按 32K、128K、400K、1M 分桶	正确率、首 token 时延(TTFT)、吞吐、显存溢出(OOM)

11.3 选型建议

优先选择 GLM-5.2，当任务持续一小时以上、仓库或资料规模很大、需要多轮工具反馈，并且有测试或 verifier 可以约束结果。开放权重与 MIT 许可也适合需要本地控制或定制推理栈的团队。

先做小规模试验，当日常工作主要是短补全、简单问答和低时延对话。GLM-5.2 的 43K 平均输出 token 暗示 Max 模式可能过度消耗，High 或更小模型可能有更好的单位成本。

不要把自托管当默认。FP8 权重仍接近 744 GB，完整 1M 还要大量 KV cache。只有在请求量、数据边界、定制需求或长期成本能覆盖 8 卡高端节点与运维时，自托管才合理。

上线门槛：在固定 harness 下，GLM-5.2 应同时改善任务完成率或人工返工量，并把单任务成本 and p95 完成时间控制在可接受范围。只提高 benchmark 或平均成功率，不足以替换现有生产模型。

12 · GLOSSARY AND SOURCES

术语表、延伸阅读与来源

12.1 关键术语

术语	本文含义
DSA	DeepSeek Sparse Attention。用轻量 indexer 为每个 query 选择 top-k 历史 token，再做稀疏注意力。
配置最大序列长度	max_position_embeddings 声明的位置索引上限；它约束模型可表示的序列长度，但实际服务上下文还受推理框架、KV cache、显存、并发和 API 配额约束。
IndexShare / IndexCache	跨层复用稀疏注意力索引。IndexCache 是论文方法名，IndexShare 是 GLM-5.2 发布中的产品称呼。
MTP	Multi-Token Prediction。草稿模型一次预测多个后续 token，目标模型并行验证。
KVShare	GLM-5.2 MTP 中复用第一步的 KV cache，使后续 draft step 只访问目标模型产生的历史 KV；不同于泛指的 KV cache 共享。
接受长度	一次推测解码中，平均被目标模型接受的连续 draft token 数。
OPD	On-Policy Distillation。教师对当前策略正在访问的状态提供监督，减少离策略分布差异。
Compaction	把长轨迹压缩成摘要或子轨迹，保留任务状态并继续执行。
critic-based PPO	基于 critic 的近端策略优化(Proximal Policy Optimization)，用价值模型估计 token 级 advantage，适合数量和长度不一致的单条 rollout。
KV cache	保存历史 token 的 key/value，减少自回归解码重复计算；长上下文下通常成为主要内存开销。
Harness	模型之外的 Agent 运行环境，包括 system prompt、CLI、工具、权限、超时和上下文管理。

12.2 Further Reading

1. 最佳起点: Z.ai, [GLM-5.2: Built for Long-Horizon Tasks](#)。覆盖全部 5.2 新增模块与官方评测。
[S01]
2. 架构基线: GLM-5 Team, [GLM-5: from Vibe Coding to Agentic Engineering](#)。理解 744B MoE、DSA、MTP 与异步 Agentic RL。[S04]
3. 注意力方法: Bai et al., [IndexCache: Accelerating Sparse Attention via Cross-Layer Index Reuse](#)。给出跨层索引复用的完整动机与实验。[S05]
4. 独立测量: Artificial Analysis, [GLM-5.2 is the new leading open weights model](#)。同时看 intelligence、成本和 token 用量。[S13]
5. 部署起点: [vLLM recipe](#) 与 [SGLang cookbook](#)。包含 FP8、1M KV cache、MTP 与硬件边界。
[S10][S11]

12.3 完整来源

1. [S01] Z.ai, GLM-5.2: Built for Long-Horizon Tasks, 2026-06-17.
2. [S02] zai-org, GLM-5.2 Hugging Face Model Card.
3. [S03] zai-org, GLM-5.2 `config.json` .
4. [S04] GLM-5 Team, GLM-5: from Vibe Coding to Agentic Engineering, arXiv: 2602.15763.
5. [S05] Bai et al., IndexCache, arXiv: 2603.12201.
6. [S06] Li et al., Breaking Entropy Bounds, arXiv: 2606.12370.
7. [S07] THUDM/slime repository and documentation.
8. [S08] Z.ai Developer Docs, Thinking Mode.
9. [S09] Z.ai Developer Docs, GLM Coding Plan Overview.
10. [S10] vLLM Recipes, zai-org/GLM-5.2.
11. [S11] SGLang Documentation, GLM-5.2.
12. [S12] KTransformers, GLM-5.2 Tutorial.
13. [S13] Artificial Analysis, GLM-5.2 launch analysis.
14. [S14] Artificial Analysis, GLM-5.2 model page.
15. [S15] FrontierSWE leaderboard and task pages.
16. [S16] PostTrainBench leaderboard, methodology and changelog.
17. [S17] SWE-Marathon benchmark site.
18. [S18] Jie Tang, GLM-5.2 release commentary, 2026-06-13.
19. [S19] Tsinghua KEG, Jie Tang academic homepage.

12.4 边界说明

本文是独立技术解读, 不代表 Z.ai、评测平台或论文作者。发布方 benchmark 均标为官方结果, 外部平台结果按各自 harness 与页面日期引用, 本文计算均基于公开数字。后续若模型卡、排行榜、价格或框架 recipe 更新, 应重新核验时效性内容。