

大模型 OPD：让学生在 自己的错误上学习

这里的 OPD 指 on-policy distillation，中文可称在线或在策略蒸馏：学生模型先按当前策略生成轨迹，教师再在这些学生访问过的状态上给 token、prefix、sequence 或 trajectory 级监督。

证据复核
2026.06.12 CST
公开材料截至 2026.06.10
证据等级: A 为论文或官方报告, B 为研究机构解释

1/10

Qwen3 Table 21 报告 OPD 用约 1,800 GPU hours，对照 RL 为 17,920。S02

4

2026 公开工业报告已把 OPD 用于多教师、跨阶段、能力合并和回归恢复。S04-S07

2x-47x

Prefix OPD 报告的 training FLOP 降幅，前提是任务信号集中在前缀。S08

3类

探索不足、高方差或错配梯度、teacher-student 分布差距，是 2026 方法主要在修的失败面。S09 S10

核心判断

OPD 不是“更会模仿的 SFT”，而是把模仿发生的位置改成学生真实会到达的位置。

当部署学生会犯自己的错时，静态教师答案不够。纯 SFT 让学生看教师轨迹，RL 给学生自己的轨迹打稀疏分。OPD 把两者合并：样本来自学生，监督来自教师，所以它最适合长链推理、代码、工具调用、多阶段后训练和小模型压缩。

SEED	先用 SFT、off-policy distillation 或 RL checkpoint 让学生进入教师可修复的支持集。
ROLLOUT	学生按当前策略生成答案、推理链、工具调用或 agent trajectory。
RELABEL	教师在学生轨迹上给 logprob、偏好、过程分或 hindsight hint。
UPDATE	用 reverse KL、advantage-weighted loss、prefix loss、trust region 或 asymmetric objective 更新学生。
AUDIT	教师退出评测闭环；同时记录 teacher 调用成本、collapse、遗忘和 out-of-domain 表现。

2026 前沿谱系

主线不是换一个损失函数，而是在“谁 rollout、谁监督、哪些 token 可信、何时停”上做工程约束。

Baseline OPD	学生 rollout，教师给 dense token-level feedback，缓解 exposure bias；适合从强 SFT checkpoint 继续提升。	S01 S02
Multi-teacher	MiMo、GLM-5、Nemotron、DeepSeek-V4 都把 OPD 用作领域能力合并、跨阶段保留或回归恢复的后训练部件。	S04-S07
Prefix OPD	只对学生生成前缀做蒸馏并提前停止 rollout，把教师评估集中在早期分叉 token，报告降低 FLOP。	S08
AOPD	把正优势的强化和非正优势区域的局部散度最小化分开，针对高方差、零优势区和弱初始化探索瓶颈。	S09
TrOPD	只在教师监督可靠的 trust region 做 OPD，对 outlier 区域采用 clipping、masking 或 forward KL guidance。	S10
Agentic OPD	把用户反馈、工具输出和环境 next-state 转为 hindsight hint，再给 token-level directional supervision。	S12

什么时候用

- 01 学生小、便宜、要部署，教师大、贵、可离线打分。
- 02 任务长，早期错误会滚雪球，静态教师轨迹覆盖不到学生状态。
- 03 已有 SFT 或 RL checkpoint，目标是补强、压缩、合并或抗遗忘。

什么时候慎用

- A 学生太弱，rollout 大量落在教师也难修的坏区域。
- B teacher logits 不可得，tokenizer 不一致，或教师调用成本超过 RLVR。
- C 评测仍由同一教师主导，容易把风格贴近误读为能力提升。

落地配方

先离线蒸馏建支持集，再短周期 OPD；先全量找信号，再用 prefix、entropy、trust region 或 asymmetric objective 降成本；最后用无教师评测守住事实、代码、推理、工具和安全边界。

一句话

OPD 的价值不在“学生更像教师”，而在“学生在自己会犯错的位置获得密集纠偏”。