

多阶段排序算法 技术路线

国内外头部互联网平台在召回、粗排、精排、混排与重排阶段的公开算法路线和工程经验总结

Winston

资料核验截至 2026-05-27

Industrial papers · official engineering disclosures · production evidence

目录

01	执行摘要：漏斗仍是工业系统的骨架	结论、证据边界与阅读方式
02	为什么在线排序必须分阶段	规模、延迟、特征与目标
03	召回：先保证候选有机会进入比赛	多路、双塔、图与生成检索
04	粗排：以有限计算保存精排上限	蒸馏、成本约束与一致性
05	精排：高价值特征进入逐项决策	兴趣、长序列与多目标
06	混排与重排：最终页面是一项列表决策	多样性、约束与生成重排
07	训练、评测与在线学习	偏差、跨阶段对齐与护栏
08	国内平台公开路线	淘宝、京东、字节、快手、美团、腾讯
09	海外平台公开路线	Google、Meta、Pinterest、LinkedIn 等
10	实施路线与常见误区	从诊断到全量的决策门禁
11	附录与进一步阅读	术语、证据地图与阅读入口

执行摘要：漏斗仍是工业系统的骨架

从数十亿物品或内容中在毫秒级交付一个页面，算法团队无法把最重的模型施加于所有候选。公开资料显示，头部平台仍把在线决策分成召回、粗排、精排与最终重排，区别在于每一层都在吸收更强的序列建模、多目标学习与生成能力。

FUNNEL

分阶段来自计算边界

YouTube 把百万候选缩为数百再精排；Instagram Explore 明确公开 retrieval、first-stage ranking、second-stage ranking 和 final reranking 四层。
[S01][S04]

RETRIEVAL

召回开始表达更深意图

MIND、KuaiFormer、PinRec 与 LinkedIn LLM 双编码器分别展示多兴趣、短视频序列、生成检索与语义向量路线。
[S09][S11][S22][S31]

RANKING

精排在扩容，也在守时延

DIN、DIEN 与 SIM 处理目标相关兴趣和长行为，RankMixer、MTGR 及 Meta GEM 扩大模型容量或迁移知识，同时保留在线成本约束。
[S05][S20-S21][S23][S30][S34]

SLATE

末端决定整页效用

淘宝、快手、美团与 Airbnb 的公开工作把多目标、多样性或上下文交互留在重排层处理，生成模型先进入小候选、高价值决策位置。
[S17][S26-S27][S32-S35]

公开证据能说明到哪里

证据强度	代表材料	可使用的结论	不能外推的内容
A 论文或官方架构	YouTube、Instagram、淘宝、Pinterest、LinkedIn、Airbnb	阶段分工、方法、部署说明与所报实验范围	未公布特征、流量分配与跨业务复用
B 公开预印本	RankMixer、快手、美团、腾讯广告	作者报告的架构、场景和线上结果	经外部复核的长期经营结论
C 产品说明	Netflix 排序说明、Amazon 科学历史稿	产品层排序行为或方法演进	未公开的漏斗模型实现

研究结论

新模型更可能沿着漏斗逐层替换能力：召回获得更强的语义覆盖，粗排学习如何保留精排会选中的对象，精排扩大序列和交互建模，重排负责整页目标与显式约束。可复用的经验来自这种分工以及相应的验证方法。

为什么在线排序必须分阶段

一个在线请求同时面对巨大物品库、极短响应时间、昂贵特征和相互冲突的产品目标。漏斗把计算花在越来越少、越来越值得精确判断的候选上，并让每一层拥有可以验证的责任。

候选数下降，单个候选可用的计算上升



漏斗为同一请求分配不同计算强度；末端候选最少，却承担最完整的页面责任。

四项分层理由

现实约束	对算法的要求	公开例证
候选空间巨大	召回使用可索引、可近邻查找或可约束生成的表示，优先保证覆盖。	YouTube 近邻候选生成；Instagram 多路来源；淘宝多通道商品召回。[S01][S04][S25]
延迟与计算有硬上限	昂贵交互和长序列留给缩小后的候选；粗排防止好候选过早丢失。	Google Play 报告毫秒级服务；COLD 联合优化粗排效果与成本。[S02][S24]
目标不止点击	精排估计多个行为价值，重排处理整页目标、配额和多样性。	YouTube 多目标排名；淘宝 CMR、SORT-Gen；Airbnb 多样性排序。[S03][S17][S26-S27]
反馈受曝光影响	上游筛掉的候选没有下游反馈，训练和评测要处理选择偏差。	LinkedIn 用小流量随机化近似二阶排序反馈；Airbnb 以流量回放评测召回。[S10][S18]

阶段名称在不同团队中并不完全一致。搜索论文常写 retrieval、coarse ranking、fine-grained ranking 和 mixed ranking；内容推荐更常写 retrieval、first-stage ranking、ranking 与 reranking。本文按工程职责统一术语，不把名称差异写成架构差异。

召回：先保证候选有机会进入比赛

召回层的失误无法被下游挽救：没有进入候选集的商品、帖子或广告，不会被精排重新发现。因此召回评估关注覆盖和增量贡献，也必须把索引更新、过滤和服务延迟视作模型的一部分。

从多路候选到更强表示

技术路线	输出与优势	代表公开实践	上线观察项
规则、热度与多路检索	不同来源提供实时性、稳定性、探索或安全保底。	Instagram 融合实时与预生成来源；LinkedIn 旧结构由多种 first-pass ranker 供给二阶排序。 [S04] [S10]	去重后贡献、来源偏置与新鲜度。
双塔与近似近邻	离线计算物品向量，在线计算用户或查询侧，适合大库存。	YouTube、Amazon 商品语义搜索、Airbnb EBR 与 Instagram 都公开过这一类服务路线。 [S01] [S04] [S13] [S18]	Recall@K、索引更新、过滤后延迟和冷启动。
多兴趣与图召回	一个用户或对象由多个局部兴趣表示，扩展覆盖与多样性。	Tmall MIND 以多个兴趣向量检索；Pinterest PinSage、PinnerSage 用图和多模态兴趣表示服务推荐。 [S06-S07] [S22]	冗余候选、热门集中与缓存成本。
序列或生成式召回	下一动作预测或生成候选标识，表达短期意图与目标条件。	KuaiFormer 作者报告已用于快手召回；PinRec 探索生成检索；LinkedIn 使用共享 LLM 双编码检索。 [S09] [S11-S12] [S31]	无效候选、生成延迟、多样性与回退渠道。

电商召回展示了多目标并非末端专属

淘宝搜索公开架构包含多通道召回、级联排序和异构结果混排。MOPPR 在检索阶段同时优化相关性、曝光、点击与购买，论文报告其自 2021 年双十一后替换既有向量召回模型，并在 28 天在线实验中报告交易及 GMV 提升。京东论文也将语义召回和 pairwise 深度重排作为商品搜索的两个关键阶段。[\[S25\]](#)[\[S28\]](#)

这一经验适用于多数交易场景：召回不只追求相似。对于有价格、库存和转化目标的市场，过早只以点击或语义近邻筛选，会让后续排序看不到可能成交的候选。召回层可以接受下游目标监督，同时仍需保持多路覆盖和可承受的服务成本。

召回层的工程检查

按来源报告去重后覆盖、长尾覆盖、新物品覆盖以及与精排 top-K 的重合率，再观察线上点击、购买或观看的增量。双塔服务还要记录物品索引更新滞后、过滤后候选不足和 ANN 查询尾延迟；生成召回另加无效标识、重复生成与回退触发率。

粗排：以有限计算保存精排上限

粗排位于候选已经可控、精排仍然太贵的位置。它的质量不宜只用自身点击标签衡量，更应看它是否把精排和最终页面会需要的候选保留下来。

三条公开路线

问题	路线	公开实践	判断
轻模型过早丢掉好候选	以较重排序器输出作为监督，让粗排拟合下游选择。	Instagram 的 first-stage ranker 学习 second-stage top-K 标签，将其表述为知识蒸馏。[S04]	粗排老师来自下游价值，比重复曝光标签更合理。
简化模型牺牲交互能力	在计算预算内保留交叉特征，以系统优化承载更强模型。	Alibaba COLD 将模型和计算成本联合优化，自 2019 年起用于涉及预排序模块的展示广告产品。[S24]	粗排是独立的成本约束学习问题。
候选选择造成训练偏差	随机暴露少量候选，测量与二阶排名 top-K 的重合。	LinkedIn first-pass candidate selection 以 recall 对 second-pass 结果评估，并报告项目中 recall 翻倍。[S10]	需要探索或校正样本看见被历史策略遮住的候选。

粗排还要把来自不同召回源的候选带入统一比较空间。召回源的分值通常不可直接比较，YouTube 早期论文已经指出精排需要整合不同来源；Instagram 与 LinkedIn 则公开了来源融合后再排序的在线结构。[S01][S04][S10]

粗排验收口径

主指标包括对精排或最终列表 top-K 的 Recall@K、各召回源的保留率以及尾延迟，不只是一项独立 AUC。粗排换模时同时观察长尾、新内容、低曝光商家或创作者，避免系统在早期失去探索空间。

精排：高价值特征进入逐项决策

候选降到百级后，系统才有余量计算目标相关兴趣、长序列、交叉特征和多个行为目标。精排通常仍以单个候选的价值预测为中心，为末端列表决策提供可靠的逐项估值。

精排模型能力沿三条方向扩展

扩展方向	算法含义	平台证据	落地经验
候选相关兴趣	按当前候选激活历史中有关部分，再刻画兴趣演化。	Alibaba DIN 部署于展示广告主流量；DIEN 报告经工程优化将服务延迟由 38.2 ms 降至 6.6 ms，并服务主流量。 [S20-S21]	效果和延迟优化应同时验收。
超长行为序列	先从长期行为检索相关片段，再在可控范围精细交互。	Alibaba SIM 报告自 2019 年部署于展示广告，处理长期序列并报告 CTR 与 RPM 提升。 [S23]	序列价值依赖检索压缩和在线存储。
可扩展主干与序列 ranker	使用硬件友好结构或用户级压缩，把更大模型放进排名请求。	RankMixer 作者报告在抖音推荐全流量运行；MTGR 作者报告承载美团外卖主流量；Pinterest TransAct 已部署于多个推荐面。 [S08] [S30] [S34]	扩参前核算请求组织、GPU 利用和近实时特征。

多目标需要保留拆解能力

YouTube 排名工作从观看时间目标进一步公开多任务排序，处理多种行为目标和反馈选择偏差。Google Play 的 Wide & Deep 表明，在生产排序中记忆已发生的特征组合与泛化到新组合都重要。Meta GEM 官方稿描述了另一条路径：训练更大的广告基础模型，以知识迁移增强对延迟敏感的下游模型，并报告 Facebook 和 Instagram 广告转化的上线效果。[\[S02-S03\]](#)[\[S05\]](#)

这些系统没有要求把所有业务目标压入同一在线巨型模型。精排可以输出点击、观看、购买和负反馈等预测，由价值函数或重排层决定特定页面与流量条件下的组合。这样安排使业务调整不必每次重新训练最昂贵的在线部分。

混排与重排：最终页面是一项列表决策

精排逐项估值仍不足以交付页面。重复内容、同类扎堆、库存与广告约束、创作者或商家覆盖，以及位置间相互影响，都要在看到候选列表时处理。

末端处理的三类冲突

冲突	重排任务	公开实践	不能省略的护栏
逐项价值与列表效用	考虑候选交互，选择整页顺序。	SORT-Gen 将点击、转化和 GMV 的列表级目标写为生成重排，论文报告在淘宝百亿补贴场景的 CLICK 与 GMV 改善。 [S27]	库存、去重、合规和回退要在输出后复核。
固定权重与时段变化	同一模型在服务时接受目标偏好，减少反复训练。	Taobao CMR 使用 policy hypernetwork 控制多目标权重，并报告在线 A/B 验证。 [S26]	偏好范围和监控阈值应预设。
准确率与多样性	避免高分相似项占满列表，为不同选择留下空间。	Airbnb 从启发式走到 RNN 上下文列表方案；Instagram final reranking 明确加入最终规则控制。 [S04] [S17]	多样性要连同预订、满意度或负反馈实验。

生成式重排先在小集合内成立

生成列表能够表达候选之间的关联，也会引入解码延迟和约束失配。快手 NAR4Rec 使用非自回归生成降低实时重排成本，作者称已部署于快手；其 Dual-Rerank 预印本继续以自回归教师、非自回归学生和在线强化学习处理质量与延迟。美团 NSGR 以树状逐级生成处理局部和全局关系，作者报告已部署于外卖平台。[\[S32-S33\]](#)[\[S35\]](#)

这些工作支持一项稳健实施选择：生成式排序从候选已缩小、约束可检查、失败可回滚的重排层切入。判别式精排给出稳定逐项价值，生成或组合优化处理列表结构，两者无需互相取代。

混排与重排指标


除 CTR、观看、转化和 GMV 外，记录重复率、来源集中度、负反馈、广告或自然结果约束违例、库存失效与页面响应尾延迟。短期点击改善而供给多样性明显退化，不能视作稳定升级。

训练、评测与在线学习

多阶段系统的主要风险来自目标错配：召回以历史点击训练，粗排保留自己熟悉的候选，精排只能在已有曝光上学习，重排再把短期高收益推到更靠前的位置。工程上需要为每层建立目标、教师、随机样本和护栏的对应关系。

阶段之间如何传递监督

FIGURE 2 跨阶段监督、曝光偏差与线上验证



上游模型学习保留下游需要的候选，线上实验检验收益与风险；随机探索用于观察历史策略没有展示过的选项。

评测口径按层拆开

阶段	离线指标	线上结果与护栏	典型偏差
召回	Recall@K、coverage、新物品和长尾覆盖、增量重合	下游点击、观看或购买增量；索引新鲜度和 p99	未曝光候选没有标签，热门偏置加深
粗排	对精排 top-K 的 recall、各来源保留率、校准	精排输入质量、吞吐和尾延迟	以自身点击标签训练，提前淘汰下游高值项
精排	AUC/GAUC、NDCG、多任务损失与切片稳定性	观看、点击、交易、负反馈和算力	位置偏差、稀疏转化、短期目标支配
混排/重排	列表效用、多样性、约束违例与重复率	整页效用、供给分布、投诉和服务成本	局部指标改善而页面体验或治理受损

实时更新依赖可追踪的服务面

ByteDance Monolith 关注稀疏嵌入的实时训练和参数同步，为快速变化的反馈提供系统背景，并不是一份抖音完整漏斗说明。LinkedIn Feed 工程稿详细描述特征跟踪、数据包部署与异步日志汇总，模型发布速度由三天缩至三十分钟。两者都说明，更新频率的价值依赖训练与在线特征的一致记录。^{[s10][s29]}

国内平台公开路线

国内工业论文在淘宝广告和搜索、短视频推荐以及本地生活推荐上形成了密集的公开链路。它们分属不同业务面，不能拼成某家公司唯一的线上架构，却能准确展示各阶段的工程选择。

Alibaba：从匹配到重排的公开纵深

阶段	系统与位置	公开陈述	可迁移经验
召回	MIND 在 Tmall 首页学习多个兴趣向量；MOPPR 位于淘宝搜索多通道召回。	MIND 论文说明已处理主要线上流量；MOPPR 报告移动淘宝搜索部署及 28 天实验结果。 [S22] [S25]	召回可接受购买目标监督，同时保持多路覆盖。
粗排	COLD 面向展示广告 pre-ranking。	论文称自 2019 年部署于涉及预排序模块的多项展示广告产品。 [S24]	预算内保留交互能力优于机械截小精排。
精排	DIN、DIEN、SIM 形成兴趣激活、演化和长期行为检索路线。	三篇论文均报告在线部署或主流量服务，DIEN 还披露服务延迟降低。 [S20-S21] [S23]	模型创新和服务优化应同时说明。
重排	CMR 动态控制多目标偏好，SORT-Gen 直接生成列表。	CMR 为 KDD 2023 工业论文；SORT-Gen 为 SIGIR 2025 论文并报告多场景部署。 [S26-S27]	促销和目标冲突适合在末端管理。

京东、ByteDance、快手、美团与腾讯

平台	公开阶段	关键材料与事实范围	证据限制
京东	召回、精排	商品搜索论文分别设计语义召回和 pairwise 深度重排，并报告线上核心指标改善。 [S28]	覆盖搜索，不外推首页推荐。
ByteDance / 抖音推荐	实时系统、精排	Monolith 公开实时训练基础设施；RankMixer 作者报告十亿参数版本在抖音 Feed Ranking 全流量服务。 [S29-S30]	RankMixer 以预印本作者声明使用。
快手	召回、重排	KuaiFormer 作者报告 2024 年 5 月接入短视频召回；NAR4Rec 和 Dual-Rerank 描述低延迟生成重排演进。 [S31-S33]	新重排结果不作长期效果证明。
美团	排序、重排	MTGR 保留交叉特征并扩大序列模型，作者称服务外卖主流量；NSGR 报告树状生成重排部署。 [S34-S35]	部署结论来自作者预印本。
腾讯广告	召回、评测	GPU feature-interaction 双塔论文报告广告召回部署；TencentGR 提供全模态生成推荐数据和基线。 [S36-S37]	数据集不证明完整线上漏斗。

国内路线的共同点

电商、广告、内容流和本地生活的目标不同，却都把实时反馈、新鲜度与多目标留在系统设计中心。更大的序列模型或生成方法进入生产时，公开论文最常讨论的仍是候选截断、延迟、成本、反馈偏差和最终列表约束。

海外平台公开路线

海外材料的优势在于架构叙述清楚: YouTube 和 Instagram 给出了漏斗, Pinterest 与 LinkedIn 说明检索和排名如何随表示模型更新, Airbnb 展示市场约束如何改变检索与列表, Amazon 与 Netflix 则划定商品和页面层的公开边界。

内容流与社交推荐

平台	漏斗演进	工程要点	来源
Google / YouTube	深度候选生成缩到数百项, 再以丰富特征按预期观看时间精排; 后续扩展至多目标。	离线指标与实时 A/B 未必一致; 召回和精排分别训练和验收。	[S01-S03]
Meta / Instagram	官方稿明确四层 Explore 漏斗; Ads 的 GEM 将大模型知识迁移至下游模型。	缓存、预计算和蒸馏使重模型进入不同阶段; Explore 与 Ads 分开归因。	[S04-S05]
Pinterest	PinSage 图召回、PinnerSage 多兴趣、TransAct 实时序列精排, 再到 PinRec 生成召回探索。	短期实时行为和长期批量表示可以组合, 生产模型同时控制成本和多样性。	[S06-S09]
LinkedIn	two-pass Feed 从候选选择到二阶排序; 新系统以 LLM 双编码检索并引入生成序列排名。	官方稿报告近线 embedding 更新和 sub-50ms 检索; 候选选择仍管理公平与新鲜度。	[S10-S12]

市场、商品与页面型系统

平台	直接证据	可确认的经验	边界
Amazon	商品语义搜索与官方推荐历史说明	商品检索需区别曝光未购买和购买信号; item-to-item 是早期大规模推荐路线。[S13-S14]	不据研究稿复原当前商城全链路。
Airbnb	embedding personalization、深度排名、多样性及 EBR 官方稿	供给按日期可售, 召回索引承受价格、可用性更新和地域过滤; 最终搜索管理多样性。[S15-S18]	两边市场目标不同于内容流。
Netflix	官方推荐说明	主页对行和行内标题均作个性化排序, 并考虑观看、时间、语言和设备等输入。	未公开召回、粗排或具体模型, 只作产品行为证据。[S19]

海外路线的共同点

可持续改造都把模型能力放进既有服务约束: 近线更新改善新鲜度, 蒸馏或缓存控制延迟, 多目标与列表规则留在可审计位置。业务差异决定优化对象, 观看、购买、预订、广告转化和职业对话不能混写为同一种奖励。

实施路线与常见误区

多阶段系统的升级从可诊断的问题出发：缺候选、早截断、价值预测不准，或最终列表不合适。新模型安放在错误层位，常会获得漂亮的离线数值，却找不到线上收益来源。

从问题到首个实验

症状	先改阶段	最小可行试验	成功门槛
长尾、新内容或新商品进不了后续层	召回	新增一条双塔、图或生成候选源，与旧源去重融合。	对精排 top-K 的增量 recall 与线上增量为正，尾延迟可控。
精排会选的高值项在前层被过滤	粗排	以精排 top-K 蒸馏粗排，加入随机曝光评测切片。	候选保留率提升，精排吞吐与整体延迟不恶化。
实时兴趣或长行为未被利用	精排	在有限流量接入候选相关兴趣或压缩后的序列模型。	多目标线上收益成立，GPU/CPU 和服务 P99 在预算内。
高分结果重复或页面规则复杂	混排/重排	固定上游候选，仅替换列表优化器，保留规则回退。	页面效用改善，且多样性、投诉和约束违例不恶化。

分层发布门禁



每个阶段先证明没有破坏下游选择空间，再用线上实验确认产品价值。

五种高频误区

误区	为什么失败	修正办法
只提高召回自身点击	召回迎合历史曝光，减少新物品和精排可能偏好的候选。	以精排或最终列表 top-K 为老师，保留探索切片。
把粗排视为缩水精排	候选数和预算不同，简单删特征会丢失交互信息。	采用成本感知建模、蒸馏与专门服务优化。
用离线 AUC 取代线上判断	曝光、位置和产品目标使离线排序无法代表真实选择。	预注册线上主指标、护栏和回退阈值。
让生成模型接管全链路	目录覆盖、延迟、约束和故障范围同时扩大。	从生成候选通道或小集合列表重排起步。
跨平台搬运指标	观看、购买、预订、广告转化与对话贡献不是同一目标。	迁移结构经验，重新定义本业务数据和效用函数。

交付系统还应固定审计面：候选来源、模型版本、训练和服务特征时间戳、策略过滤原因、实验分桶、延迟预算以及回退动作。没有这些记录，即使观察到收益，也难以定位收益来自表示提升、流量偏差还是规则变化。

11 · APPENDIX

附录与进一步阅读

本文可以独立建立多阶段系统的技术坐标；需要继续进入实现细节时，下列论文和官方工程稿是合适的原始入口。编号与 `sources.md`、`data/source-map.tsv` 一致。

首选深读材料

入口	材料	重点阅读问题
漏斗起点	YouTube DNN [S01]	候选生成和精排为何拆开，观看时长目标怎样进入排名。
全阶段	Instagram Explore 官方工程稿 [S04]	四层生产漏斗、蒸馏式粗排和末端规则。
国内纵深	MIND、COLD、SIM、CMR [S22-S26]	召回、粗排、长行为精排和可控多目标重排的连续演进。
实时排名	Pinterest TransAct [S08]	在线短期行为与离线长期表示如何组合进入生产。
市场约束	Airbnb EBR 与 diversity [S17-S18]	库存更新、过滤和列表多样性如何改变推荐设计。

术语表

术语	本文所指含义
召回 / Retrieval	从全库取得有限候选，侧重覆盖、速度和可索引表示；也称 matching 或 candidate generation。
粗排 / Pre-ranking	以低于精排的成本进一步压缩候选，目标是尽量保留下游会选择对象。
精排 / Ranking	对较小候选集使用丰富特征与模型，估计逐项行为价值或多目标价值。
混排 / Blending	将不同来源或类型结果放在统一页面比较、组合并施加策略。
重排 / Reranking	在最终候选上利用上下文、多样性、配额或列表目标决定呈现顺序。
阶段一致性	上游筛选目标与下游或最终页面目标之间的对齐程度，常以 top-K 重合或蒸馏监督衡量。

来源映射摘要

编号	来源组	类型	正文用途
S01-S05	Google/YouTube; Meta/Instagram/Ads	工业论文 / 官方稿	两层与四层漏斗、多目标排名、知识迁移
S06-S12	Pinterest; LinkedIn	工业论文 / 官方稿	图召回、实时序列排名、LLM 检索、two-pass Feed
S13-S19	Amazon; Airbnb; Netflix	论文 / 官方稿	商品语义搜、市场排序、多样性与披露边界
S20-S27	Alibaba / Taobao	工业论文	国内公开覆盖最完整的召回至重排路线
S28-S37	京东; ByteDance; 快手; 美团; 腾讯广告	论文 / 预印本 / 数据集	搜索两阶段、实时系统、扩展排名与生成重排

完整来源标题、链接、阶段分类、用途与核验日期见同目录 `sources.md` 及 `data/source-map.tsv`。预印本涉及线上结果时，正文均以作者报告口径陈述。