

多模态 Embedding/Rerank 后训练 2026: 从对比学习到 SFT、RL 与 OPD

面向搜索、推荐、RAG、视觉商品检索与文档理解系统的后训练方案手册。结论并非“把所有后训练方法套到 embedding 上”，而是按模型决策面拆解：向量召回、late interaction、cross-encoder rerank、生成式 rerank 与检索代理，分别需要不同训练信号。

证据日期：2026-07-07。论文版本、产品能力、榜单结果与工业案例均按该日期解释。

覆盖范围：多模态 embedding、reranker、visual document retrieval、commerce retrieval、OPD/RL 后训练可行性和工程评测闭环。

证据边界：论文和官方仓库作为方法依据；公司论文、博客、产品文档作为工业信号；厂商榜单和 A/B 结果均视为作者报告。

目录

本文先给结论，再展开证据。读者如果只关心落地，可直接读第 6 节和第 7 节。

01 结论摘要：三类模型面，三类后训练

02 问题边界：embedding、rerank 与生成式决策

03 证据图谱：学术路线与工业路线

04 SFT：向量模型的可行路径与误用边界

05 RL：更适合 rerank 与检索代理

06 OPD：适合有轨迹的多模态决策面

07 落地配方：四条可执行训练链路

08 评测、风险与上线门槛

09 决策树与资料索引

结论摘要：三类模型面，三类后训练

多模态 embedding/rerank 后训练的关键，不是选择一个听起来先进的算法，而是先确认模型在哪里做决策。纯向量模型、cross-encoder reranker、生成式 reranker 或检索代理的可优化信号不同，SFT、RL、OPD 的价值也随之改变。

高

Embedding

成熟路线是 instruction-conditioned contrastive tuning、hard-negative curriculum、teacher/reranker distillation、synthetic data 与 MRL。VLM2Vec、VLM2Vec-V2、Qwen3/Qwen3-VL 系列均支持这一判断 [S01][S02][S03][S04]。

高

Rerank

reranker 有明确候选集、排序标签和下游指标，SFT 与 RL 都更自然。MM-R5 用 SFT 构造 reasoning chain，再用 reranking reward 和 reasoning reward 优化；Pailitao-VL 把工业重排推向 listwise compare-and-calibrate [S06][S08]。

中

OPD

OPD 的核心是 student 在自己的状态分布上产生 token 轨迹，teacher 给密集反馈。它适合多模态 reasoning、生成式 rerank、SFT 到 RLVR 的预对齐；对纯 dense embedding 则通常只能作为间接数据和教师信号来源 [S13][S14][S15][S16]。

一句话判断：embedding 后训练不要直接追逐 RL/OPD 名称；先把对比学习、指令化、难负例、蒸馏和评测数据闭环做到位。rerank 或检索代理如果能稳定定义 reward，才进入 SFT plus RL。OPD 放在会生成推理、解释、比较或检索动作的模型面，而不是直接替代向量损失。

方案	对 dense embedding	对 rerank	上线前必须证明
SFT-like 指令调优	高可行，但通常表现为带指令的对比训练或蒸馏，不是传统 token likelihood SFT。	高可行，可训练输入格式、跨模态证据链、yes/no 或 listwise 打分。	跨域 Recall@K、NDCG、难负例鲁棒性、指令迁移收益。
RL	直接做向量训练可行性偏低，常遇到离散 top-k、索引刷新、credit assignment 与高方差问题。	中到高，适合候选集固定、reward 稳定、排序或 answerability 可度量的场景。	reward 与真实业务指标相关，未发生 judge hacking，延迟预算未被打穿。
OPD	直接可行性低到中，因为纯向量编码器没有 token 轨迹；可间接生成更好的 queries、rationales、教师分数。	中到高，尤其是生成式 reranker、视觉推理 reranker、SFT 到 RLVR 的过渡阶段。	student-state distribution drift 下降，OPD 之后 RL 或 rerank 指标真实提升。

问题边界：embedding、rerank 与生成式决策

多模态检索系统通常被拆成召回、粗排、精排、重排和答案生成。embedding 负责把 query、图像、视频、文档页、商品或文本映射到共享空间；reranker 在较小候选集上做更贵的跨注意力或 listwise 比较。二者的训练目标相邻，但不是同一个问题。




图 1: 同一个检索系统中, embedding、rerank、policy 的后训练信号不同。OPD 和 RL 的自然位置通常在右侧的生成式或可行行动决策面。

四个概念必须分开

模型面	输出	主要训练信号	后训练问题
Dense embedding	单向量或少量向量	对比损失、triplet、in-batch negatives、teacher score distillation	让相似项更近、混淆项更远，同时保持跨模态泛化。
Late interaction	多向量集合与 max-sim 聚合	页面 patch/token 级监督、late-interaction ranking loss	保留文档图像细节，换取更高存储和检索计算。
Cross-encoder reranker	候选得分或 yes/no logits	pairwise/listwise SFT、teacher ranking、calibrated labels	让模型在候选集合内做精细比较，而不是负责全库召回。
Generative reranker / retrieval agent	排序、解释、动作、证据链	SFT traces、OPD、RLVR、task reward	对齐推理过程、减少分布漂移，并让 reward 绑定业务目标。

因此，“SFT 是否能训练 embedding”需要拆开回答。如果 SFT 指经典语言模型 token likelihood，它并不是 dense embedding 的主损失；如果 SFT 指面向任务指令、query-document pair、hard negative、teacher score 的监督微调，则它是当前最可落地的后训练范式之一。Qwen3 Embedding/Reranker 与 Qwen3-VL-Embedding/Reranker 的公开资料显示，工业级 embedding 往往使用多阶段训练：无监督或大规模弱监督预训练，随后是任务数据、指令、难负例和 reranker/distillation 信号 [S03][S04]。

证据图谱：学术路线与工业路线

2024 到 2026 年的公开资料给出两个互补方向：学术界把多模态 embedding 从图文检索扩展到文档页、视频、视觉问答和 grounding；工业界把它接入商品检索、推荐、企业 RAG 与统一多模态 API。

学术路线

工作	核心贡献	对后训练的启发
VLM2Vec / MMEB [S01]	把 VLM 转成 embedding model, 使用任务指令和对比学习, 覆盖分类、VQA、多模态检索、视觉 grounding 等任务。	多模态 embedding 的后训练应显式携带任务指令和任务族, 而不是只做通用图文对齐。
VLM2Vec-V2 / MMEB-V2 [S02]	把评测扩展到视频、图像、视觉文档、temporal grounding、video QA 等多任务输入。	评测集必须覆盖模态混合和任务混合, 否则“通用 embedding”只是文本检索或图文检索的局部最优。
ColPali [S05]	直接把文档页面作为图像输入, 生成多向量表示, 用 late interaction 做视觉文档检索。	PDF、票据、合同、长图等场景不应被强行压成单向量。多向量召回能保留布局与局部视觉证据, 但要付出索引成本。
MM-R5 [S06]	用 SFT 构造多模态检索 reasoning chain, 再用任务 reranking reward 和 template reasoning reward 做 RL。	RL 的自然落点是 reranker 和 reasoning surface。它优化的是候选集内排序和解释过程, 而不是直接替代 embedding loss。
Think Then Embed [S07]	在 embedding 前引入 reasoner, 用 embedding-centric reasoning traces 辅助小模型学习。	当 query 需要跨视觉、文本和隐含意图推理时, 先生成可控上下文, 再训练 embedding 或 reranker, 往往比盲目扩大向量模型更有效。

工业路线

系统或模型	公开信号	落地含义
Qwen3-VL-Embedding/Reranker [S04]	多阶段训练、contrastive pretraining、reranking model distillation、MRL、32k context、多语言和多模态输入。	“embedding plus reranker”应作为一套共同训练和共同评测的系统，而不是两个互不校准的模型。
Pailitao-VL [S08]	阿里视觉商品检索工业论文，召回从 contrastive learning 走向 absolute ID recognition，重排从 pointwise 走向 listwise compare-and-calibrate。	超大商品库的后训练不只关心 pair 级相似，还关心 ID 级可识别性、候选集比较和业务分布。A/B 与 GMV 结果按作者报告处理。
Gemini Embedding 2 [S09]	Google 发布 native multimodal embedding，覆盖文本、图像、视频、音频，论文描述大规模多任务、多阶段对比训练。	闭源 API 路线证明统一多模态 embedding 已成为产品能力，但训练细节和长期稳定性需要本地评测兜底。
Amazon Nova Multimodal Embeddings [S10]	AWS 文档给出统一语义空间、模态输入和上下文限制。	企业落地要把模型能力转成输入规范、分片策略、批处理、异步任务和成本控制，而不是只看榜单。
PinCLIP / MML-TP [S11][S12]	Pinterest 和 Amazon 的公开资料强调多模态 representation、邻居对齐、在线文本清洗和商品搜索噪声处理。	电商和推荐系统的关键不是“更大 VLM”，而是多模态数据质量、属性噪声、近邻结构和线上分布。

证据合流：学术界提供任务扩展、损失函数与评测基准；工业界提供长尾商品、文档、视频、API、延迟和线上分布压力。可靠方案必须同时解释二者，否则会变成只在 benchmark 上漂亮、上线后无法维护的模型。

SFT：向量模型的可行路径与误用边界

对多模态 embedding 而言，SFT 最容易被误解。传统语言模型 SFT 通过 teacher-forced token loss 学会输出文本；dense embedding 则输出向量，主要目标是距离结构。因此，严格说，embedding 的“后训练”常常不是 token SFT，而是 supervised representation tuning：在带指令、带正负样本、带教师分数的数据上优化对比或排序蒸馏损失。

可行路径一：指令化对比训练

VLM2Vec 的关键信号是把任务说明纳入 embedding 输入，使同一个 VLM 可以在不同任务下形成可比较表示 [S01]。这对工业系统尤其重要：商品图搜、图文 RAG、视觉文档问答、视频检索的相似性定义不同。如果不把任务写入输入，模型会把“相似图片”“同款商品”“能回答问题的文档页”“同一事件视频片段”混成一种距离。

落地时，训练样本至少应包含四元组：(instruction, query, positive, negatives)。instruction 不是装饰性前缀，而是决定监督语义的条件。负例也不能只靠随机采样，需要包括同类商品、近似布局文档页、相同 OCR 但不同图像证据、相似视频封面但事件不同的 confusers。

可行路径二：难负例与 reranker 蒸馏

Qwen3 和 Qwen3-VL 的公开资料都把 embedding 与 reranker 放在同一系统里理解。embedding 负责高覆盖召回，reranker 负责高精度比较；reranker 的分数、排序和失败样本反过来构成 embedding 后训练数据 [S03][S04]。

这个闭环比简单扩充正样本更重要。对于多模态检索，最常见失败不是“模型完全不懂图片”，而是相似外观、同品牌不同型号、同页面不同表格、视频同封面不同片段、商品标题属性缺失等细粒度错误。hard-negative curriculum 能把这些错误显式喂给向量模型。

可行路径三：MRL 与多粒度服务

Qwen3 系列公开提到 Matryoshka Representation Learning，这代表一种工程化诉求：同一模型输出可以在不同向量维度上服务不同成本层级 [S03][S04]。后训练时不能只看最高维度指标，也要验证缩短维度后的 Recall@K、类目长尾、跨语言、跨模态和 latency cost。

SFT 数据	训练目标	可接受证据	常见陷阱
人工或业务日志 pair/triplet	对比损失、margin loss、multi-negative loss	冷启动类目和跨模态 holdout 提升，而非只在训练相邻类目提升。	随机负例过易，导致线上 top-k 几乎无改善。
LLM/VLM 合成 queries 与 captions	query 多样化、指令泛化、跨语言增强	人工抽检通过，合成分布不覆盖真实 query 频率。	模型学会 caption 模板，而不是学会视觉证据。
reranker teacher scores	score distillation、排序蒸馏、soft label	蒸馏后召回和 rerank pipeline 总 NDCG 同时提升。	把 teacher 的 benchmark bias 压进召回模型。
page image 与 visual document labels	late interaction 或多向量对齐	ViDoRe 风格页面检索、表格页、扫描件和版式变化测试。	OCR 管线已经足够时，盲目引入多向量导致成本上升。

RL：更适合 rerank 与检索代理

RL 的优势是直接优化目标函数以外的任务收益；它的代价是高方差、reward 设计、线上分布模拟和训练成本。对 dense embedding 来说，top-k 检索结果依赖索引、近邻搜索和离散候选集合，直接 credit assignment 很难。对 reranker 来说，候选集固定、排序指标明确，RL 的落点自然得多。

为什么 dense embedding 不应优先做直接 RL

纯向量模型的输出是连续向量，但业务 reward 往往来自离散 top-k：用户是否点击、答案是否能被生成、候选是否同款、排序是否正确。训练时还要面对索引刷新、ANN 近似误差、负例池漂移、batch 内样本不代表线上候选集等问题。把这些都塞进 RL，通常会让训练变得复杂而不稳定。

这并不表示 RL 与 embedding 无关。更合理的路径是：先用 reranker、检索代理或 query reformulator 做 RL，得到更高质量的排序、查询改写、hard negatives 或 teacher scores，再蒸馏回 embedding。这样 RL 优化发生在能定义动作和 reward 的模型面，embedding 仍用稳定的表征损失吸收结果。

reranker 的 RL 可行性更高

MM-R5 是一个明确例子：它先用 SFT 让模型生成多模态检索 reasoning chain，再用任务特定 reranking reward 和 reasoning template reward 继续优化 [S06]。这说明 RL 在 rerank 面有三个优势：候选集较小，reward 可以绑定 NDCG/MRR/answerability，生成式 reasoning 能被格式或证据奖励约束。

Pailitao-VL 的工业信号也指向同一方向：大规模商品视觉检索的后段重排从 pointwise 走向 listwise compare-and-calibrate policy [S08]。对商品搜索而言，用户看到的是一页结果，而不是孤立的 query-item pair；listwise 信号能显式学习同屏候选之间的替代、互补和校准关系。

RL 对象	动作空间	reward 来源	推荐程度
Dense encoder	向量位置或相似度结构	top-k 命中、点击、问答成功	低 仅建议研究性探索或非常成熟的模拟器场景。
Cross-encoder reranker	候选得分、pairwise/listwise order	NDCG、MRR、人工偏好、教师排序	高 候选集稳定时可以做 SFT plus RL。
Generative reranker	解释、证据链、最终排序	排序指标、证据引用、格式约束、答案可用性	高 适合视觉推理和文档检索 rerank。
Query reformulator / retrieval agent	查询改写、检索轮次、过滤条件	下游召回、答案正确性、成本惩罚	中 需要严格成本和越权检索约束。

上线原则：没有稳定 candidate generator、离线 reward 与线上业务指标相关性、反作弊 judge、人工抽检和延迟预算，就不要把 RL 接入生产检索链路。RL 的第一批收益应发生在 reranker 或 retrieval policy，而不是直接改向量空间。

OPD: 适合有轨迹的多模态决策面

OPD 解决的问题可以概括为: SFT 在 teacher 或数据集前缀上学习, 学生部署后却在自己的状态分布上生成; 这种 distribution drift 会让后续 RL 或推理轨迹不稳定。OPD 让 student 先在自己的轨迹上 rollout, 再由 teacher 在这些状态上给更密集的 token 级或步骤级反馈 [S13][S14]。

为什么 OPD 不是 dense embedding 的直接替代

dense embedding 模型通常不生成 token 轨迹, 训练目标也不是“下一个 token”。因此, OPD 无法像作用于语言模型那样直接作用于一个纯向量编码器。若要把 OPD 用到 embedding 系统, 通常需要引入一个会生成的中间面: query reasoner、caption/attribute generator、generative reranker、检索代理或 teacher model。OPD 先改善这个中间面的状态分布, 再把结果转成 pair、hard negatives、teacher scores 或 reasoning-conditioned inputs, 最后仍用对比学习或蒸馏训练 embedding。

OPD 对多模态 reranker 的价值

PRISM 将多模态训练链路写成 SFT 到 OPD pre-alignment 到 RLVR, 目标是缓解 SFT 到 RL 时的分布漂移 [S15]。Vision-OPD 则把教师和学生放在不同视觉信息条件下, 用 crop-conditioned teacher 指导 full-image student rollout, 针对细粒度视觉理解做在策略蒸馏 [S16]。二者共同说明: OPD 的有效面不是“任何模型”, 而是有可观察轨迹、有 teacher feedback、有分布漂移的多模态决策过程。

适合 OPD 的场景

- 视觉问答式 rerank: 模型需要解释为什么某个候选能回答 query。
- 文档页检索: 模型需要在表格、图章、版式和文字之间定位证据。
- 商品比较: 模型需要生成属性差异、替代关系和排序理由。
- SFT 到 RLVR 过渡: 学生 rollout 与 SFT 数据分布差距很大。

不适合直接 OPD 的场景

- 只输出固定维度向量, 且没有可生成的中间状态。
- 业务标签只是 pair 正负, reward 尚未校准。
- teacher 无法稳定评价学生轨迹, 或 teacher 与线上目标冲突。
- 主要瓶颈是数据清洗、负例挖掘、索引刷新和服务成本。

OPD 可行方案

方案	训练流程	最终落点	验证方式
OPD for generative reranker	SFT 学会候选比较格式, student 对候选集生成排序和理由, teacher 在学生轨迹上给 token/step feedback。	reranker 本身, 或蒸馏成轻量 cross-encoder。	比较 SFT、SFT plus OPD、SFT plus OPD plus RL 的 NDCG、错误解释率和延迟。
OPD for visual grounding	teacher 看到 crop 或增强证据, student 只看原图或页面, 学生 rollout 后接受 teacher 反馈。	细粒度视觉理解模块、文档页 rerank、视觉证据提取器。	遮挡、裁剪、同款不同属性、视觉反事实测试。
OPD-assisted embedding	reasoner 经 OPD 改善 query decomposition、attribute extraction 和 hard-negative explanation, 再转成 embedding 训练数据。	dense embedding 的监督数据与蒸馏标签。	embedding 本身仍用 Recall@K、MRR、跨域 holdout 和 index 成本验证。

落地配方：四条可执行训练链路

实际团队不应从算法名开始，而应从数据形态、服务延迟、候选规模和评测预算开始。下面四条配方覆盖最常见的生产场景。

配方 A：领域多模态 dense embedding

目标 提高一阶段或二阶段召回，覆盖图文、商品、文档页、视频片段等候选。

1. 构建任务说明：每个样本明确是同款、同义、可回答、同事件、同风格还是同属性。
2. 整理 pair/triplet/list 数据：保留来源、时间、类目、语言、模态、人工置信度。
3. 先训练 instruction contrastive baseline，再引入 hard negatives 和 teacher score distillation。
4. 如果服务需要多成本档位，加入 MRL 并在多个向量维度上分别验证。
5. 上线前评估 Recall@K、类目长尾、跨模态 query、噪声标题、OCR 错误、视觉反事实和 ANN latency。

适用证据：VLM2Vec、VLM2Vec-V2、Qwen3/Qwen3-VL、Gemini Embedding 2 [S01][S02][S03][S04][S09]。

配方 B：多模态 reranker

目标 在固定候选集上提升 NDCG、MRR、top-1 精度和答案可用性。

1. 从 embedding 或现有召回系统收集真实候选集，不用离线随机负例替代线上候选分布。
2. 训练 cross-encoder 或 generative reranker：输入 query、候选文本、图像、页面或视频片段，输出 score、yes/no logits 或 listwise order。
3. 用 SFT 固定输入格式、证据引用和排序理由；再视 reward 稳定性引入 RL。
4. 把 reranker 的困难样本和软分数蒸馏回 embedding，形成召回与重排协同闭环。

适用证据：Qwen3 reranker、Qwen3-VL reranker、MM-R5、Pailitao-VL [S03][S04][S06][S08]。

配方 C：视觉文档 late interaction

目标 处理 PDF、扫描件、票据、合同、表格、幻灯片和复杂页面。

1. 先判断 OCR text pipeline 是否足够。如果文本结构完整，late interaction 不是默认选择。
2. 对页面图像生成多向量表示，保留布局和局部视觉证据，使用 late interaction 做 query-page 匹配。
3. 把页面级召回接入 reranker，由 reranker 负责跨页比较、证据定位和答案可用性判断。
4. 重点监控 index size、查询延迟、页面压缩、图像分辨率和视觉证据丢失。

适用证据：ColPali 和视觉文档检索路线 [S05]。

配方 D: OPD 插入 SFT 与 RLVR 之间

目标 当 reranker 或检索代理在 SFT 后进入 RL 时，用 OPD 缓解学生状态分布漂移。

1. 用 SFT 学会候选比较、视觉证据描述、查询分解、引用格式和安全边界。
2. 让 student 在真实候选集或困难集上 rollout，而不是继续只看 teacher demonstrations。
3. teacher 在 student 的轨迹上给 token、step、evidence 或 preference feedback。
4. OPD 后再接 RLVR 或 ranking reward，最后把提升样本蒸馏回 reranker 或 embedding。

适用证据：OPD 机制、OPD survey、PRISM、Vision-OPD [S13][S14][S15][S16]。

评测、风险与上线门槛

多模态检索的评测最容易被单一指标误导。一个 embedding 模型可以在图文检索 benchmark 上表现很好，却在商品同款、视觉文档问答、长尾类目或多语言 query 上失败。一个 reranker 可以提高离线 NDCG，却因延迟、candidate mismatch 或 judge leakage 无法上线。

评测矩阵

层级	必须指标	诊断指标	失败信号
Embedding	Recall@K、MRR、NDCG@K、跨模态 holdout、跨语言 holdout。	hard-negative 命中率、false negative 审计、MRL 维度退化、ANN recall loss。	随机负例提升显著但线上 top-k 无改善；文本字段变化导致视觉检索崩溃。
Late interaction	page-level Recall@K、视觉文档 query NDCG、证据页命中。	index size、page token 数、分辨率敏感性、OCR-free 与 OCR-assisted 对比。	指标提升来自页面模板记忆，成本却超过 reranker 预算。
Reranker	NDCG@K、top-1 accuracy、MRR、校准误差、延迟。	同屏多样性、listwise swap 错误、候选分布漂移、teacher-student gap。	离线榜单提升但真实候选集上退化；理由文本正确而排序错误。
RL/OPD	相对 SFT baseline 的稳定增益、reward-业务相关性、人工偏好审计。	judge hacking、轨迹长度、格式奖励占比、视觉证据引用准确率。	模型学会讨好 reward，但视觉 grounding 或用户目标变差。

数据和实验卫生

- 时间切分：商品、文档、视频和 query 分布会漂移。训练、验证、测试至少需要时间切分，不能只做随机切分。
- 类目切分：同类相似负例要进入验证集。只在训练类目内验证，会高估泛化。
- 模态消融：分别屏蔽文本、图像、OCR、视频帧、音频，检查模型是否依赖捷径。
- teacher 审计：teacher score 不是事实。需要抽样人工复核，并记录 teacher 与业务目标冲突的样本。
- 成本约束：所有指标都要带延迟、QPS、索引大小、显存、批处理吞吐和刷新频率。

上线门槛

离线通过

- 新模型相对强 baseline 在目标任务有稳定提升。
- hard-negative、跨类目、跨语言、跨模态 holdout 无显著退化。
- MRL 或压缩维度满足成本档位。
- reranker 延迟、batch size 和超时策略可上线。

线上通过

- 灰度 A/B 与业务主指标、护栏指标方向一致。
- query 分布、类目分布和候选分布与训练评测可解释。
- 失败样本能回流到 hard-negative 和 reranker 蒸馏流程。
- 回滚、索引刷新、模型版本和数据血缘可追踪。

最小可发布标准: embedding 至少要证明召回泛化; reranker 至少要证明候选集内排序提升和延迟可控; RL/OPD 至少要证明相对 SFT baseline 的真实增益, 而不是只证明训练曲线或 reward 上升。

决策树与资料索引

下面的决策树把本文判断压缩成执行顺序。大多数团队应先完成数据、对比训练、难负例、reranker 蒸馏和评测，再考虑 RL/OPD。

问题	如果是	如果不是
主要瓶颈是召回覆盖不足吗？	先做 instruction contrastive tuning、hard negatives、合成 query 和 reranker distillation。	不要先改 embedding，检查 rerank、候选生成和业务排序目标。
候选集内 top-k 顺序错误明显吗？	训练 cross-encoder 或 generative reranker，先 SFT，后续再看 RL。	继续优化召回、多样性或 query understanding。
模型需要生成解释、查询分解或检索动作吗？	可以考虑 OPD 或 RL，因为存在轨迹和 teacher feedback。	OPD 通常不是第一优先级。
文档页视觉布局是关键信号吗？	评估 ColPali 式 late interaction 或多向量检索。	单向量 embedding 加 reranker 可能更经济。
离线 reward 与线上目标相关吗？	小规模 RL/OPD 灰度，配合人工审计和成本护栏。	先校准评测，不要用 RL 放大错误目标。

推荐路线图

- 第 0 周：定义任务口径，建立 source map、数据血缘、验证集和线上候选采样。
- 第 1 到 2 周：训练或接入 baseline embedding，完成 task instruction、hard negatives、跨模态 holdout。
- 第 3 到 4 周：训练 reranker，建立 embedding-reranker 蒸馏闭环。
- 第 5 到 6 周：对文档页或视觉商品引入 late interaction、listwise rerank 或 attribute reasoning。
- 第 7 周以后：只有当生成式 rerank 或检索代理成为瓶颈，并且 reward 已校准，才引入 RL/OPD。

资料索引

ID	资料	本文用途
S01	VLM2Vec, MMEB	指令化多模态 embedding 与任务基准。
S02	VLM2Vec-V2, MMEB-V2	视频、视觉文档和扩展任务评测。
S03	Qwen3 Embedding/Reranker	文本 embedding/reranker 的多阶段训练与工业接口类比。
S04	Qwen3-VL-Embedding/Reranker	多模态 embedding plus reranker 系统范式。
S05	ColPali	视觉文档 late interaction。
S06	MM-R5	SFT plus RL reranker。
S07	Think Then Embed	reasoning before embedding。
S08	Pailitao-VL	工业视觉商品检索与 listwise rerank。
S09-S12	Gemini Embedding 2, Nova, PinCLIP, Amazon MML-TP	工业产品能力、数据质量和推荐检索落地约束。
S13-S16	OPD blog, OPD survey, PRISM, Vision-OPD	OPD 机制、多模态 reasoning 和视觉对齐。
S17-S18	Cohere, Voyage product docs	托管多模态 embedding 产品信号。

最终判断：多模态 embedding/rerank 后训练的成熟形态是一条系统链路，而不是单点算法。embedding 用稳定的表征学习吸收任务语义，reranker 用更强交互模型处理候选内细节，RL 和 OPD 只在可定义轨迹、reward 与 teacher feedback 的地方承担后训练增益。